

데이터 리터러시

03 / 믿을 수 있는 데이터

목차

- 01 분석 신뢰도
- 02 데이터 편향/오류/결측
- 03 데이터 수집 원천
- 04 데이터의 연결

④ 분석 신뢰도

데이터 양이 충분하다면, 무조건 분석 결과를 신뢰할 수 있을까?

- 데이터 자체가 틀렸다면?
- 데이터의 많은 부분을 분석가가 임의로 채웠다면?
- **실제 사실**을 얼마나 정확하게 담고 있는가?

데이터
편향

데이터
오류

결측
데이터

🔍 용어 해설

데이터 편향

데이터가 전체 모수를 포괄하지 못하고 특정 표본만을 대표하는 것

데이터 오류

데이터가 사실이 아닌 잘못된 정보를 적재하는 경우

결측 데이터

수집 혹은 적재과정에서 누락된 데이터

03 믿을 수 있는 데이터

④ 데이터 Mind set

- 신뢰도 높은 데이터를 분석하고 수집하는 자세가 필요
- 데이터에 대한 믿음이 선행되어야 분석이 가능

④ 실제 사실을 정확하게 담고 있는가?

오류가 있는 정보들로 데이터 구성, 잘못된 방법으로 데이터 분석 진행 등

모든 데이터와 데이터 분석 결과는 항상 사실만을 담고 있지 않음

용어 해설

모수

모집단의 특성

④ 실제 사실을 정확하게 담고 있는가?

예시

각종 매체에서 공개한 평판 지수

대부분의 평판 지수는 '웹 상에 해당 이름이 얼마나 많이 검색되고 있느냐'
평판지수를 만듦에 있어 정확한 기준을 발표하고 있는 곳은 많지 않음

검색을 자주한다고 높은 평판? → 부정적 여론 형식으로 검색 가능성

용어 해설

모수

모집단의 특성

④ 실제 사실을 정확하게 담고 있는가?

예시

각종 매체에서 공개한 평판 지수

정확한 평판 조사를 위해선

긍정적 단어와 함께 검색 된 것은 + , 부정적 단어와 함께 검색된 것은 -

명확한 기준에 의해 필터링 되지 않은 데이터로 분석된 결과는 신뢰할 수 없음

용어 해설

모수

모집단의 특성

④ 데이터 편향 _ 데이터가 전체 모수를 대표하지 못하는 경우

CASE 특정 회사 고객들의 멤버십 사용 현황을 분석하고자 할 때,

- 전체 고객의 멤버십 등급 별 비중은 동일하지 않을 확률이 높음
- 각 고객의 멤버십 등급마다 사용할 수 있는 혜택은 차별적

Q. 전체 등급을 통틀어 가장 인기있는 혜택을 살펴보려면?

Q. VVIP 등급의 회원이 잘 사용하는 혜택을 살펴보려면?

용어 해설

모수

모집단의 특성

④ 데이터 오류 _ 데이터가 사실이 아닌 정보를 적재하고 있는 경우

다음 자료에서의 문제는?

	성별	연령	거주지	학력	연봉
A	남성	23	서울특별시	대학교 재학	0
B	여성	17	서울특별시	고등학교 재학	0
C	남성	15	경기도 수원시	중학교 재학	
D	남성	39	인천광역시	대학교 졸업	5200만원
E	여성	9999	서울특별시	대학교 졸업	
F	여성	44	부산광역시	고등학교 졸업	5400만원

③ 데이터 오류 _ 데이터가 사실이 아닌 정보를 적재하고 있는 경우

평균연령 1689.5세?



	성별	연령	거주지	학력	연봉
A	남성	23	서울특별시	대학교 재학	0
B	여성	17	서울특별시	고등학교 재학	0
C	남성	15	경기도 수원시	중학교 재학	
D	남성	39	인천광역시	대학교 졸업	5200만원
E	여성	9999	서울특별시	대학교 졸업	
F	여성	44	부산광역시	고등학교 졸업	5400만원



9999세라는 연령?

④ 데이터 오류 _ 데이터가 사실이 아닌 정보를 적재하고 있는 경우

- 직접 설문하여 조사한 데이터라면?
- 데이터 오류는 그냥 삭제하면 될까?

데이터 오류는 명확히 검증할 방법이 부재,
수집 방법에 대한 이해와 숫자에 대한 합리적 추론이 필요

④ 결측 데이터

데이터가 누락된 경우, 데이터 파일에서 비어 있는 경우 등.

결측 데이터가 발생하는 원인과 데이터 처리 방법은 다양함

	성별	연령	거주지	학력	연봉
A	남성	23	서울특별시	대학교 재학	0
B	여성	17	서울특별시	고등학교 재학	0
C	남성	15	경기도 수원시	중학교 재학	
D	남성	39	인천광역시	대학교 졸업	5200만원
E	여성	9999	서울특별시	대학교 졸업	
F	여성	44	부산광역시	고등학교 졸업	5400만원



결측 데이터에 특별한 의미가 있는 경우 존재

👉 결측 데이터

머신러닝 분야에서는 결측치 처리 성능이 가시적


7 Ways to Handle Missing Values in Machine Learning

Popular strategies to handle missing values in the dataset

1. Deleting Rows with missing values
2. Impute missing values for continuous variable
3. Impute missing values for categorical variable
4. Other Imputation Methods
5. Using Algorithms that support missing values
6. Prediction of missing values
7. Imputation using Deep Learning Library — Datawig

④ 데이터 수집 원천

데이터 수집 원천, 데이터 가공 정도를 파악하는 것은 데이터의 신뢰성과 직결



용어 해설

원천 데이터

데이터 수집 이후 아무런 가공도 거치지 않은 데이터

EX) 웹 수집, 설문수집, 로그, 센서 데이터 등

④ 데이터 수집 원천

- 데이터베이스

여러 사람이 공유하여 사용할 목적으로 체계화해 통합, 관리하는 데이터의 집합

- 크롤링 데이터

인터넷 상에 있는 정보 중 자동화 기기로 탐색 및 수집한 데이터

- 로그 데이터

실제 현실에서 발생하는 사건을 데이터로 기록한 것

- 센서 데이터

물리적 환경으로 특정 기기가 반응하여 수집한 데이터

📖 용어 해설

원천 데이터

데이터 수집 이후 아무런 가공도 거치지 않은 데이터

EX) 웹 수집, 설문수집, 로그, 센서 데이터 등

④ 데이터 수집 원천

- 설문 데이터

설문조사를 실시한 결과를 기반으로 데이터를 수집한 것

- Open API 데이터

파일 혹은 API를 활용해 제공되어 있는 데이터

개발자에게 사유 응용 소프트웨어나
웹 서비스의 프로그래밍 적인 권한을 무료로 제공하는 것

🔗 용어 해설

원천 데이터


데이터 수집 이후 아무런 가공도 거치지 않은 데이터

EX) 웹 수집, 설문수집, 로그, 센서 데이터 등

03 믿을 수 있는 데이터

④ 크롤링 데이터 _ 크롤링 대상 되는 웹페이지 신뢰도를 파악해야 함

- 모든 웹 상의 데이터는 HTML 언어로 구조화되어 있어 이를 다시 확인 가능
- 웹 내에 존재하는 각 데이터를 수집하는 프로그램을 통해 데이터 수집



용어 해설

크롤링 데이터

인터넷 상에 있는 정보 중
자동화 기기로
탐색 및 수집한 데이터

④ 로그 데이터 – 행동 로그

웹/앱 등 로그 데이터가 수집된 경로에 따라 웹 로그 데이터, 앱 로그 데이터 등으로 총칭

- 로그 기록 자체의 오류가 발생할 수 있음
한 번의 행동 로그가 중복되어 데이터로 적재

- 로그 설계 과정에서 작업자의 실수가 있을 수 있음
행동 로그 값의 잘못된 인식

로그 데이터를 분석할 때는 로그 기록을 일부러 남기고, 이를 확인해보는 것이 바람직함

용어 해설

로그 데이터

실제 현실에서 발생하는 사건을
데이터로 기록한 것

④ 센서 데이터 _ IoT / 인공지능 분야에서 가장 중요하게 사용되는 데이터

- 데이터에 기록되어 있는 숫자의 의미를 가장 파악하기 어려운 데이터 중 하나
- 데이터의 용량이 매우 큰 경우가 많아 처리에 어려움이 있을 수 있음
- 센서 자체에 오류에 대한 점검 필요
- 전체 데이터 중 중복, 결측, 오류 데이터를 먼저 검증하는 과정이 필요

용어 해설

센서 데이터

물리적 환경으로부터 특정 기기가
반응하여 수집한 데이터

④ 설문 데이터 _ 설문에 응하는 사람이라는 것 자체로 데이터에 편향이 있을 수 있음

- 분석가가 원하는 내용의 데이터를 갖출 수 있는 가장 직접적인 데이터 수집 방법
- 대부분의 경우 데이터 개수가 적어 이를 감안한 분석 방법이 필요
- 무성의한 응답을 방지하기 위해 설문 계획 수립 단계부터 장치가 필요

용어 해설

설문 데이터

설문조사를 실시한 결과를 기반으로 데이터를 수집한 것

Open API 데이터

용어 해설

Open API 데이터

파일 혹은 API를 활용해 제공되어 있는 데이터

 이 누리집은 대한민국 공식 전자정부 누리집입니다.

검색어를 입력해 주세요.

목록등록관리시스템로그인회원가입사이트맵ENGLISH

DATA 공공데이터포털 . GO . KR

데이터찾기국가데이터맵데이터요청데이터활용정보공유이용안내

오픈API 상세



URL 복사

XML

건강보험심사평가원_코로나19병원정보(국민안심병원 외)서비스

활용신청

코로나바이러스감염증-19(COVID-19) 관련 병원 운영 현황 정보 등 제공

- 국민안심병원,

- 코로나-19 검사 실시기관

- 코로나-19 선별진료소

9

0

관심

OpenAPI 정보

 메타데이터 다운로드

 오픈API 에러코드

데이터 개선요청

오류신고 및 문의

분류체계	보건 - 보건의료	제공기관	건강보험심사평가원
관리부서명	빅데이터실 빅데이터전략부	관리부서 전화번호	033-739-1047
API 유형	REST	데이터포맷	XML
활용신청	1954	키워드	국민안심병원,코로나-19 검사 실시기관,선별진료소

④ Open API 데이터

- 파일 API를 통해 데이터 제공받는 다는 것 = 외부 조직의 데이터를 사용
- 사용자 입장에서 해당 데이터에 남겨진 수치가 무엇을 의미하는지 파악해야 함
- 제공받은 파일 혹은 API의 신뢰도가 선행되어야 전체 데이터 신뢰성 판단 가능
: 데이터에 문제가 있을 시 이를 보완하는 것이 어려움
- 메타 데이터(Meta Data)를 확보하여 데이터에 대한 명확한 이해 필요

용어 해설

Open API 데이터

파일 혹은 API를 활용해 제공되어 있는 데이터


④ 데이터의 연결

- 데이터 분석을 할 때 단일 데이터를 사용하는 것 보다는 여러 데이터를 연결
: 양질의 데이터는 다른 데이터와 연결되기 좋은 구조를 띄고 있어야 함

이름	성별	나이	직업
짱구	남자	5	유치원생
철수	남자	5	유치원생
유리	여자	5	유치원생



이름	거주지	학력
짱구	일본	미취학
빌게이츠	미국	고졸



이름	성별	나이	직업	거주지	학력
짱구	남자	5	유치원생	일본	미취학
철수	남자	5	유치원생	?	?
맹구	남자	5	유치원생	?	?
유리	여자	5	유치원생	?	?

용어 해설

Data Join


특성 속성(열)을 기준으로 다른 데이터를 연결

Data Concat

데이터를 가로/세로 축 기준으로 연결

④ 데이터의 연결의 종류

Data Concat 데이터를 수직/수평으로 이어 붙여 데이터 병합



용어 해설

Data Join


특성 속성(열)을 기준으로 다른 데이터를 연결

Data Concat

데이터를 가로/세로 축 기준으로 연결

☑ 데이터의 연결의 종류

Data Merge 데이터를 공통된 컬럼(열)을 기준으로 병합



✍ 용어 해설

Data Join

특성 속성(열)을 기준으로 다른 데이터를 연결

Data Concat

데이터를 가로/세로 축 기준으로 연결

④ 데이터의 연결의 종류

Data Merge는 그 종류에 따라 inner, outer, left, right 4가지로 구분

