

데이터 리터러시

04 / 양질의 데이터를 통한 데이터 커뮤니케이션

④ 상관관계 vs 인과관계


여러 데이터를 연결해 데이터를 분석할 때 데이터의 **연관성**에 주목

상관관계

특정 요인들이 함께 움직이는 경향이 있다
아이스크림 판매량과 모기약의 판매량은 특정 시기에 함께 늘어난다 (여름철)

인과관계

요인들 간 관계가 원인과 결과의 형식을 띄고 있다
모기약의 판매량이 늘어나는 것은 아이스크림 판매량이 늘어났기 때문이다



용어 해설

상관관계


특정 요인들이 서로 간의 함께 움직이는 경향이 있다는 것을 의미

인과관계

요인들 간 관계가 원인과 결과 형식을 띄고 있는 것을 의미

☑ 관계형 데이터베이스

- 3V = Velocity + Volume + **Variety**
- 다양한 종류의 데이터를 알맞게 구분 지어 저장




✍ 용어 해설

관계형 데이터베이스

데이터베이스 양식 중 하나로 데이터를 행(Row)과 열(Column)의 테이블(Table) 형식으로 저장하여, 서로 관계 있는 데이터를 관리하는 양식

☑ 관계형 데이터베이스의 중요성

- 다른 데이터와 결합할 수 있는 가능성
- 키(Key)의 존재, 유일성과 무결성 조건
- 보유한 다른 데이터와 유기적으로 연결하여 넓은 시야로 데이터를 분석하기 위함



✍ 용어 해설

키(Key)

데이터의 속성(열) 중 식별자로 이용 가능한 속성

유일성


하나의 키가 하나의 식별 값을 정확히 식별할 수 있는 성질

무결성

데이터에서 키값이 비어 있거나 중복되지 않아야하는 성질

키, 유일성, 무결성

- 조건에 맞는 키를 가지는 것이 관계형 데이터베이스의 핵심
- 키 존재여부, 조건 만족 여부를 파악하는 것이 모든 데이터 분석의 첫째 과정



용어 해설

키(Key)

데이터의 속성(열) 중 식별자로 이용 가능한 속성

유일성

하나의 키가 하나의 식별 값을 정확히 식별할 수 있는 성질

무결성

데이터에서 키값이 비어 있거나 중복되지 않아야하는 성질

④ 키(Key) _ 키가 없으면 사실상 데이터 분석이 불가능

키 하나만을 보았을 때 그 전체 데이터를 추적할 수 있어야 한다는 것

- 데이터에 키가 없다면 해당 데이터가 어떤 개인 혹은 상황을 의미하는지 알 수 없음
→ 데이터 분석을 완성하더라도 이를 실제로 활용할 수 없음
- 데이터에 키가 없다면 다른 데이터와 연결을 하는 것이 불가능

우리나라 국민의 정보를 수집하여 데이터화 한다고 할 때?

이름	성별	나이	직업
짱구	남자	5	유치원생
철수	남자	5	유치원생
유리	여자	5	유치원생

이름	거주지	학력
짱구	일본	미취학
빌게이츠	미국	고졸

용어 해설

키(Key)

데이터의 속성(열) 중 식별자로 이용 가능한 속성

유일성

하나의 키가 하나의 식별 값을 정확히 식별할 수 있는 성질

무결성

데이터에서 키값이 비어 있거나 중복되지 않아야하는 성질

④ 유일성 _ 키의 조건

하나의 키로 하나의 데이터만 식별 가능해야 한다.

중복을 제외한 전체 데이터의 개수 vs 중복을 제외한 전체 키의 개수

- 겹보기에 키의 역할을 하는 데이터가 있더라도 유일성을 확인해보아야 함
- 키의 정의를 생각해 보았을 때 반드시 만족되어야 하는 개념

일반적인 데이터에서 이름이 키의 역할을 할 수 있을까?

이름	성별	나이	직업
짱구	남자	5	유치원생
철수	남자	5	유치원생
유리	여자	5	유치원생

이름	거주지	학력
짱구	일본	미취학
빌게이츠	미국	고졸

용어 해설

키(Key)

데이터의 속성(열) 중 식별자로 이용 가능한 속성

유일성

하나의 키가 하나의 식별 값을 정확히 식별할 수 있는 성질

무결성

데이터에서 키값이 비어 있거나 중복되지 않아야하는 성질

④ 무결성 _ 데이터베이스 및 키의 조건

개체 무결성	참조 무결성
모든 데이터는 키를 가져야 하며 중복이거나 결측일 수 없다.	참조 관계에 있는 두 데이터가 항상 일관된 값을 가진다.

- 겉보기에 키의 역할을 하는 데이터가 있더라도 무결성을 확인해보아야 함
- 키의 정의를 생각해 보았을 때 반드시 만족되어야 하는 개념
중복을 제외한 전체 데이터의 개수 vs 중복을 제외한 전체 키의 개수

🔗 용어 해설

- 키(Key)
데이터의 속성(열) 중 식별자로 이용
가능한 속성
- 유일성
하나의 키가 하나의 식별 값을
정확히 식별할 수 있는 성질
- 무결성
데이터에서 키값이 비어 있거나 중
복되지 않아야하는 성질

④ 무결성 _ 데이터베이스 및 키의 조건

개체 무결성

모든 데이터는 키를 가져야 하며 중복이거나 결측일 수 없다.

참조 무결성

참조 관계에 있는 두 데이터가 항상 일관된 값을 가진다.

키를 기준으로 데이터를 연결시켰을 때 데이터가 명확하게 연결되는 지

이름	성별	나이	직업
짱구	남자	5	유치원생
철수	남자	5	유치원생
유리	여자	5	유치원생

이름	거주지	학력
짱구	일본	미취학
빌게이츠	미국	고졸

용어 해설

- 키(Key)

데이터의 속성(열) 중 식별자로 이용 가능한 속성
- 유일성

하나의 키가 하나의 식별 값을 정확히 식별할 수 있는 성질
- 무결성

데이터에서 키값이 비어 있거나 중복되지 않아야하는 성질

④ 순수한 정형데이터

데이터 형식에 따라 나뉘는 데이터 품질

▶ 모든 데이터는 생김새에 차이가 있음

빅데이터가 강조되며 데이터의 개념은 확대

▶ 빅데이터는 다양한 경로로 수집되고 가공됨

정형 데이터

- 1. 정해진 형식과 구조가 있음
- 2. 행과 열의 형태로 엑셀 형식

비정형 데이터

- 1. 정의된 구조가 없는 데이터
- 2. 수치 데이터 외 대부분

용어 해설

정형 데이터

미리 정해 놓은 형식과 구조가 있어
그에 따라 고정된 자리에 저장된
데이터

비정형 데이터

정해 놓은 구조가 없는 데이터

④ 정형 데이터 vs 비정형 데이터

정형 데이터와 비정형 데이터는 활용 방식에 차이를 보임

분석 목적이 명확하다면, 데이터 형식으로부터
어느 정도 양질의 데이터를 파악하는 것이 가능

용어 해설

정형 데이터

미리 정해 놓은 형식과 구조가 있어
그에 따라 고정된 자리에 저장된
데이터

비정형 데이터

정해 놓은 구조가 없는 데이터

④ 정형 데이터 vs 비정형 데이터

비정형 데이터

- 딥러닝을 통한 AI 구현 활용 분야에 대부분을 활용
- 통계 기법을 적용하는 것에 한계가 존재

POINT

- 비정형 데이터를 정성적으로 분석하기 위한 관련 연구도 활발히 진행 중
- 정성적 분석의 경우 비정형 데이터는 저품질의 데이터

용어 해설

정형 데이터

미리 정해 놓은 형식과 구조가 있어
그에 따라 고정된 자리에 저장된
데이터

비정형 데이터

정해 놓은 구조가 없는 데이터

④ 정형 데이터 vs 비정형 데이터

정형 데이터

- 평균, 표준편차, 단순 시각화 등 일차적 데이터 분석
- 심화된 통계 기법을 적용
- 머신러닝을 비롯한 AI 알고리즘 구현

다양한
활용 방법이 존재

POINT

- 변수의 속성에 따라 데이터 활용성 차이가 날 수 있음

용어 해설


정형 데이터

미리 정해 놓은 형식과 구조가 있어
그에 따라 고정된 자리에 저장된
데이터

비정형 데이터

정해 놓은 구조가 없는 데이터

④ 변수의 속성



용어 해설

명목척도	서열척도
주민번호	등수
등간척도	비율척도
온도	몸무게

④ 범주형 데이터

명목 척도

서열 척도

범주형 데이터는 **사칙 연산이 불가능**
= 수학적 연산에 한계가 있기에 적용 가능한 기법에도 제한

남자(1) * 2 = 여자(2)

2등 x 2 = 4등

수치형 데이터로만 구성된 데이터를 찾는 것은 욕심
통계적 분석의 카이제곱 검정, 머신러닝의 CatBoost 등의 기법 존재
범주형 데이터의 비중이 얼마나 되는가?

용어 해설

명목척도	서열척도
주민번호	등수
등간척도	비율척도
온도	몸무게

04 양질의 데이터를 통한 데이터 커뮤니케이션

④ 정확한 양질의 데이터 판별

- 완벽한 양질의 데이터 판별은 불가능
- 데이터 양, 오류 정도, 양식, 속성은 하나의 도구일 뿐

좋은 데이터 ≠ 매번 쓰이는 데이터
나쁜 데이터 ≠ 절대 쓰이지 않는 데이터

양질의 데이터 판별을 위한 최고의 방법은 **상황과 목적에 맞는** 데이터를 선별하는 것

④ DIKW 피라미드 이론


Data → Information → Knowledge → Wisdom

1) 데이터를 통해 지혜를 얻는 것에는 단계가 있다.

2) 지혜도 결국 데이터에 근거한다.

POINT 원하는 정보가 담겨있지 않으면 애초에 활용 불가

- '이 데이터도 수집하면 언젠간 사용되겠지'
- '이 데이터도 보다 보면 가능성이 있겠지'



용어 해설

DIKW 이론

데이터가 정보로, 정보는 지식으로, 지식은 지혜로 바뀌어 활용성을 띄게 된다는 내용

④ DIKW 피라미드 이론

Data 주관적인 의견이 배제된 사실

A 방송사의 드라마 평균 시청률은 1%, B 방송사의 드라마 평균 시청률은 5%이다

Information 데이터를 가공해 도출된 내용

A 방송사보다 B 방송사의 드라마가 더 재미있고 인기가 많다.

Knowledge 패턴이나 공식을 통해 새로운 사실을 알아낸 것

B 방송사의 드라마 제작 능력이 A 방송사보다 우수하다.

Wisdom 지식에 창의적인 아이디어를 더해 통찰을 얻은 것

새로운 드라마를 보고 싶으면 B방송사의 드라마를 찾는 것이 유리하다.

✍ 용어 해설

DIKW 이론

데이터가 정보로, 정보는 지식으로, 지식은 지혜로 바뀌어 활용성을 띄게 된다는 내용

④ 인사이트 분석 목적의 빅데이터

- 전통적인 데이터 활용 방법
- 궁극적인 목표는 데이터 내부에 존재하는 새로운 패턴을 발견하고 활용하는 것

→ 데이터 분석가의 역량이 더욱 중요하게 작용

→ 데이터 가공 정도와 그 의미가 연결

④ 머신러닝 목적의 빅데이터

- 최근 빅데이터 활용 트렌드
- 머신러닝 목적의 데이터 활용의 궁극적인 목표는 미래 상황에 대한 사전 예측

- 데이터에 종속 변수가 반드시 필요
- 목적에 따라 종속 변수는 다양하게 변할 수 있음
- 데이터 양 측면에서 학습 데이터가 충분해야 함

④ 양질의 데이터 판별

- 1) 목적이 명확하지 않다면 양질의 데이터를 논할 수 없음
- 2) 양질의 데이터를 100% 판별하는 방법도 없음
- 3) 특징을 염두에 두고 경험이 쌓이면 판단이 쉬움
- 4) 양질의 데이터 판별은 데이터 수집 및 분석에 효율성을 분명히 올릴 수 있음

04 양질의 데이터를 통한 데이터 커뮤니케이션

☑ 데이터 수집/활용 사이트 _ 공공데이터 포털

- 공공 데이터 포털에 올라오는 데이터는 다양한 활용처에 무료로 확인 가능
- 기술 특허, 부동산, 식당 등 다양한 종류의 데이터를 확인 가능

전체(69,000건)

파일데이터(51,733건)

오픈 API(9,050건)

표준데이터셋147개(8,217건)

수정일자순 ▾

5개씩 ▾

파일데이터 (51,733건)

더보기 >

사회복지

자치행정기관

미리보기

CSV

JSON + XML

충청북도_노숙인복지시설 현황

충청북도내 운영 중인 노숙인 복지시설 현황에 대한 데이터로 소재지, 시설명, 대표자, 소재지 도로명주소, 연락처 등의 항목을 제공합니다.

제공기관

충청북도

수정일

2022-06-17

조회수

1932

다운로드

695

주기성 데이터

3

키워드

노숙인,노숙인요양,노숙인재활

다운로드

환경기상

자치행정기관

미리보기

CSV

JSON + XML

대전광역시 중구_폐의약품 수거함 현황

대전광역시 중구 폐의약품 수거함 현황 (구분, 주소지, 전화번호, 데이터 기준일자) 정보를 제공합니다.수거함은 가까운 약국에도 설치가 되어 있지만 설치되어 있는 약국 정보를 보유하...

제공기관

대전광역시 중구

수정일

2022-06-17

조회수

6

다운로드

1

키워드

의약품,폐기물,수거

다운로드

공공행정

자치행정기관

미리보기

CSV

JSON + XML

전라남도 진도군_보조사업현황

전라남도 진도군 보조사업현황 공공데이터는 진도군 보조사업 보조사업명, 부서, 금액 , 보조금 등 정보를 제공합니다.

제공기관

전라남도 진도군

수정일

2022-06-17

조회수

1432

다운로드

410

주기성 데이터

2

키워드

보조사업,보조금,사업지원

다운로드



출처 : data.go.kr

🔖 용어 해설

공공데이터 포털

행정안전부에서 국민들에게 데이터를 제공하기 위해 만든 시스템

* 정부기관들은 공공 데이터 포털을 통해서 다양한 공공 데이터를 일반인에게 공개

04 양질의 데이터를 통한 데이터 커뮤니케이션

④ 데이터 수집/활용 사이트 _ 네이버 데이터랩

→ GUI 기반 방식을 통해 데이터 현황을 확인

→ 사람들이 상대적으로 많이 검색 한 검색어, 자주 구매를 한 쇼핑 카테고리 등 탐색



출처 : datalab.naver.com

용어 해설

네이버 데이터랩

네이버에서는 데이터랩을 통해 검색어나 쇼핑 관련 데이터를 제공

04 양질의 데이터를 통한 데이터 커뮤니케이션

④ 데이터 수집/활용 사이트 _ AI - hub

인공지능 모델을 만들고자 하는 사람들에게 공공데이터 포털/네이버 데이터 랩은 한계

- 대부분의 최근 인공지능 모델은 비정형 데이터를 기반으로 개발
- 인공지능 모델에 사용될 수 있는 데이터 제공에 초점을 맞추고 다양한 데이터를 제공
- 데이터 형식 혹은 데이터 분야에 따라 데이터를 구분



출처 : <https://www.aihub.or.kr/>

용어 해설

데이터 형식

문자, 이미지 등

데이터 분야

헬스케어, 농축수산

04 양질의 데이터를 통한 데이터 커뮤니케이션


☑ 데이터 수집/활용 사이트 _ 통합 데이터지도

- 데이터 검색/분류를 통해 이용자 입장에서 유용한 데이터를 찾을 수 있도록 기능 제공
- 일반적인 공공데이터보다 더욱 방대한 데이터 검색 결과
- 유료/무료 뿐 아니라 공공/민간 데이터를 모두 구분하여 검색할 수 있도록 기능을 제공

용어 해설

통합 데이터지도

데이터의 배포 뿐 아니라 유용하게 데이터를 활용하기 위한 도구



출처 : <https://www.bigdata-map.kr/>