

데이터 리터러시

02 / 좋은 데이터? 나쁜 데이터?

목차

- 01 데이터의 품질
- 02 데이터 목적 사고력
- 03 신뢰도 있는 데이터

☑ 데이터에도 품질이 있다

🏠 홈 > 정책

🖨 가 가

데이터 산업 시장 규모 19조 넘어...과기정통부, '2021 4차 산업혁명 지표' 발표

👤 이하나 기자 ⌚ 입력 2021.10.05 18:42 💬 댓글 0 ❤ 좋아요 0



AI, 클라우드, 데이터, 네트워크, VR·AR 기술로 DX 혁신
3월 공공데이터 개방 건수 5만 5561건으로 63.4% 늘어
AI 학습용 데이터 활용 횟수도 153.4% 증가해...관련 기업 933개로 측정

4200만개 판매!
독보적 1위 국민바디스크럽 플루

사설.칼럼 칼럼

[유레카] 디디추싱과 미-중 ‘데이터 전쟁’ / 박민희

 박민희 기자 [+구독](#)

사회 > 사회일반

‘보조금24’ 데이터, 민간 전면 개방

입력 2021-09-14 18:18:45 수정 2021.09.15 09:59:04 이지성 기자

02 좋은 데이터? 나쁜 데이터?

④ 데이터에도 품질이 있다

주민식 삼성SDS 박사 "AI 상용화, 질 좋은 데이터 확보에 답 있다"

✎ 김동원 기자 ⌚ 입력 2021.03.24 18:19 ⌚ 수정 2021.04.14 16:14 💬 댓글 1 ❤️ 좋아요 0

주 박사는 AI 상용화에 가장 큰 걸림돌로 데이터 확보 문제를 꼽았다. 기계학습(머신러닝)과 통계분석 기법을 적용하기 위해서는 질 좋은 데이터가 많이 필요하지만, 실제 관측된 데이터는 오염된 데이터가 많고 그 수도 적다는 것.

이 문제는 빙하로 이해할 수 있다. 사람은 빙하를 볼 때 흔히 수면 위 모습만 보고 판별한다. 하지만 수면 아래에는 엄청난 크기의 얼음 덩어리가 있다. 데이터도 사람이 관측하는 부분은 수면 위 빙하처럼 극히 일부에 불과하고, 진짜 데이터는 관측하지 못해 AI 개발에서 오류가 발생할 수 있다는 의미다.

눈에 보이는 데이터라도 기술적 문제로 인해 오류가 범해지기도 한다. 삼성SDS는 반도체 웨이퍼 품질 검사를 AI가 대신할 수 있는 시스템 개발에 착수한 적 있다. 이때 AI는 같은 패턴을 다르게 인식했다. 이유는 카메라에 있었다. 초정밀 카메라를 사용했지만, 사진에 웨이퍼 패턴이 다르게 인쇄되면서 알고리즘이 인식하는데 장애가 발생했다.

02 좋은 데이터? 나쁜 데이터?


☑ 데이터에도 품질이 있다

실제 데이터 수

저품질 데이터 > 고품질 데이터

분석에 활용되는 데이터의 수

저품질 데이터 < 고품질 데이터



02 좋은 데이터? 나쁜 데이터?

④ 데이터에도 품질이 있다

질 좋은 데이터에 대한 명확한 정의는 X

분석 하기 편한 데이터

분석할 가치가 있는 데이터

02 좋은 데이터? 나쁜 데이터?

④ 데이터에도 품질이 있다

많은 데이터 확보


○ 분석 가능한 자료의 증가

✕ 데이터를 통한 이익의 증가

02 좋은 데이터? 나쁜 데이터?

④ 빅데이터 활용 ≠ 프로젝트 성공


빅데이터



보고서 통과를 위한 마법의 단어

02 좋은 데이터? 나쁜 데이터?

④ 데이터 활용의 목적 = 성공적인 데이터 활용의 필수 요소



🏠 > 데이터레이크


빅데이터 | 애널리틱스

"실패 가능성 85%" 빅데이터 프로젝트의 문제와 해법

그린바움은 “대량의 데이터를 모으기만 한다면 데이터 쓰레기 매립지가 될 뿐이다. 쓰레기장에서는 해결책을 찾을 수 없다”면서 “항상 고객에게 **해결해야 할 개별적인 비즈니스 문제가 무엇인지 사전에 결정**해서 거기에 집중하고, 비즈니스 문제가 파악된 다음부터 가용한 데이터의 품질을 살피고 데이터 문제를 해결하라고 조언한다”고 말했다.

02 좋은 데이터? 나쁜 데이터?

④ 데이터 목적 사고력



02 좋은 데이터? 나쁜 데이터?

④ 데이터 목적 사고력

좋은 데이터? 나쁜 데이터?

상황과 목적에 맞는 데이터를 선별하는 것

02 좋은 데이터? 나쁜 데이터?

④ 데이터를 바라보는 관점

가짜뉴스와 진짜 뉴스

데이터 관점에서의 사실 확인

논리적으로 관련이 있는 데이터인지?

데이터가 틀리지는 않았는지?

02 좋은 데이터? 나쁜 데이터?

④ 데이터를 바라보는 관점

방향성에 대해
멀리서 내다보는
관점

나의 목적에 맞는
데이터를
핵심적으로
도출하는 관점

02 좋은 데이터? 나쁜 데이터?

✔ 비판적 데이터 수용





02 좋은 데이터? 나쁜 데이터?

④ 비판적 데이터 수용

자료의 X축, Y축 정보에 대한 꼼꼼한 확인

0 점이 정확하게 표시되어 있는지

데이터 간격이 정확히 유지되고 있는지



출처 : <https://hsm-edu.tistory.com/766>, <https://www.mk.co.kr/news/stock/view/2019/10/890840/>

02 좋은 데이터? 나쁜 데이터?

④ 데이터를 비판적으로 수용하기 위해 체크 포인트

- 1 데이터 출처
- 2 데이터 날짜
- 3 데이터 수집 방법
- 4 데이터 수집 기관
- 5 데이터 크기

02 좋은 데이터? 나쁜 데이터?

④ 데이터를 비판적으로 수용하기 위해 체크 포인트

빅데이터

- 방대한 양의 데이터
- 현실적으로 모든 데이터의 양이 방대하지는 않음
- 1,000개 미만의 데이터?

데이터의 양이 의미하는 것

- 적은 샘플로 검증 vs 많은 샘플로 검증
- 분석 결과의 신뢰성과 연결
- 데이터 양이 치명적인 경우?
- 충분한 데이터 양을 판별하는 방법?

02 좋은 데이터? 나쁜 데이터?

④ 용어 포인트

모집단

- 정보를 얻고자 하는 관심 대상의 전체집합

표본(집단)

- 모집단의 부분, 집단 속에서 그 일부를 뽑아내어 조사한 결과

(표본의) 대표성

- 표본이 모집단의 성질을 나타냄에 있어 어느 정도의 전형성을 확실히 나타내는지 여부

02 좋은 데이터? 나쁜 데이터?

☑ 사례로 알아보는 데이터 오류

1954년 미국 암 협회 소속 과학자

흡연과 폐암의 확실한 상관관계를 입증 논문 발표

18만7766명의 남자 흡연습관 조사 후,
조사 후 20개월 동안 조사 대상자 중 폐암 사망률

0.03%



X4

0.13%

비흡연자의 폐암 사망률

흡연자의 폐암 사망률

02 좋은 데이터? 나쁜 데이터?

☑ 사례로 알아보는 데이터 오류

1954년 미국 암 협회 소속 과학자

흡연과 폐암의 확실한 상관관계를 입증 논문 발표

1. 조사에 참여한 흡연자나 비흡연자 집단 모두
미국 남자들의 폐암 사망률보다 훨씬 낮은 사망률을 나타냈다.

= 조사가 건강한 사람들만을 대상으로 실시됨

2. 조사대상자 중에서 흡연자의 비율이 다른 조사에서 나타난
흡연자의 비율보다 낮다


= 많은 흡연자들이 조사에 참여하기를 거부했음

02 좋은 데이터? 나쁜 데이터?

④ 데이터의 양을 중요하게 고려해야 하는 경우

AI 알고리즘을 적용하고자 할 때, **많은 데이터 수 = 높은 성능의 AI**

- 절대적인 데이터 행의 수와는 다른 의미
- 최종적으로 분석 대상이 되는 데이터의 수



02 좋은 데이터? 나쁜 데이터?

☑ 데이터의 양을 중요하게 고려해야 하는 경우

경기도 광주시 기온데이터 (공공데이터 포털)

2018년 1월 1일 ~ 2019년 5월 31일
일별로 데이터를 보고 싶다면?

약 540개의 데이터

6월 15일의 평균 기온을
알고 싶다면?

하루치 데이터

	A	B	C	D	E
1	측정일시	측정주기	평균값	최소값	최대값
2	2018-01-01 0:00	M	-140	-140	-140
3	2018-01-01 0:00	H	-130	-130	-130
4	2018-01-01 0:00	D	-423	-450	-400
247385	2019-05-31 13:20	M	2365	2319	2400
247386	2019-05-31 13:30	M	2330	2300	2360
247387	2019-05-31 13:40	M	2335	2288	2369

02 좋은 데이터? 나쁜 데이터?

④ 데이터 양 = 분석 결과의 신뢰도와 연결

- (1500, 100)의 shape을 가진 데이터 셋을 통한 머신러닝?
- 동전을 던져 앞면이 나올 확률은 $\frac{1}{2}$ 일까?

