

ADsP 자격증 수업 개요

『데이터의 이해』

00 ADsP 자격증 대비반

교육 일정 : 06.30 (월) ~ 07.11(금)

교육 시간 : 18:30 ~ 22:30

쉬는 시간 : 45분 수업 / 15분 휴식

교육 강사 : 정지훈 강사

제1과목

『데이터의 이해』

I. 데이터의 이해

01 데이터와 정보

데이터의 유형

정성적 데이터: 저장, 검색, 분석에 많은 비용이 소모되는 언어, 문자 형태의 데이터 (ex. 인성평가)

정량적 데이터: 정형화된 데이터로 수치, 도형, 기호 등의 형태를 가진 데이터 (ex. 나이, 몸무게)

지식 경영의 핵심 이슈

암묵지: 학습과 경험으로 개인에게 체화되었으나 겉으로 드러나지 않은 지식 (ex. 자전거 타기)
→ 사회적으로 중요하지만 공유되기 어려움


형식지: 문서나 매뉴얼처럼 형상화된 지식 (ex. 손님 응대 매뉴얼, DB 등)
→ 상호 간의 전달과 공유가 용이함



I. 데이터의 이해

01 데이터와 정보

DIKW 피라미드



I. 데이터의 이해

02 데이터베이스

데이터베이스의 정의

- EU
체계적이거나 조직적으로 정리되고 전자식 또는 기타 수단으로 개별적으로 접근할 수 있는 독립된 저작물, 데이터 또는 기타 소재의 수집물
- 국내 저작권법
소재를 체계적으로 배열 또는 구성한 편집물로 개별적으로 그 소재에 접근하거나 그 소재를 검색할 수 있도록 한 것
- 국내 컴퓨터 용어사전
동시의 복수 적용 업무를 지원할 수 있도록 복수 이용자의 요구에 대응해서 데이터를 받아들이고 저장, 공급하기 위하여 일정한 구조에 따라서 편성된 데이터의 집합



I. 데이터의 이해

02 데이터베이스

데이터베이스의 특징

통합된 데이터 (Integrated Data)

- 동일한 내용의 데이터가 중복되지 않는다는 것을 의미
- 데이터 중복은 관리 상의 복잡한 부작용을 초래하므로 주의

I

공용 데이터 (Shared Data)

- 여러 사용자가 서로 다른 목적으로 공동 이용하는 것을 의미
- 대용량화 되고 데이터 구조가 복잡한 것이 보통

S

저장된 데이터 (Stored Data)

- 자기 디스크나 자기 테이프와 같이 컴퓨터가 접근할 수 있는 저장 매체에 저장되는 것을 의미
- 데이터 베이스는 기본적으로 컴퓨터 기술을 바탕으로 한 것

S

변화되는 데이터 (Changeable Data)

- 데이터베이스에 저장된 내용은 곧 현 시점의 상태를 나타냄
- 새로운 데이터의 삽입, 기존 데이터의 삭제, 갱신 등으로 항상 변화하면서도 현재의 정확한 데이터를 유지해야 함

C

I. 데이터의 이해

02 데이터베이스

데이터베이스의 다양한 측면에서의 특징

정보 축적 및 전달 측면

- 1) 기계 가독성
: 대량의 정보를 일정한 형식에 따라 컴퓨터 등의 정보처리기가 읽고 쓸 수 있다.
- 2) 검색 가능성
: 다양한 방법으로 필요한 정보를 검색할 수 있다.
- 3) 원격 조작성
: 정보통신망을 통해 원거리에서도 즉시 온라인으로 이용 가능하다.

정보 이용 측면

- 이용자의 정보 요구에 따라 다양한 정보를 신속하게 획득할 수 있고 원하는 정보를 정확하고 경제적으로 찾아낼 수 있다.

정보 관리 측면

- 정보를 일정한 질서와 구조에 따라 정리, 저장하고 검색, 관리할 수 있게 하여 방대한 양의 정보를 체계적으로 축적하고, 새로운 내용 추가나 갱신이 용이하다.

정보기술 발전 측면

- 정보 처리 검색 관리 소프트웨어 관련 하드웨어 정보 전송을 위한 네트워크 기술 등의 발전을 견인할 수 있다.

경제 산업적 측면

- 다양한 정보를 필요에 따라 신속하게 제공 이용할 수 있는 인프라의 특성을 가지고 있어 경제 산업 사회활동의 효율성을 제고하고 국민의 편의를 증진하는 수단의 의미를 가진다.

II. 데이터의 가치와 미래

01 빅데이터의 이해

빅데이터의 정의

- McKinsey (2011)

일반적인 DB 소프트웨어로 저장, 관리, 분석할 수 있는 범위를 초과하는 규모의 데이터
→ 데이터 규모 측면에 중점을 둔 정의


- IDC (2011)

다양한 종류의 대규모 데이터로부터 저렴한 비용으로 가치를 추출하고,
데이터의 초고속 수집, 발굴, 분석을 지원하도록 고안된 차세대 기술 및 아키텍처
→ 분석 비용 및 기술 측면에 초점을 둔 정의

빅데이터의 특성

- 가트너 그룹(Gartner Group) 더그 레니(Doug Laney)

빅데이터의 특성을 **Volume, Variety, Velocity** 라는 3V의 개념으로 정의함



II. 데이터의 가치와 미래

01 빅데이터의 이해

빅데이터의 새로운 특징

* 더그 레니의 3V에 이어 Value, Veracity를 포함하여 빅데이터 특징을 설명하기도 한다.

- Value(가치)

데이터의 전체를 파악하고 패턴을 발견하기가 어렵게 되면서 가치의 중요성이 강조된다.


- Veracity(정확성)

빅데이터 기반의 예측 분석 결과에 대한 신뢰성이 중요하게 되었다.

5V Value: 가치

4V Veracity: 정확성

3V



II. 데이터의 가치와 미래

01 빅데이터의 이해

빅데이터 정의의 범주 및 효과

데이터의 변화

- 3V : 규모(Volume), 형태(Variety), 속도(Velocity)

기술 변화

- 데이터 처리, 저장, 분석 기술 및 아키텍처
- 클라우드 컴퓨터 활용

인재, 조직 변화

- Data Scientist와 같은 새로운 인재 필요
- 데이터 중심 조직으로의 변화

빅데이터의 출현 배경

산업계의 출현배경

- 고객 데이터 추적, 보유를 통해 데이터에 숨어있는 가치를 발굴

학계의 출현배경

- 거대 데이터를 다루는 학문 분야가 늘어남에 따라
필요한 기술 아키텍처 및 통계 도구가 발전하면서 중요성 부각

기술 발전으로 인한 출현 배경

- 관련기술(저장 기술, 인터넷 보급, 클라우드 컴퓨팅, 모바일 혁명의 발달)

기존 방식으로는 얻을 수 없는 통찰 및 가치 창출 사업방식 ➡ 시장, 사회, 정부 등에서 변화와 혁신 주도

II. 데이터의 가치와 미래

01 빅데이터의 이해

빅데이터에 거는 기대

산업혁명의 석탄과 철

- 제조업 뿐만 아니라 서비스 분야의 생산성을 획기적으로 끌어올려 사회, 경제, 문화, 생활 전반의 혁명적 변화를 가져올 것

21세기의 원유

- 빅데이터도 원유처럼 각종 비즈니스, 공공기관 대국민 서비스, 그리고 경제 성장에 필요한 정보를 제공하여 산업 전반의 생산성을 향상시키고 새로운 범주의 산업을 만들어낼 것

렌즈

- 렌즈를 통해 현미경이 생물학 발전에 끼쳤던 영향만큼 빅데이터도 렌즈처럼 산업 발전에 큰 영향을 줄 것

플랫폼

- 플랫폼은 공동 활용의 목적으로 구축된 유무형의 구조물을 의미하며, 빅데이터는 플랫폼으로서 다양한 서드 파티 비즈니스에 활용될 것으로 기대된다.
ex. 페이스북, 카카오톡

II. 데이터의 가치와 미래

01 빅데이터의 이해

빅데이터가 만들어내는 변화

사전처리



사후처리

: 데이터를 사전처리하지 않고 가능한 많은 데이터를 모으고 다양한 방식으로 조합하여 숨은 인사이트를 발굴

표본조사



전수조사

: IoT, 클라우드 기술의 발전으로 데이터 처리 비용이 감소하게 되면서 데이터 활용방법이 표본조사에서 전수조사로 변화했다.

질적 데이터



양적 데이터

: 수집 데이터의 양이 증가할수록 분석의 정확도가 높아져 양질의 분석 결과 산출에 긍정적인 영향을 주었다.

인과관계



상관관계

: 상관관계를 통해 특정 현상의 발생 가능성이 포착되고 그에 상응하는 행동을 추천하는 등 상관관계를 통한 인사이트 도출이 점점 확산됨

II. 데이터의 가치와 미래

02 데이터의 가치와 미래

빅데이터의 가치

- 데이터 활용 방식의 다양성
- 끊임없이 새로운 가치 창출
- 분석 기술의 지속적인 발전

이러한 특징으로 빅데이터의 가치 산정이 어려움

빅데이터의 활용

→ 연관 규칙 학습, 군집분석, 유전 알고리즘, 기계학습, 회귀분석, 감정분석, 소셜 네트워크 분석(사회관계망 분석) 등

[기업] 혁신, 경쟁력 제고, 생산성 향상

소비자 행동을 분석하고 시장 변동을 예측하여
비즈니스 모델을 혁신하거나 신사업을 발굴

- 구글: 사용자 로그 데이터를 활용한 검색엔진 개발
- 월마트: 고객 구매 패턴을 분석해 상품 진열에 활용

[정부] 환경 탐색, 상황 분석, 미래 대응

기상, 인구이동 통계, 법제 데이터 등을 수집하여
사회 변화를 추정하고 필요한 정보를 추출

- 실시간 교통정보, 기후정보, 소방 서비스를 위해
실시간 모니터링을 실시하여 국가안전 확보에 활용

[개인] 목적에 따른 활용

빅데이터 서비스 비용이 지속적으로 하락하여
정치인, 대중 가수 등이 인지도 향상에 활용

- 정치인: 사회관계망 분석을 활용해 유세 지역 선거홍보
- 가수: 음악 청취 기록을 분석해 공연 곡 순서 선정

II. 데이터의 가치와 미래

02 데이터의 가치와 미래

위기로인과 통제 방안

사생활 침해

- 개인의 사생활 침해를 넘어 사회적 경제적 위협으로 변형될 수 있다.
- 익명화 기술이 발전하지만 아직 충분하지 않으며, 정보가 오용될 때 위협이 커진다. → 개인정보 제공자의 '동의'를 통해 해결하기보다 사용자의 '책임'으로 해결
- ex) 조지 오웰 <1984>의 빅 브라더, SNS 개인정보 유출

책임원칙 훼손

- 빅데이터 기반 분석과 예측기술이 발전하면서 정확도가 증가한 만큼, 분석 대상이 되는 사람이 예측 알고리즘의 희생양이 될 가능성이 높아졌다. → 특정인의 '성향'이 아닌 '행동 결과'를 보고 처벌한다
→ 범죄를 저지를 것이라 예상되더라도 아무런 조치를 취할 수 없음
- ex) 영화 <마이너리티 리포트>

데이터 오용

- 데이터 과신 혹은 잘못된 지표의 사용으로 얻은 인사이트를 비즈니스에 적용할 경우 직접 손실이 발생할 수 있다. → 데이터 활용 로직인 알고리즘을 통하여 피해자를 구제
빅데이터는 과거를 분석하는 것이므로, 이를 과신하거나 오용하면 창조적인 제품을 개발하기 어렵다. → Algorithmist로 사전 피해자 방지 및 구제 가능
- ex) 적군의 사망자 수로 전쟁의 승리를 예측하는 오류

II. 데이터의 가치와 미래

03 가치창조를 위한 데이터 사이언스와 전략 인사이트

빅데이터 회의론

부정적 학습효과 : 과거 고객관계관리(CRM)에서의 공포 마케팅 → 투자 대비 효과 미흡

부적절한 성공사례 : 빅데이터 필요 없는 분석사례, 기존 CRM 분석 성과를 빅데이터 분석 성과로 과대포장

➔ 단순히 빅데이터에 포커스를 두지 말고, 분석을 통해 가치를 만드는 것에 집중해야 함

빅데이터 분석 전략 인사이트

일차원적 분석 애플리케이션

- 금융: 신용점수 산정, 사기 탐지, 프로그램 트레이딩, 클레임 분석, 고객 수익성 분석
- 병원: 가격 책정, 고객 로열티, 수익 관리
- 에너지: 트레이딩, 공급, 수요 예측
- 정부: 사기 탐지, 사례 관리, 범죄 방지, 수익 최적화



전략도출 가치 기반 분석

- 전략적 통찰력의 창출에 포커스를 두었을 때
해당 사업에 중요한 기회를 발굴, 주요 경영진의 지원을 얻게 됨
- 분석의 활용 범위를 더 넓고 전략적으로 변화시키고,
전략적 인사이트를 주는 가치 기반의 분석 단계로 나아가야 함


II. 데이터의 가치와 미래

03 가치창조를 위한 데이터 사이언스와 전략 인사이트


데이터 사이언스

➔ 데이터 공학, 수학, 통계학, 컴퓨터공학, 시각화, 해커의 사고방식 등 해당 분야의 전문지식을 종합한 학문

- 구성요소



- 요구 역량



II. 데이터의 가치와 미래

03 가치창조를 위한 데이터 사이언스와 전략 인사이트

데이터 사이언스

과학과 인문의 교차로

→ 분석 기술보다 더 중요한 것은 소프트 스킬로,
전략적 통찰을 주는 분석은 단순 통계 및 데이터 처리능력보다 스토리텔링, 커뮤니케이션, 창의력, 열정, 직관력, 비판적 사고 등의 인문학적 요소가 필요함.

전략적 통찰력과 인문학의 부활

외부환경의 변화	내용	예시
컨버전스 → 디버전스	단순 세계화에서 복잡한 세계화로의 변화	규모의 경제, 세계화, 표준화, 이성화 → 복잡한 세계, 다양성, 관계, 연결성, 창조성
생산 → 서비스	비즈니스 중심이 제품생산에서 서비스로 이동	고장 나지 않는 제품의 생산 → 뛰어난 서비스로 응대
생산 → 시장창조	공급자 중심의 기술경쟁에서 무형자산의 경쟁으로 변화	생산에 관련된 기술 중심의 대규모 투자 → 현재 패러다임에 근거한 시장 창조 현지 사회와 문화에 관한 지식

II. 데이터의 가치와 미래


03 가치창조를 위한 데이터 사이언스와 전략 인사이트

빅데이터의 미래

빅데이터의 시대

- 빅데이터 분석은 선거 결과에 결정적인 영향을 미칠 수도 있고, 기업들은 비용 절감, 매출 증대, 신규 비즈니스 창출, 내부 의사결정 지원 등에 활용한다.

가치 패러다임의 변화



데이터 사이언스의 한계

- 분석 과정에서 가정 등 인간의 해석이 개입되는 단계를 반드시 거침
- 분석 결과가 의미하는 바는 사람에 따라 전혀 다른 해석과 결론을 내릴 수 있음
- 아무리 정량적인 분석이라도 모든 분석은 가정에 근거한다는 한계점이 있음

데이터 사이언스와 인문학

- 인문학을 이용하여 데이터 사이언스가 데이터에 묻혀 있는 잠재력을 풀어냄
- 새로운 기회를 찾고, 누구도 보지 못한 창조의 밑그림을 그릴 수 있는 힘을 발휘할 수 있음

제2과목

『데이터 분석 기획』

I. 데이터 분석 기획의 이해

01 분석 기획과 분석 방법론

분석 기획


- 실제 분석을 수행하기 앞서 분석을 수행할 과제를 정의하고, 의도한 결과를 도출할 수 있도록 적절한 관리 방안을 사전에 계획하는 일련의 작업

* 데이터 사이언티스트의 역량

: 수학/통계학적 지식, 정보기술(IT기술, 해킹 기술, 통신기술 등), 비즈니스에 대한 이해와 전문성

분석 대상 및 방법

- 분석은 **분석 대상(What)**과 **분석 방법(How)**에 따라서 4가지로 분류할 수 있음



I. 데이터 분석 기획의 이해

01 분석 기획과 분석 방법론

목표 시점별 분석 기획 방안

	목적	1차 목표	과제의 유형	접근 방식
당면한 분석주제의 해결 (과제 단위)	빠르게 해결	Speed & Test	Quick-Win	Problem Solving
지속적 분석 문화 내재화 (마스터 플랜 단위)	지속적으로 해결	Accuracy & Deploy	Long Term View	Problem Definition

분석 기획 시 고려사항

가용 데이터 고려

- 분석의 기본이 되는 데이터 확보 가능성 및 데이터 유형에 대한 선행 분석 필요

장애요소 고려

- 장애요소에 대한 사전 계획 수립

적절한 활용방안과 유스케이스 탐색

- "바퀴를 재발명하지 마라"라는 격언처럼 기존에 잘 구현된 유사시나리오의 활용
- 과거 유사한 사례가 있다면, 과거 실패를 반복하지 않고 성공을 위한 가이드로 참조

I. 데이터 분석 기획의 이해

01 분석 기획과 분석 방법론

분석 방법론 개요

* 기업의 합리적 의사결정을 가로막는 장애요소

: 고정 관념(Stereotype), 편향된 생각(Bias), 프레임링 효과(Framing Effect)

방법론의 적용 업무에 따른 모델

폭포수 모델(Waterfall Model)

: 순차적으로(Top-Bottom) 문제를 해결하는 모델

프로토타입 모델(Prototype Model)

: 프로토타입을 먼저 개발한 후 수정·보완을 거쳐 완성하는 모델


나선형 모델(Spiral Model)

: 위험요소를 사전에 제거하면서 프로토타입을 발전시키는 모델

계층적 프로세스 모델

: KDD, CRISP-DM 등 전통적 방법론의 뼈대가 되는 모델

빅데이터 분석 방법론 3계층 구조




I. 데이터 분석 기획의 이해

01 분석 기획과 분석 방법론

전통적 분석 방법론

Knowledge Discovery in Database (KDD)

: 데이터로부터 통계적 패턴이나 지식을 찾기 위해 체계적으로 정리한 데이터 마이닝 프로세스



I. 데이터 분석 기획의 이해

01 분석 기획과 분석 방법론

전통적 분석 방법론

Knowledge Discovery in Database (KDD)

: 데이터로부터 통계적 패턴이나 지식을 찾기 위해 체계적으로 정리한 데이터 마이닝 프로세스

1. 데이터셋 선택

비즈니스 도메인에 대한 이해와 목표 설정이 필수
분석에 필요한 타깃 데이터를 설정

2. 데이터 전처리

잡음, 이상치, 결측치를 제거 또는 재가공 처리
데이터가 추가로 요구될 경우 데이터셋 선택 재실행

3. 데이터 변환

변수를 선택하고 데이터 차원을 축소
학습용(training) 및 검증용(validation) 데이터 분리

4. 데이터 마이닝

분석 목적에 맞는 데이터 마이닝 기법 및 알고리즘 선택
분석 필요에 따라 전처리와 변환 프로세스도 추가

5. 해석과 평가

분석 목적과의 일치성을 확인하고 평가
발견한 지식에 대한 업무 활용 방안 마련

I. 데이터 분석 기획의 이해

01 분석 기획과 분석 방법론

전통적 분석 방법론

Cross Industry Standard Process for Data Mining (CRISP-DM)

: 유럽연합에서 발표한 계층적 프로세스 모델로, KDD 모델보다 더 세분화됨

※ KDD에서 추가된 단계

1. 업무 이해

업무 목적 파악, 프로젝트 계획 수립,
데이터 마이닝 목표 설정

2. 데이터 이해

데이터 수집, 데이터 기술 분석,
데이터 탐색, 데이터 품질 확인

3. 데이터 준비

분석용 데이터셋 선택, 데이터 정제,
데이터셋 편성, 데이터 통합, 데이터 포매팅

4. 모델링

모델링 기법 선택, 테스트 계획 설계,
모델링 수행 및 모델 평가

5. 평가

분석 결과 평가, 모델링 과정 평가, 모델 적용성 평가


6. 전개

전체 계획 수립, 모니터링과 유지보수 계획 수립,
프로젝트 종료 보고서 작성, 프로젝트 리뷰

I. 데이터 분석 기획의 이해

01 분석 기획과 분석 방법론

빅데이터 분석 방법론 5단계



I. 데이터 분석 기획의 이해

02 분석 과제 발굴

분석 과제 발굴 방법론


- 기업에서 분석을 통해 기업경영 전략에 활용하기 위하여 분석 과제를 발굴하는 것
➔ 분석 대상을 알고 있다면 **하향식 접근법**, 모른다면 **상향식 접근법**을 사용

1) 하향식 접근법 (Top-Down)

: 문제에 대한 해법을 찾기 위하여 각 과정을 체계적으로 단계화 하여 수행한다.

2) 상향식 접근법 (Bottom-Up)

: 문제의 정의 자체가 어려운 경우 데이터를 기반으로 과제를 지속적으로 발굴한다.



I. 데이터 분석 기획의 이해

02 분석 과제 발굴

하향식 접근법 (Top-Down)

1단계
문제 탐색

비즈니스 모델 탐색: **비즈니스 모델 캔버스**를 5가지 단순화
: ①업무 ②제품 ③고객 단위 문제 발굴 + ④규제 및 ⑤자원 인프라 확인
외부 참조 모델 기반 탐색 및 분석 유스케이스 정의

• 비즈니스 모델 캔버스

2단계
문제 정의


비즈니스 문제를 데이터의 문제로 정의
ex. 고객 불만이 늘어나는 문제
→ 고객 불만율에 대한 예측모델 수립 과제 발굴

3단계
해결방안 탐색

분석 가능한 시스템인지, 가용 인력이 있는지 판단
- 기존 시스템으로 문제 해결이 가능한가
- 해결을 위해 필요한 역량은 어떤 것이 있는가

4단계
타당성 검토

도출된 해결방안의 경제적, 기술적 타당성 검토
- 경제 타당성: 실질 비용 절감, 추가 수익
- 기술 타당성: 분석 가능 여부



I. 데이터 분석 기획의 이해

02 분석 과제 발굴

상향식 접근법 (Bottom-Up)

정의

- 기업이 보유하고 있는 다양한 원천 데이터로부터 통찰력과 지식을 얻는 방법
- 다양한 원천 데이터를 분석하여 가치 있는 모든 문제를 도출하는 일련의 과정

비지도 학습 (Unsupervised Learning)

- 정답을 제외한 데이터를 학습시켜 데이터 간의 규칙을 찾아내는 머신 러닝 기법

* 지도 학습 (Supervised Learning)

: 문제와 정답을 포함한 데이터를 학습시켜
예측, 분류 등을 수행하는 머신 러닝 기법

* 강화 학습 (Reinforcement Learning)

: 보상을 통해 상은 최대화, 벌은 최소화하며
행위를 강화하는 머신 러닝 기법




특징

- 하향식 접근법은 최근의 복잡하고 다양한 문제들을 해결하기 어렵기 때문에 디자인적 사고 (Design Thinking) 접근법을 통하여 'Why → What' 관점을 가지고 존재하는 데이터 그 자체를 객관적으로 관찰하여 문제를 해결하는 접근법을 사용한다.

프로토타입 접근법 (시행착오 해결법)

- 문제에 대한 인식 수준이 낮은 경우
- 필요 데이터의 존재 여부가 불확실한 경우
- 데이터의 사용 목적이 변화하는 경우



I. 데이터 분석 기획의 이해

03 분석 프로젝트 관리 방안

분석 프로젝트 관리 영역

- 분석프로젝트는 범위, 일정, 품질, 리스크, 의사소통 등 영역별 관리가 수행되어야 할 뿐 아니라
데이터 기반 분석 기법을 적용한다는 특성 때문에 아래 5가지 주요 속성을 고려하여 추가적인 관리가 필요

1) 데이터 크기 : 데이터 크기에 따른 분석환경 필요 (CPU, RAM)

2) 데이터 복잡도 : 텍스트, 오디오, 비디오 등 비정형 데이터 고려

3) 분석 속도 : 분석의 요구에 따라 속도도 중요

4) 분석 복잡도 : 정확도와 복잡도는 Trade off
→ 복잡할수록 정확도가 올라가지만, 해석이 어려워짐

5) 정확도(Accuracy) & 정밀도(Precision)
- 정확도 : 분석모델의 예측 값과 실제 값의 차이 (오차 개념)
- 정밀도 : 반복적인 예측 값의 편차 수준 (분산 개념)



정확도 높음
정밀도 높음



정확도 낮음
정밀도 높음



정확도 높음
정밀도 낮음



정확도 낮음
정밀도 낮음

I. 데이터 분석 기획의 이해

03 분석 프로젝트 관리 방안

분석 프로젝트 특성

- 분석가의 목표

: 개별적인 분석 수행 뿐만 아니라 전반적인 프로젝트 관리 또한 중요

- 분석가의 입장

: 데이터 영역과 비즈니스 영역의 현황을 이해하고, 프로젝트 목표인 분석의 정확도 달성과 결과에 대한 가치 이해를 전달하는 조정자로서 분석가의 역할이 중요

분석 프로젝트는 도출된 결과의 재해석을 통한 지속적인 반복 및 정교화가 수행되는 경우가 대부분이므로
프로토타이핑 방식의 애자일(Agile) 프로젝트 관리방식에 대한 고려도 필요

II. 분석마스터 플랜

01 마스터 플랜 수립

마스터 플랜 수립 프레임워크


분석 프로젝트를 위한 전체 설계도. 앞선 분석 방법을 모두 아우르는 개념

- 분석 마스터 플랜 수립의 시작은 발굴한 **분석 과제의 우선순위**를 정하는 것
- 분석 과제의 우선순위와 함께 적용 범위 및 방식을 설정

• IT 프로젝트 우선순위 평가 예시

: 전략적 중요도 및 실행 용이성을 기준으로 분석 과제의 우선순위 설정

ROI (Return on Investment) 요소



전략적 중요도	전략적 필요성	- 전략적 목표 및 본원적 업무에 직접 연관된 정도 - 이슈 미해결 시 발생하는 위험 및 손실에 대한 정도
	시급성	- 요구사항 대응, 업무 향상을 위해 시급한 정도 - 향후 경쟁우위 확보를 위한 중요도
실행 용이성	투자 용이성	- 기간 및 인력 투입 용이성 정도 - 비용 및 투자예산 확보 가능성 정도
	기술 용이성	- 적용 기술의 안정성 검증 정도 - 응용시스템, H/W 유지보수 용이성 정도 - 개발 Skill 성숙도 및 신기술 적용 용이성 정도

II. 분석마스터플랜

02 분석 거버넌스 체계 수립

분석 거버넌스 체계

거버넌스(Governance): '통치'라는 뜻으로 의사결정을 위한 데이터의 분석과 활용에 적용되는 체계적인 관리를 뜻함

→ 이는 단순히 데이터를 수집, 축적하는 것보다는 분석을 수행하고 활용할 것 인지 결정하고 기업의 문화로 정착시키며 데이터 관리 체계를 수립하는 것

데이터 품질 관리

Data Quality Management

- 데이터 프로파일링 및 데이터 정제와 같은 작업을 포함하여
데이터 사용 방법에 따라 실행

데이터 주기 관리

Data Lifecycle Management

- 데이터 생성 및 초기 저장에서부터
데이터가 폐기될 때까지 시스템의 데이터 흐름을 관리하는 정책 수립 필요

메타데이터 관리

Metadata Management

- 데이터 검색 중 데이터를 찾고,
분석 도구가 빅데이터를 정확하게 해석하고 사용할 수 있도록 실행

데이터 보안 및 프라이버시

Data Security and Privacy


- 데이터 요구사항 및 정책은 사용자의 역할을 기반으로
필요한 데이터 보호 수준을 정의

II. 분석마스터 플랜

02 분석 거버넌스 체계 수립


분석 거버넌스 체계 구성요소

-아래 5가지 요소로 구성되어 있음



데이터 분석 수준 진단

분석 준비도 (Readiness)



분석 성숙도 (Maturity)



- 조직의 성숙도 평가도구

: Capability Maturity Model Integration (CMMI)

- 분석 수준 진단 결과

: 정착형, 확산형, 준비형, 도입형

II. 분석마스터플랜

02 분석 거버넌스 체계 수립

데이터 거버넌스 체계 수립

- 전사 차원의 모든 데이터에 대하여 정책 및 지침, 표준화, 운영조직 및 책임 등의 표준화 된 관리체계를 수립하고 운영을 위한 프레임워크(Framework) 및 저장소(Repository)를 구축하는 것을 말함
- 마스터 데이터(Master Data), 메타 데이터(Meta Data), 데이터 사전(Data Dictionary)은 데이터 거버넌스의 중요한 관리 대상

구성요소

- 원칙(Principle), 조직(Organization), 프로세스(Process)

데이터 거버넌스 체계

- 데이터 표준화, 데이터 관리 체계, 데이터 저장소 관리(Repository), 표준화 활동 등




II. 분석마스터플랜

02 분석 거버넌스 체계 수립

데이터 분석을 위한 조직 구조


집중 구조

- 데이터 전문조직이 별도로 존재함




기능 구조

- 각 부서에 데이터 분석가가 소속됨



분산 구조

- 데이터 전문조직이 각 부서에 분산 편성됨



※ DSCoE : Data Science Center of Excellence

II. 분석마스터 플랜

02 분석 거버넌스 체계 수립

분석과제 관리 프로세스

과제발굴

①
분석Idea
발굴②
분석과제
후보제안③
분석과제
확정

과제후보 Pool

전사분석 조직

분석과제

과제 제안자
↓
과제 추진 팀④
팀구성

과제수행

⑦
결과 공유
/개선⑥
분석과제
진행관리⑤
분석과제
실행

과제결과 Pool

전사분석 조직

과제수행 지원

제3과목

『데이터 분석』

01 R 기초

데이터 분석 기법의 이해

1. 데이터 처리 과정

- 데이터 분석을 위해서는 데이터 웨어하우스(DW)나 데이터 마트(DM)을 통해 분석데이터를 구성
- 신규 데이터나 DW에 없는 데이터는 기존 운영시스템(Legacy)에서 직접 가져오거나 운영 데이터 저장소(ODS)에서 정제된 데이터를 가져와서 DW의 데이터와 결합하여 활용

2. 시각화 기법

- 가장 낮은 수준의 분석이지만 잘 사용하면 복잡한 분석보다 더 효율적이며, 대용량 데이터를 다루거나 탐색적 분석을 수행할 때 시각화는 필수

3. 공간분석

- 공간적 차원과 관련된 속성들을 시각화 하는 분석으로, 지도 위에 관련된 속성들을 생성하고 크기, 모양, 선 굵기 등을 구분하여 인사이트를 얻음

4. 탐색적 자료분석 (EDA)

- 다양한 차원과 값을 조합하여 특이점이나 의미 있는 사실을 도출하고 분석의 최종 목적을 달성해가는 과정
 - ➔ 저항성의 강조, 잔차 계산, 자료 변수의 재표현, 그래프를 통한 현시성

01 R 기초

데이터 분석 기법의 이해

5. 통계 분석


- 어떤 현상을 종합적으로 한눈에 알아보기 쉽게 일정한 체계에 따라 숫자와 표, 그림의 형태로 나타내는 것

6. 데이터 마이닝

- 대용량의 자료로부터 정보를 요약하고 미래를 예측하는 것을 목표로

자료에 존재하는 관계, 패턴, 규칙을 탐색하고 이를 모형화 하여 이전에 알지 못한 지식을 추출하는 분석 방법

- 지도학습(기계학습): 인공신경망, 의사결정나무, 클러스터링, SVM 등
- 비지도학습(패턴인식): 연관규칙, 장바구니 분석 등



01 R 기초

R 프로그래밍

R의 탄생

- R은 오픈소스 프로그램으로 통계 데이터 마이닝과 그래프를 위한 언어이다.
- 다양한 최신 통계분석과 마이닝 기능을 제공하며, 5000개에 이르는 패키지와 수시로 업데이트 된다.

통계 분석 도구의 비교

구분	SAS	R	Python
프로그램 비용	유료, 고가	오픈소스	오픈소스
다양한 모듈 지원	별도 구매 필요		
최근 알고리즘 및 기술 반영	느림	빠름	매우 빠름
학습자료 입수의 편의성	유료 도서	공개논문 많음	공개논문 많음
질의를 위한 공개 커뮤니티	없음	활발	매우 활발

01 R 기초


R 프로그래밍

R의 특징

- 오픈소스 프로그램
- 뛰어난 그래픽 및 성능
- 시스템 데이터 저장 방식
- 모든 운영체제에서 사용 가능(윈도우, 맥, 리눅스)
- 표준 플랫폼(S 언어 기반)
- 객체 지향언어이면서 함수형 언어

실습환경

- 방법1
: Local Machine(노트북) R Studio 설치
- 방법2
: replit 서비스 이용하기
→ <https://replit.com/>
(PC, 스마트폰 등에서 사용가능)



01 R 기초

R 프로그래밍

편리한 기능

- R의 작업환경 설정
: 속성 -> 바로가기 -> 시작위치에서 현재 작업위치 입력 -> 저장
- 프로그램에서 작업환경 설정: `setwd('작업위치')`
- 도움말: `help('함수명')`, `?함수`, `RSiteSearch('함수명')`
- 히스토리: `history()`, `savehistory(file='파일명')`, `loadhistory(file='파일명')`
- 콘솔 청소: `Ctrl + L`

스크립트 사용하기

- 한 줄 실행: `Ctrl + R`
- 여러 줄 실행: 드래그 후 `Ctrl + R`
- 주석 처리: `#`

패키지

- : R함수, 데이터 및 컴파일 코드의 모임
→ `install.packages('패키지명')`으로 설치 가능

배치 실행

- : 매일 실행해야 하는 프로그램을 시스템 프로세스에서 자동으로 구동하는 작업
→ `batch.R` 실행 파일이 있는 위치에서 `R CMD BATCH batch.R` 입력

변수 다루기

- R에서는 변수 선언 후 값을 할당하면 자료 형태를 스스로 인식하고 선언함
- 화면에 출력하고자 할 때, `print()`를 사용하지 않고 변수 이름만 입력해도 출력 가능
- 변수에 값을 할당할 때는 대입연산자(`<-`, `=`, `->`) 사용

I.R 기초와 데이터 마트

01 R 기초

R 프로그래밍

기초 통계량 계산

- 평균값: mean()
- 중앙값: median()
- 표준편차: sd()
- 분산: var()
- 공분산: cov()
- 상관관계수: cor()

함수의 생성 및 활용

- 사용자가 직접 원하는 함수를 생성하여 활용 가능 → 함수 이름, 매개변수, 표현식 등
- 함수 선언: function(매개변수1, 매개변수2 ..) → 2줄 이상인 경우 {}로 범위 설정
- 표현식: 변수 할당, 조건문(if문), 반복문(for, while, repeat), 전달 값(return) 등

연산자 우선순위

연산자	뜻	예시	연산자	뜻	예시
① []	인덱스	a[1]	⑧ +, -	덧셈, 뺄셈	3-5
② \$	요소 추출	a\$coef	⑨ ==, !=, <, >, <=, >=	비교	3==5
③ ^	지수	5^2	⑩ !	논리 not	!TRUE
④ -, +	단항 마이너스, 플러스	-3, +5	⑪ &	논리 and	TRUE & FALSE
⑤ :	수열 생성	1:10	⑫	논리 or	TRUE FALSE
⑥ %any%	특수 연산자	%/%	⑬ ~	식	
⑦ *, /	곱셈, 나눗셈	3+5			

01 R 기초


R 프로그래밍

데이터 입력과 출력

- 텍스트 뿐만 아니라 데이터베이스와 다양한 프로그램에서 작성된 데이터를 읽고 적절한 데이터 분석을 수행할 수 있음
- 부동소수점은 기본 7자리 수로 설정되어 있으며, `option()` 함수, `digit = '숫자'`를 지정해서 자릿수를 변경할 수 있음
- 문자열을 파일로 저장하는 경우: `cat('저장할 문자열', file = '파일명')`
※ R에서는 역슬래시를 인식하지 못하므로 슬래시 또는 이중 역슬래시로 파일 경로 지정

외부 파일 입력과 출력

- csv 파일 읽기: `read.csv('파일명.csv', header=T)`
- csv 파일 출력: `write.csv('데이터프레임', file='파일명.csv')`
- 파일 다운로드: `read.csv('URL/파일명.csv')`



02 데이터 마트

데이터 마트

- 데이터 웨어하우스와 사용자 사이의 중간층에 위치한 것으로,
하나의 주제 또는 하나의 부서 중심의 데이터 웨어하우스라고 할 수 있음

요약 변수와 파생변수

요약 변수

- 수집된 정보를 분석에 맞게 종합한 변수로, 데이터 마트에서 가장 기본 변수
- 많은 모델이 공통으로 사용할 수 있어 재활용성 높음

ex. 기간별 구매금액, 횟수 / 상품별 구매 금액, 횟수, 순서 / 초기 행동변수 / 결측값, 이상치 / 연속형 변수의 구간화

파생변수

- 특정 조건을 만족하거나 특정 함수에 의해 값을 만들어 의미를 부여한 변수
- 매우 주관적일 수 있으므로 논리적 타당성을 갖출 필요가 있음

ex. 근무시간 구매지수 / 주 구매 매장 / 주 활동 지역 / 구매 상품의 다양성 / 라이프 스타일 변수 / 최대가치 변수

02 데이터 마트

데이터 변경 및 요약

reshape 패키지


- 2개의 핵심적인 함수로 구성

① `melt()`: 쉬운 casting을 위해 데이터를 적당한 형태로 만들어주는 함수


② `cast()`: 데이터를 원하는 형태로 계산 또는 변형해주는 함수

- 변수를 조합해 변수명을 만들고 변수들을 시간, 상품 등의 차원에 결합하여
다양한 요약변수와 파생변수를 쉽게 생성하여 데이터 마트를 구성하게 해주는 패키지

With Aggregation



Without Aggregation



02 데이터 마트

데이터 변경 및 요약

sqldf 패키지

- R에서 sql 명령어를 사용 가능하게 해주는 패키지로 SAS의 proc sql과 같은 기능

```
> head([df]) -> sqldf('select * from [df] limit 6*')  
> subset([df], col %in% c('BF', 'HF')) -> sqldf('select * from [df] where [col] in ('BF', 'HF')')  
> merge([df1],[df2]) -> sqldf('select * from [df1],[df2]')
```

plyr 패키지

- apply 함수를 기반으로 데이터와 출력변수를 동시에 배열로 치환하여 처리
- 데이터를 분리하고 처리한 후 재결합하는 등 필수적인 데이터 처리 기능 제공
(split - apply - combine 방식)

data.table 패키지

- R에서 가장 많이 사용하는 패키지 중 하나로 대용량 데이터의 탐색, 연산, 병합에 유용
- 기존 data.frame 방식보다 월등히 빠른 속도
- 특정 column을 key 값으로 색인을 지정한 후 데이터를 처리
- 빠른 grouping과 ordering, 짧은 문장 지원 측면에서 데이터프레임보다 유용

03 데이터 탐색

데이터 기초 분석

변수의 구간화

- 신용평가모형, 고객 세분화 등의 시스템으로 모형을 적용하기 위해서 각 변수들을 구간화 하여 점수를 적용하는 방식이 활용
- 변수의 구간화를 위한 rule 이 존재함 (*10진수 단위 혹은 구간을 5개로 나눔)

Binning

연속형 변수를 범주형 변수로 변환하기 위해 50개 이하의 구간에 동일한 수의 데이터를 할당하여 의미를 파악하면서 구간을 축소하는 방법

의사결정 나무

의사결정나무 모형을 통해 연속형 변수를 범주형 변수로 변환하는 방법

03 데이터 탐색

데이터 기초 분석

결측값 처리

- 1) 변수에 데이터가 비어 있는 경우: NA, 99999, Unknown 등으로 표현
- 2) 단순 대치법(Single Imputation)
 - Completes Analysis : 결측값의 레코드를 삭제
 - 평균 대치법 : 관측 및 실험을 통해 얻어진 데이터의 평균으로 대치
 - 비조건부 평균 대치법 : 관측 데이터의 평균으로 대치
 - 조건부 평균 대치법 : 회귀분석을 통해 데이터를 대치
 - **단순 확률 대치법** : 평균대치법에서 추정량 표준 오차의 과소추정문제를 보완
→ Hot Deck 방법, Nearest Neighbor 방법 등
- 3) 다중 대치법(Multiple Imputation)
 - 단순 대치법을 m번 실시하여, m개의 가상적 자료를 만들어 대치하는 방법



<code>complete.cases()</code>	데이터내 레코드의 결측값 여부를 TRUE, FALSE로 반환
<code>is.na()</code>	결측값이 NA인지의 여부를 TRUE, FALSE로 반환
DMwR 패키지: <code>centralimputation()</code>	NA 값을 가운데 값(Central Value)으로 대치 (숫자 - 중위수, Factor - 최빈값)
DMwR 패키지: <code>knnImputation()</code>	NA 값을 k최근 이웃 분류 알고리즘을 사용하여 대치 (k개 주변 이웃까지의 거리를 고려하여 가장 평균한 값을 사용)
Amelia 패키지: <code>amelia()</code>	time-series-cross-sectional data set에서 활용

03 데이터 탐색

데이터 기초 분석

이상치 처리

- 의도하지 않은 현상으로 입력된 값 or 의도된 극단 값 -> 활용할 수 있음
- 잘못 입력된 값 or 의도하지 않은 현상으로 입력된 값이지만 분석 목적에 부합되지 않는 값 -> Bad Data이므로 제거

- ① ESD (Extreme Student Deviation) : 평균으로부터 3표준편차 떨어진 값
- ② 사분위수 : $Q1 - 1.5 \times IQR < data < Q3 + 1.5 \times IQR$ 의 범위를 넘어서는 값 ($IQR = Q3 - Q1$)

절단
(Trimming)

: 이상치가 포함된 레코드를 삭제

조정
(Winsorizing)

: 이상치를 상한, 하한 값으로 조정

II. 통계분석

01 통계의 이해

데이터 기초 분석

구분	내용
통계	특정집단을 대상으로 수행한 조사나 실험을 통해 나온 결과에 대한 요약된 형태의 표현
통계자료의 획득 방법	총 조사(Census)와 표본조사(Sampling)
표본 추출 방법	단순 랜덤추출(Simple Random Sampling), 계통추출법(Systematic Sampling), 집락추출법(Cluster Sampling), 층화추출법(Stratified Random Sampling)
자료의 측정 방법	명목척도, 순서척도, 구간척도, 비율척도

통계 분석

구분	내용
기술통계(Descriptive Statistics)	평균, 표준편차, 중위수, 최빈값, 그래프
통계적 추론(Statistical Inference)	모수추정, 가설검정, 예측

II. 통계분석

01 통계의 이해

표본 추출 방법

구분	내용
단순 랜덤 추출	N개의 모집단에서 n개의 샘플 무작위 추출
계통 추출법	모집단에서 숫자 부여 후 일정한 간격으로 추출
집락 추출법	군집을 구분하고 군집별로 단순랜덤 추출법을 수행한 후, 모든 자료를 활용하거나 샘플링하는 방법 예: 지역표본추출
층화추출법	이질적인 원소들로 구성된 모집단에서 각 계층을 고루 대표할 수 있도록 표본을 추출하는 방법으로, 유사한 원소끼리 몇 개의 층(Stratum)으로 나누어 각 층에서 랜덤 추출하는 방법

II. 통계분석

01 통계의 이해

확률과 개념

확률

- 특정 사건 A가 발생할 수 있는 비율로 0과 1사이 값이며, 모든 가능한 사건의 합은 항상 1

예시)

- 주사위를 던졌을 때 나오는 숫자를 확률 변수 X라 한다면

X	1	2	3	4	5	6
P(X)	1/6	1/6	1/6	1/6	1/6	1/6

조건부 확률

- 특정 사건 A가 발생했다는 것이 사실이라는 전제하에 다른 사건 B가 발생할 확률

$$P(A) = \frac{\text{특정 사건 } A \text{의 개수}}{\text{전체 사건의 개수}}$$

$$P(B|A) = \frac{P(B \cap A)}{P(A)}$$

II. 통계분석

01 통계의 이해

확률과 개념

독립사건

- 동전 2번을 던질 때, 첫 번째 시도와 두 번째 시도가 서로 영향을 주지 않는 것처럼 두 사건이 영향을 주지 않을 때 독립이라고 함
- 두 사건이 독립이라면 다음 식이 성립한다.

$$P(B|A) = P(B)$$

$$P(A \cap B) = P(A) \times P(B)$$

독립사건 예시

- 주사위를 1개 굴려서 2의 배수가 나올 확률을 $P(A)$, 3의 배수가 나올 확률을 $P(B)$ 라 하면, 두 사건은 독립


II. 통계분석

01 통계의 이해


확률분포

확률분포의 개념

- 확률변수에 의해 정의된 실수(주사위의 눈금 값)를 확률에 대응시키는 함수를 확률함수라고 함
- 이를 그래프로 시각화 한 것을 확률분포라고 하며, 크게 이산확률분포와 연속확률분포로 구분함



이산확률분포



연속확률분포

II. 통계분석

01 통계의 이해

기대값

기대값

- 특정 사건이 시행되었을 때 X가 취할 수 있는 평균값
- 주사위를 하나 굴렸을 때, 나올 수 있는 숫자의 기대값은?

$$E(X) = \frac{(1 + 2 + 3 + 4 + 5 + 6)}{6} = 3.5$$


X	1	2	3	4	5	6
P(X)	1/6	1/6	1/6	1/6	1/6	1/6

II. 통계분석


01 통계의 이해

첨도와 왜도

구분	내용
첨도 (kurtosis)	확률분포의 뾰족한 정도를 나타내는 척도



구분	내용
왜도 (skewness)	확률분포의 비대칭 정도를 나타내는 척도



II. 통계분석

01 통계의 이해

이산확률 분포의 종류

구분	예시	내용
베르누이 분포	동전 던지기, 시험의 합격/불합격	결과가 2개만 나오는 경우
이항분포	5번 타석에서 3번 안타 칠 확률	N 번의 베르누이 시행에서 k 번 성공할 확률 분포
기하분포	5번 타석에서 3번째 타석에서 안타 칠 확률	성공확률 p 인 베르누이 분포에서 처음으로 성공할 때까지 k 번 실패할 확률
다항분포	-	N 번의 시행에서 각 시행이 3개이상의 결과를 가질 수 있는 확률 분포
포아송분포	책에 오타가 page당 10개씩 나올 때 한 페이지 오타가 3개 나올 확률	단위 시간 또는 단위 공간 내 발생할 수 있는 사건의 발생 횟수에 따른 확률 분포

II. 통계분석

01 통계의 이해

연속확률 분포의 종류

구분	예시	내용
균일분포	다트의 확률 분포	모든 확률변수 X 가 균일한 확률을 가지는 확률분포
정규분포	Z-점수 표준화, 최소-최대 정규화	평균이 μ 이고, 표준편차가 σ 인 x 의 확률밀도함수 표준정규분포: 평균이 0이고 표준편차가 1인 정규분포
지수분포	전자레인지의 수명시간, 정류소에서 버스가 올 때까지의 시간	어떤 사건이 발생할 때까지 경과 시간에 대한 연속확률분포
t-분포	검정통계량으로 활용	표준정규분포와 같이 평균이 0을 중심으로 좌우가 동일한 분포를 따름 표본이 30개 이상이면 표준정규분포와 거의 같은 분포가 됨
χ^2 분포	동질성 검정 통계량에 활용	모평균과 모분산이 알려지지 않은 모집단의 모분산에 대한 가설 검정에 사용되는 분포
F분포	분산의 동일성 검정에 사용되는 검정 통계량	두 집단 간 분산의 동질성 검정에 사용되는 검정 통계량의 분포

II. 통계분석

01 통계의 이해

추정

- 표본으로부터 미지의 모수를 추측하는 것


구분	내용
점추정 (Point Estimation)	모수가 특정한 값일 것이라고 추정하는 것이며 평균, 표준편차, 중앙값 등을 추정 점추정 조건: 불편성, 효율성, 일치성, 충족성
구간추정 (Interval Estimation)	점추정을 보완하기 위해 모수가 특정 구간에 있을 것이라고 추정하는 것. 모분산을 알거나 대표본의 경우 표준정규분포 활용, 모분산을 모르거나 소표본의 경우 t-분포 활용

II. 통계분석

01 통계의 이해

가설검정

- 모집단에 대한 가설을 설정한 뒤, 그 가설 채택여부를 결정하는 방법
- 표본 관찰 또는 실험을 통해 귀무가설과 대립가설 중에서 하나를 선택하는 과정
- 귀무가설이 옳다는 전제하에 검정통계량 값을 구한 후에 이 값이 나타날 가능성의 크기에 의해 귀무가설의 채택여부를 결정



용어	내용
귀무가설(H_0)	비교하는 값과 차이가 없다, 동일하다를 기본개념으로 하는 가설
대립가설(H_1)	뚜렷한 증거가 있을 때 주장하는 가설
검정통계량	관찰된 표본으로부터 구하는 통계량, 검정 시 가설의 진위를 판단하는 기준
유의수준	귀무가설을 기각하게 되는 확률의 크기로 '귀무가설이 옳은데도 이를 기각하는 확률의 크기'
기각역	귀무가설이 옳다는 전제하에서 구한 검정통계량의 분포에서 확률이 유의수준 α 인 부분
유의확률 ($p - value$)	귀무가설이 맞다고 가정할 때 얻을 수 있는 결과보다 실젯값이 더 극단에 위치할 확률

II. 통계분석

01 통계의 이해

1종 오류와 2종 오류

정확한 사실 / 가설검정결과	H_0 가 사실 판정	H_0 가 사실 아님 판정
H_0 가 사실	옳은 결정	제1종 오류(α)
H_0 가 사실 아님	제2종 오류(β)	옳은 결정

- 제1종 오류: 귀무가설 H_0 가 옳은데도 귀무가설을 기각하게되는 오류
- 제2종 오류: 귀무가설 H_0 가 옳지 않은데도 귀무가설을 채택하게 되는 오류
- 두 가지 오류는 서로 상충관계가 있어서 일반적으로 가설검정에서는 제1종 오류, α 의 크기를 0.1, 0.05, 0.01 등으로 고정 시킨 뒤 제2종 오류 β 가 최소가 되도록 기각역을 설정

II. 통계분석

01 통계의 이해

모수 검정

- 검정하고자 하는 모집단의 분포에 대한 가정을 하고, 그 가정하에서 검정통계량과 검정통계량의 분포를 유도해 검정을 실시하는 방법
- 관측된 자료를 이용해 구한 표본평균, 표본분산 등을 이용해 검정 실시

II. 통계분석

01 통계의 이해

모수 검정 방법

통계적 분석 방법	분석 목적	변수의 척도		예시
T-검정	단일 집단의 검정 및 집단 간 비교	독립변수	범주형 (2개 집단 이하)	성별(남, 여)
		종속변수	연속형	투표율
분산분석	두 집단 이상의 차이 분석 (일반적으로 3개 집단)	독립변수	범주형 (2개 집단 이상)	혈액형
		종속변수	연속형	소득
카이제곱 검정	관련성 분석	독립변수	범주형	성별
		종속변수	범주형	학점
상관관계 분석	두 변수의 상관성 분석	독립변수	연속형	키
		종속변수	연속형	몸무게
회귀분석	독립변수가 종속변수에 미치는 영향 정도 분석	독립변수	범주형 및 연속형	키, 학력
		종속변수	연속형	소득

II. 통계분석

01 통계의 이해

비모수 검정

- 모집단의 분포에 대한 아무 제약을 가하지 않고 검정을 실시
- 관측된 자료가 특정 분포를 따른다고 가정할 수 없는 경우에 이용
- 관측된 자료의 수가 많지 않거나(30개 미만) 자료가 개체 간의 서열관계를 나타내는 경우에 이용
- 검정방법: 순위나 두 관측값 차이의 부호를 이용해 검정

II. 통계분석

01 통계의 이해

비모수 검정의 예: 단일표본 비모수 검정방법

- 단일표본 비모수 검정은 1개의 모집단에서 중심위치를 나타내는 중앙값이나 중앙값을 기준으로 크면 (+), 작으면(-1) 기호로 변환하여 척도로 사용하는 방법

검정방법	설명
카이제곱검정 (Chi-Square Test)	명목형 변수들 간의 관찰도수와 기대도수를 산출하여 적합도(단일표본), 독립성, 동질성 검정
K-S Test (Kolmogorov-Smirnov Test)	단일표본의 정규성 검정을 위한 적합도 검정(등간/비율척도). 독립된 두 개의 집단 간의 차이가 있는지 알기 위한 검정으로도 사용(서열척도)
Run Test	연속적인 관찰값이 무작위적(Random)으로 나타난 것인지 아니면 앞에서 나타난 관찰값이 나타나는 관찰값에 어떤 영향을 미치는지를 검정하는 방법 - 런(run): 동일한 관측값이 연속적으로 이어진 값 - 만약 이진형(0, 1) 자료가 아니면 이진형으로 변환 필요

II. 통계분석

01 통계의 이해

비모수 검정의 예: 종속표본 비모수 검정방법

- 2개 이상의 모집단에서 대응(Paired)되는 변수 간의 동질성을 검정하는 방법

검정방법	설명
부호 검정 (Sign Test)	단일표본에 대하여 중앙값을 검정하거나 대응(Paired) 표본(전/후의 관측값)의 중앙값의 차이가 있는지를 검정하는 방법 (서열척도)
윌콕슨부호순위검정 (Wilcoxon Signed Rank Test)	부호검정(Sign Test)은 부호만을 이용해 검정통계량을 산출했으나, 윌콕슨부호순위검정은 부호에 순위를 결합하여 부호검정보다 큰 검정력을 이용하는 검정방법
맥니마르 검정 (McNemar Test)	동일한 집단의 대응 범주형 데이터(Paired Nominal Data)의 전후 비율을 비교할 때 사용하는 검정방법 대응되는 명목형 변수에서 열과 행의 주변확률(Marginal Probability)이 같은지를 검정(명목척도)

II. 통계분석

01 통계의 이해

비모수 검정의 예: 독립표본 비모수 검정방법

- 2개 이상의 연속적이고 동일한 형태의 분포를 가지는 독립표본의 비모수 검정

검정방법	설명
윌콕슨 순위 합 검정 (Wilcoxon Rank Sum Test)	독립된 2개 집단의 분포가 동일한지 검정(중심위치 비교) 두 독립표본이 동일한 모집단에서 추출되었는지 또는 동일한 평균을 가지고 있는 두 모집단에서 추출되었는지를 검정(서열척도)
맨휘트니 U검정 (Man Whitney U Test)	독립된 2개의 집단의 분포가 동일한지 검정(중심위치 비교). 모수검정방법에서 독립표본 t검정과 같음
K-S Test (Kolmogorov-Smirnov Test)	독립된 두 개의 집단간의 차이가 있는지 알기 위한 비모수 검정 (1개 표본의 정규성검정으로도 사용)
크루스칼 왈리스 검정 (Kruskal-Wallis Test)	모든 그룹의 데이터가 유사한 모양의 분포를 가지고 있는 경우 3개 이상의 그룹의 중앙값이 다른지 확인하는 검정 방법. 표본 속의 관측치를 분석대상으로 하지 않고 순서를 대상으로 함

02 기초통계

데이터 기초 분석

기술 통계

- 기술 통계(Descriptive Statistics): 자료의 특성을 표, 그림, 통계량 등을 사용해 쉽게 파악할 수 있도록 정리 / 요약 하는 것


통계량에 의한 자료 정리

구분	주요 예시
중심 위치의 측도	평균, 중앙값, 최빈값
산포의 측도	분산, 표준편차, 범위, 사분위수 범위, 변동계수, 표준오차
분포의 형태	왜도, 첨도

II. 통계분석

02 기초통계

그래프를 통한 자료 정리



02 기초통계

인과 관계의 이해

용어	설명
종속변수(반응변수, y)	다른 변수의 영향을 받는 변수
독립변수(설명변수, x)	영향을 주는 변수
산점도(Scatter Plot)	좌표평면 위에 점들로 표현한 그래프

산점도에서 확인할 사항


- 두 변수 사이의 선형관계(직선관계)가 성립하는가?
- 두 변수 사이의 함수관계(직선관계 또는 곡선관계)가 성립하는가?
- 이상값이 존재하는가?
- 몇 개의 집단으로 구분(층별)되는가?

II. 통계분석


02 기초통계

산점도 그래프 예시


상관계수 = -0.99




상관계수 = -0.75




상관계수 = -0.50




상관계수 = -0.25




상관계수 = 0.99




상관계수 = 0.75



상관계수 = 0.50



상관계수 = 0.25




02 기초통계

공분산(Covariance)

- 1개의 변수 값이 변화할 때 다른 변수가 어떠한 연관성을 나타내며 변할지를 측정하는 것이다.
- 두 확률 변수 X, Y 의 방향의 조합(선형성)이다.
- 공분산의 부호만으로 두 변수 간의 방향성을 확인할 수 있다.

용어	설명
$Cov(x, y) < 0$	y 의 값이 높을 때 x 의 값이 낮음
$Cov(x, y) = 0$	변수들의 높고 낮음에 대한 관련성을 알 수 없음
$Cov(x, y) > 0$	y 의 값이 높을 때 x 의 값이 높음



02 기초통계

상관분석(Correlation Analysis)

- 두 변수 간의 관계를 상관계수를 이용하여 알아보는 분석 방법
- 상관계수가 1에 가까울수록 강한 양의 상관관계, 상관계수가 -1에 가까울수록 강한 음의 상관관계를 가짐
- 상관계수가 0인 경우 데이터간 상관이 없음

구분	피어슨(pearson)	스피어만(spearman)
개념	등간척도 이상으로 측정된 두 변수의 상관관계 측정	순서, 서열 척도인 두 변수들 간의 상관관계를 측정
특징	연속형 변수, 정규성 가정	순서형 변수, 비모수적 방법
상관계수	피어슨 r (적률상관계수)	순위상관계수 ρ (로우)

02 기초통계

t-test

구분	분석 예시	분석 목적
일표본 t-test (One Sample t-test)	공장에서 생산되는 지우개의 평균 중량은 50g 이하	하나의 모집단의 평균을 특정값과 비교
이표본 t-test	A 회사의 급여가 B 회사의 급여가 같거나 많음	서로 독립적인 두 개의 집단에서 모수(모평균)의 값이 같은지 비교 등분산성을 먼저 만족해야 함
대응표본 t-test	두 집단의 신약투약 후 전후 수치 비교	동일한 대상에 대해 두가지 관측치가 있는 경우 비교

02 기초통계

분산분석(ANOVA : Analysis of Variance)

- 세개 이상의 집단 사이의 평균을 비교하는 검정
- 주요 가정 : 정규성, 등분산성, 독립성

구분	분석 예시	분석 개념
일원분산분석	신형 핸드폰 A, B, C의 속도 차이	분산분석에서 반응값에 대한 하나의 범주형 변수의 영향을 알아보하기 위해 사용되는 검증 방법

- F-통계량을 이용함
- 모집단의 수에는 제한이 없으며, 각 표본의 수는 같지 않아도 됨

사후 검정

- 사후 검정이란 분산분석의 결과 귀무가설이 기각되어 적어도 한 집단에서 평균의 차이가 있음이 통계적으로 증명되었을 경우,
- 어떤 집단들에 대해서 평균의 차이가 존재하는지 알아보기 위해 실시하는 분석

03 회귀분석

회귀분석의 정의

- 하나 또는 그 이상의 독립변수들이 종속변수에 미치는 영향을 추정할 수 있는 통계 기법
- 독립변수의 개수가 하나이면 단순선형회귀분석
- 독립변수의 개수가 두 개 이상이면 다중선형회귀분석

회귀분석의 변수


- 영향을 받는 변수 (y) = 반응변수 (Response Variable) = 종속변수 (Dependent Variable) = 결과변수 (Outcome Variable)
- 영향을 주는 변수 (x) = 설명변수 (Explanatory Variable) = 독립변수 (Independent Variable) = 예측변수 (Predictor Variable)

II. 통계분석

03 회귀분석

단순선형회귀분석

- 하나의 독립변수가 종속변수에 미치는 영향을 추정할 수 있는 통계기법
- 최소제곱법: 측정값을 기초로 제곱합을 만들고 그것이 최소인 값을 구하여 처리하는 방법, 잔차 제곱합이 가장 작은 선을 선택



주요 용어	설명
y_i	i 번째 종속변수 값
x_i	i 번째 독립변수 값
β_0	선형 회귀식의 절편(=상수항)
β_1	선형 회귀식의 기울기
ϵ_i	오차항, 독립적이며 $N(0, s^2)$ 분포

03 회귀분석

선형회귀분석의 가정

가정	설명
선형성	입력변수와 출력변수의 관계가 선형이다.
등분산성	오차의 분산이 회귀식의 적합값(fitted values)과 무관하게 일정하다. 잔차플롯(산점도)을 활용하여 잔차와 회귀식의 적합값에 아무런 관련성이 없게 무작위적으로 고루 분포되어야 등분산성 가정을 만족한다.
독립성	입력변수와 오차는 관련이 없다. 자기상관(독립성)을 알아보기 위해 Durbin-Waston 통계량을 사용하며 주로 시계열 데이터에서 많이 활용
비상관성	오차들끼리 상관이 없음
정상성(정규성)	오차의 분포가 정규분포를 따른다. Q-Q Plot, Kolmogorov-Smirnov 검정, Shapiro-Wilk 검정

03 회귀분석

회귀분석에서의 검토사항

회귀계수들이 유의미한가?

- 해당 계수의 $t - statistics$ 의 $p - value$ 이 0.05보다 작으면 해당 회귀계수가 통계적으로 유의하다고 볼 수 있다.

모형이 얼마나 설명력을 갖는가?

- 결정계수(R^2)를 확인한다. 결정계수는 0~1 값을 가지며, 높은 가질수록 추정된 회귀식의 설명력이 높다.

모형이 데이터를 잘 적합하고 있는가?

- 잔차를 그래프로 그리고 회귀진단을 한다.

03 회귀분석

회귀분석에서의 검정

- 단순 회귀 분석의 결정계수는 상관계수 값의 제곱과 같음


검정	설명
F-검정	회귀식(모형)에 대한 검증
t-검정	회귀계수에 대한 검증
결정계수(R^2)	모형의 설명력은 1에 가까울수록 모형의 설명력이 높다고 할 수 있음 ($0 \leq R^2 \leq 1$)

II. 통계분석

03 회귀분석

결정계수

- 회귀분석의 결정계수는 1에 가까울수록 모델의 설명력이 높음



주요 용어	설명
$\hat{Y}$	관찰값(데이터의 평균)
Y_i	관찰값
SST(Sum of Square Total)	종속변수값의 총 변동 SST = SSR + SSE
SSR(Sum of Square Regression)	회귀선에 의해 설명되는 변동
SSE(Sum of Square Error)	회귀선에 의해 설명되지 않는 변동

03 회귀분석

다중선형회귀분석

- 두 개 이상의 독립변수가 하나의 종속변수에 미치는 영향을 추정하는 회귀분석
- 다중선형회귀식은 다음과 같음

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_k X_k + \epsilon$$

가설 설정

가설	설명	표현
귀무가설	각 회귀계수의 기울기는 0이다.	$\beta_1 = \beta_2 = \beta_3 \dots = \beta_k = 0$
대립가설	적어도 한 개의 독립변수 회귀계수의 기울기는 0이 아니다.	$\beta_1 \neq \beta_2 \neq \beta_3 \dots \neq \beta_k \neq 0$

II. 통계분석

03 회귀분석

다중선형회귀분석 모형의 통계적 유의성

- 모형의 통계적 유의성은 F-통계량으로 확인
- 유의수준 5% 하에서 F-통계량의 p-값이 0.05보다 작으면 추정된 회귀식은 통계적으로 유의하다고 볼 수 있음
- F 통계량이 크면 p-value가 작아지고 이렇게 되면 귀무가설을 기각한다. 즉, 모형이 유의하다고 결론지을 수 있음.

변동요인	제곱합	자유도	평균 제곱	F값(f)
회귀(SSR)	회귀제곱합	k	$MSR = \frac{SSR}{k}$	$f = \frac{MSR}{MSE}$
오차(SSE)	오차제곱합	$n - k - 1$	$MSE = \frac{SSE}{(n - k - 1)}$	
전체변동(SST)	총 제곱합	$n - 1$		

n : 관측값의 개수, k : 독립변수의 개수(단순회귀분석: $k = 1$)

MSE(Mean Square Error, 오차제곱평균) 산출, MSR(Mean Square Regression, 회귀제곱평균) 산출

03 회귀분석

다중선형회귀분석 회귀계수의 유의성

- 회귀계수의 유의성은 단순회귀분석의 회귀계수 유의성 검토와 같이 회귀계수 t-통계량을 통해 확인한다.
- 모든 회귀계수의 유의성이 통계적으로 검증되어야 선택된 변수들의 조합으로 모형을 확인할 수 있음.

다중선형회귀분석 다중공선성(Multicollinearity)

- 회귀분석에서 독립변수들 간에 강한 상관관계가 나타나는 문제
- 정확한 회귀계수의 추정이 어려워지며, 각 독립변수의 회귀계수가 종속변수에 미치는 영향력을 올바르게 설명하지 못하게 됨

다중공선성 검사 방법

- 분산팽창요인(VIF) : 4보다 크면 다중공선성이 존재한다고 볼 수 있고, 10보다 크면 심각한 문제가 있는 것으로 해석할 수 있다.

03 회귀분석

다중회귀분석의 변수 선택 방법

- 이상적으로는 독립변수의 조합에 따라 만들어지는 선형모델 모두를 비교하여 최고의 모델 선정 가능.
- 변수가 k 개인 경우, k 개 변수들의 일부를 포함하는 총 모델의 수는 2^k 개에 이르므로, 모델 모두를 고려하기는 현실적으로 불가능.
- 단계적 변수 선택(Stepwise Variable Selection) 방법 사용

단계적 변수 선택 방법의 유형

구분	표현
전진선택법 (Forward Selection)	모델적합에 가장 큰 영향을 미치는 독립변수를 순서대로 추가하여 성능지표를 비교하면서 변수를 선택하는 방법. 한 번 선택한 변수는 제거하지 않음
후진선택법 (Backward Elimination)	전체 변수로 시작해서 모델적합에 가장 약하게 영향을 미치는 독립변수를 순서대로 제거해가며 성능지표를 비교하면서 변수를 선택하는 방법
단계적방법 (Stepwise Method)	전진선택법과 후진제거법을 병행하는 방법 추가된 변수에 의해 기존 변수의 중요도가 작아지면 추가된 변수를 제거

04 다차원 척도법

다차원척도법(Multidimensional Scaling) 개요

- 데이터 간의 거리(Distance)를 바탕으로 이들 간의 관계구조를 시각적으로 표현하는 통계 데이터 분석기법(개체간 근접성: Proximity).
- 군집분석과 같이 개체들을 대상으로 변수들을 측정한 후, 개체들 사이의 유사성/비유사성을 측정하여 개체들을 2차원 공간상에 점으로 표현하는 분석방법
- 데이터 속에 잠재해 있는 패턴(Pattern), 구조를 찾아냄
- 그 구조를 소수 차원의 공간에 기하학적으로 표현함
- 데이터 축소(Data Reduction)의 목적으로 다차원척도법 이용. 즉, 데이터에 포함되는 정보를 끄집어내기 위해 다차원척도법을 탐색수단으로써 사용함
- 데이터가 만들어진 현상이나 과정에 고유의 구조로서 의미 부여

II. 통계분석

04 다차원 척도법

$$d_{ij} = \sqrt{(x_{i1} - d_{j1})^2 + \dots + (x_{iR} - d_{jR})^2}$$

다차원척도법(Multidimensional Scaling) 방법

- 개체들의 거리 계산에는 유클리드 거리행렬 활용
- 관측대상들의 상대적 거리의 정확도를 높이기 위해 적합 정도를 스트레스 값(*Stress Value*)으로 나타냄.
- 각 개체들을 공간상에 표현하기 위한 방법은 부적합도 기준으로 *Stress*나 *S - Stress*를 사용함
- 최적모형의 적합은 부적합도를 최소로 하는 반복 알고리즘을 이용하며, 이 값이 일정 수준 이하가 될 때 최종적으로 적합된 모형으로 제시
- *Stress*와 적합도 수준 *M*은 개체들을 공간상에 표현하기 위한 방법으로 *Stress*나 *S - Stress*를 부적합도 기준으로 사용함

Stress	적합도 수준
0	완벽(Perfect)
0.05 이내	매우 좋은(Excellent)
0.05 ~ 0.10	만족(Satisfactory)
0.10 ~ 0.15	보통(Acceptable, but Doubt)
0.15 이상	나쁨(Poor)

04 다차원 척도법

다차원척도법(Multidimensional Scaling) 종류

구분	계량적 다차원척도법(Metric MDS)	비계량적 다차원척도법(Nonmetric MDS)
척도	등간변수 혹은 비율변수	서열변수
근접도 계산	각 데이터(개체)들 간의 유클리드거리 행렬을 계산하고 개체들 간의 비유사성을 공간상에 표현	데이터(개체)들 간의 거리가 순서로 주어진 경우에는 서열척도를 거리의 속성과 같도록 변환하여 표현

05 주성분 분석

주성분 분석의 개요

- 여러 변수들의 변량을 '주성분(Principal Component)'이라는 서로 상관성이 높은 변수들의 선형 결합으로 만들어 기존의 상관성이 높은 변수들을 요약, 축소하는 기법이다.
- 다중공선성이 존재하는 경우, 상관성이 없는(적은) 주성분으로 변수들을 축소하여 모형 개발에 활용된다.
- 연관성이 높은 변수를 주성분분석을 통해 차원을 축소한 후에 군집분석을 수행하면 군집화 결과와 연산속도를 개선할 수 있다.
- 기계에서 나오는 다수의 센서데이터를 주성분분석으로 차원을 축소한 후에 시계열로 분포나 추세의 변화를 분석하면 기계의 고장(Fatal Failure) 징후를 사전에 파악하는데 활용하기도 함.

05 주성분 분석

주성분 분석 vs. 요인분석 (Factor Analysis)

- 요인분석은 등간척도(혹은 비율척도)로 측정한 두 개 이상의 변수들에 잠재되어 있는 공통인자를 찾아내는 기법
- 공통점 : 모두 데이터를 축소하는데 활용하며, 새로운 변수들을 만들 수 있다.

단계적 변수 선택 방법의 유형

구분	주성분 분석	요인분석
공통점	변수축소 가능, 데이터 패턴탐색 용이, 타 분석을 위한 사전분석 역할 수행	
원리	변수의 전체 분산을 토대로 요인을 추출 (원 변수들의 선형결합으로 만들어짐)	변수 간의 공통 분산만(공분산)을 토대로 요인을 추출 그룹 내 변수들 간에는 상관계수가 높고 다른 그룹 변수 간에는 상관관 계가 낮음
목적	변수들의 변동을 설명	여러 변수의 공분산 구조의 의미를 밝힘
변수 개수	원 변수를 1~2개로 축약	서로 상관성을 갖는 변수들의 군집의 수만큼 축약

05 주성분 분석

주성분 분석의 선택법

- 주성분 분석의 결과에서 누적 기여율(Cumulative Proportion)이 85% 이상이면 주성분의 수로 결정할 수 있음
- Scree Plot을 활용하여 고윳값(Eigenvalue)이 수평을 유지하기 전단계로 주성분의 수를 선택

Code

```
> library(datasets)
> data("USArrests")
> US.prim = princomp(USArrests, cor = TRUE)
> summary(US.prim)
```

Importance of components:

	Comp.1	Comp.2	Comp.3	Comp.4
Standard deviation	1.5748783	0.9948694	0.5971291	0.41644938
Proportion of Variance	0.6200604	0.2474413	0.0891408	0.04335752
Cumulative Proportion	0.6200604	0.8675017	0.9566425	1.00000000


요약

- 제 1주성분과 제 2주성분까지의 누적 분산비율은 대략 86.8%
- 2개의 주성분 변수를 활용하여 전체 데이터의 86.8%를 설명

05 주성분 분석

주성분 분석의 선택법

- 주성분 분석의 결과에서 누적 기여율(Cumulative Proportion)이 85% 이상이면 주성분의 수로 결정할 수 있음
- Scree Plot을 활용하여 고윳값(Eigenvalue)이 수평을 유지하기 전 단계로 주성분의 수를 선택



요약

- 주성분들에 의해 설명되는 변동의 비율은 Scree Plot을 통해 확인 가능함

06 시계열 분석

시계열 자료

- 시간의 흐름에 따라 관찰된 값들을 시계열 자료라 함
- 시계열 데이터 분석을 통해 미래의 값 예측, 경향, 주기, 계절성 등을 파악하여 활용함

시계열 자료의 종류

- 비정상성 시계열 자료 : 시계열 분석을 실시할 때 다루기 어려운 자료로 대부분의 시계열 자료가 이에 해당함
- 정상성 시계열 자료 : 비정상 시계열을 핸들링하여 다루기 쉬운 시계열 자료로 변환한 자료

06 시계열 분석

정상성

- 정상성은 평균이 일정할 때, 분산이 일정할 때, 공분산도 단지 시차에만 의존하고 실제 특정 시점 t , s 에는 의존하지 않을 때 만족함

주요 특징	설명
평균이 일정	모든 시점에 대해 일정한 평균을 가져야 함 평균이 일정하지 않은 시계열은 차분(Difference)을 통해 정상화 할 수 있음
분산이 일정	분산도 시점에 의존하지 않고 일정해야 함 분산이 일정하지 않을 경우 변환(Transformation)을 통해 정상화할 수 있음
공분산	시계열 분석에서, 공분산도 단지 시차에만 의존, 실제 특정 시점 t , s 에는 의존하지 않음


차분(Difference)이란 : 현시점 자료에서 전 시점 자료를 빼는 것

- 일반차분(Regular Difference) : 바로 전 시점의 자료를 빼는 방법

- 계절차분(Seasonal Difference) : 여러 시점 전의 자료를 빼는 방법, 주로 계절성을 갖는 자료를 정상화 하는데 사용

II. 통계분석

06 시계열 분석



정상 시계열

- 녹색 그래프가 정상 시계열
- 정상 시계열은 어떤 시점에서 평균과 분산 그리고 특정한 시차의 길이를 갖는 자기공분산을 측정하더라도 동일한 값을 가짐
- 정상 시계열은 항상 그 평균값으로 회귀하려는 경향이 있으며, 그 평균값 주변에서의 변동은 대체로 일정한 폭을 가짐
- 정상 시계열이 아닌 경우 특정 기간의 시계열 자료로부터 얻은 정보를 다른 시기로 일반화 할 수 없음

06 시계열 분석

시계열자료 분석방법

- 회귀분석(계량경제)방법, Box-Jenkins 방법, Box-Jenkins 방법, 지수평활법, 시계열 분해법 등 존재.
- 수학적 이론 모형 : 회귀분석(계량경제)방법, Box-Jenkins 방법
- 직관적 방법 : 지수평활법, 시계열 분해법으로 시간에 따른 변동이 느린 데이터 분석에 활용
- 장기 예측 : 회귀분석방법 활용
- 단기 예측 : Box-Jenkins 방법, 지수평활법, 시계열 분해법 활용

II. 통계분석

06 시계열 분석

$$F_{n+1} = \frac{1}{m} \sum_{t=n-m+1}^n Z_t, t = n - m + 1$$

이동평균법

- 과거로부터 현재까지의 시계열 자료를 대상으로 일정 기간별 이동평균을 계산하고, 이들의 추세를 파악하여 다음 기간을 예측하는 방법
- 시계열 자료에서 계절변동과 불규칙 변동을 제거하여 추세변동과 순환변동만 가진 시계열로 변환하는 방법으로도 사용됨
- n 개의 시계열 데이터를 m 기간으로 이동평균하면 $n - m + 1$ 개의 이동평균 데이터가 생성됨.
- 간단하고 쉽게 미래를 예측할 수 있으며, 자료의 수가 많고 안정된 패턴을 보이는 경우 예측의 품질(Quality)이 높음
- 특정 기간 안에 속하는 시계열에 대해서는 동일한 가중치를 부여함
- 일반적으로 시계열 자료에 뚜렷한 추세가 있거나 불규칙변동이 심하지 않은 경우에는 짧은 기간(m 의 개수를 적음)의 평균을 사용, 반대로 불규칙 변동이 심한 경우 긴 기간(m 의 개수가 많음)의 평균을 사용함
- 이동평균법에서 가장 중요한 것은 적절한 기간을 사용하는 것, 즉, 적절한 m 의 개수를 결정하는 것임

II. 통계분석

06 시계열 분석

$$F_{n+1} = \alpha Z_n + (1 - \alpha)F_n$$

지수평활법

- 모든 시계열 자료를 사용하여 평균을 구하며, 시간의 흐름에 따라 최근 시계열에 더 많은 가중치를 부여하여 미래를 예측하는 방법
- F_{n+1} 은 n시점 다음의 예측값, α 는 지수평활계수, Z_n 은 n시점의 관측값이며, 지수평활 계수가 과거로 갈수록 지수형태로 감소하는 형태인 것을 확인할 수 있다.
- 단기간에 발생하는 불규칙 변동을 평활하는 방법
- 자료의 수가 많고 안정된 패턴을 보이는 경우일수록 예측 품질이 높음
- 지수평활법에서 가중치의 역할을 하는 것은 지수평활계수(α)이며, 불규칙변동이 큰 시계열의 경우 지수평활계수는 작은 값을 불규칙변동이 작은 시계열의 경우, 큰 값의 지수평활계수를 적용함(generally, α is between 0.05 and 0.3)
- 지수평활계수는 예측오차(실제 관측치와 예측치 사이의 잔차제곱합)를 비교하여 예측오차가 가장 작은 값을 선택하는 것이 바람직함
- 지수평활법은 불규칙변동의 영향을 제거하는 효과가 있으며, 중기 예측 이상에 주로 사용됨 (단, 단순지수 평활법의 경우, 장기추세나 계절변동이 포함된 시계열의 예측에는 적합하지 않음)

06 시계열 분석

시계열모형

- 시계열이 모형은 자기회귀 모형(AR 모형), 이동평균 모형(MA 모형), 자기회귀누적이동평균 모형(ARIMA 모형)이 있음.

자기회귀 모형(AR 모형, Autoregressive Model)

- 자신의 이전 관측값이 이후 자신의 관측값에 영향을 준다는 아이디어 이용

- p 시점 전의 자료가 현재 자료에 영향을 주는 모형

$$Z_t = \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + \dots + \phi_p Z_{t-p} + \alpha_t$$

- Z_t : 현재 시점의 시계열 자료

- $Z_{t-1}, Z_{t-2}, \dots, Z_p$: 이전, 그 이전 시점 p 의 시계열 자료

- ϕ_1 : p 시점이 현재에 어느 정도 영향을 주는지를 나타내는 모수

- α_t : 백색잡음과정(White Noise Process), 시계열 분석에서 오차항을 의미

06 시계열 분석

시계열모형

- 시계열이 모형은 자기회귀 모형(AR 모형), 이동평균 모형(MA 모형), 자기회귀누적이동평균 모형(ARIMA 모형)이 있음.

자기회귀 모형(AR 모형, Autoregressive Model)

- 평균이 0, 분산이 σ^2 , 자기공분산이 0인 경우를 뜻하며, 시계열간 확률적 독립인 경우 강(Strictly) 백색잡음 과정이라고 함.

- 백색잡음 과정이 정규분포를 따를 경우 이를 가우시안(Gaussian) 백색잡음과정이라고 한다.

- AR(1) 모형: $Z_t = \phi_1 Z_{t-1} + \alpha_t$, 직전 시점 데이터로만 분석

- AR(2) 모형: $Z_t = \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + \alpha_t$, 연속된 2시점 정도의 데이터 분석

- 자기상관함수(ACF)는 빠르게 감소, 부분자기함수(PACF)는 어느 시점에서 절단점을 가진다.

- 예: ACF가 빠르게 감소하고, PACF가 3시점에서 절단점을 갖는 그래프가 있다면, 2시점 전의 자료까지가 현재에 영향을 미치는 AR(2) 모형이라 볼 수 있다.

06 시계열 분석

시계열모형

- 시계열이 모형은 자기회귀 모형(AR 모형), 이동평균 모형(MA 모형), 자기회귀누적이동평균 모형(ARIMA 모형)이 있음.

이동평균 모형(MA 모형, Moving Average Model)

- 이동평균모형은 경향성(평균 혹은 시계열 그래프에서의 y값)이 변화하는 상황에 적합한 회귀모델.

- 유한한 개수의 백색잡음의 결합이므로 언제나 정상성 만족

- 1차 이동평균모형(MA(1) 모형)은 이동평균모형 중에서 가장 간단한 모형으로 시계열이 같은 시점의 백색잡음과 바로 전 시점의 백색잡음의 결합으로 이뤄진 모형

$$Z_t = \theta_1 \alpha_{t-1} + \theta_2 \alpha_{t-2} + \dots + \theta_p \alpha_{t-p}$$

- 2차 이동평균모형(MA(2) 모형)은 바로 전 시점의 백색잡음과 시차가 2인 백색잡음의 결합으로 이뤄진 모형

$$Z_t = \alpha_t + \theta_1 \alpha_{t-1}$$

- AR 모형과 반대로 ACF에서 절단점을 갖고, PACF가 빠르게 감소

$$Z_t = \alpha_t + \theta_1 \alpha_{t-1} + \theta_2 \alpha_{t-2}$$

06 시계열 분석

시계열모형

- 시계열이 모형은 자기회귀 모형(AR 모형), 이동평균 모형(MA 모형), 자기회귀누적이동평균 모형(ARIMA 모형)이 있음.

자기회귀누적이동평균 모형(ARIMA 모형, Autoregressive Integrated Moving Average Model)

- ARIMA는 AR(자기회귀), I(차분, 즉 통합), MA(이동 평균)의 합성으로 관측치 사이의 차분(Difference)이라는 개념을 사용하여 불규칙적 시계열 데이터를 규칙적 시계열 데이터로 활용할 수 있도록 하는 과정이다.

- 현재 상태의 변수에서 바로 전 상태의 변수를 빼주는 것을 차분이라고 하며, 차분을 거친 결과 변수들이 화이트닝(Whitening) 되는 효과가 있다. 차분을 통해 현재 상태를 변환한다.

- 기존 AR, MA, ARMA 모델의 경우 데이터가 정상(Stationary)이어야 함으로 비정상(Non Stationary)인 경우는 차분(Differencing)을 통해 데이터를 정상으로 변형해주어야 함

- ARIMA는 ARMA 모델에 차분을 d회 수행해준 모델이다.

06 시계열 분석

시계열모형

- 시계열이 모형은 자기회귀 모형(AR 모형), 이동평균 모형(MA 모형), 자기회귀누적이동평균 모형(**ARIMA** 모형)이 있음.

자기회귀누적이동평균 모형(**ARIMA** 모형, Autoregressive Integrated Moving Average Model)

- ARIMA는 ARMA 모델에 차분을 d 회 수행해준 모델이다.

$$ARIMA(p, d, q)$$

p : AR 모델의 차수, d : 차분, q : MA 모델의 차수

- $d = 0$ 이면, $ARMA(p, q)$ 모형이라고 부르고, 이 모형은 정상성을 만족함

- $p = 0$ 이면, $IMA(d, q)$ 모형이라고 부르고, d 번 차분하면 $MA(q)$ 모형 따름

- $q = 0$ 이면, $ARI(p, d)$ 모형이라고 부르고, d 차분한 시계열이 $AR(p)$ 모형 따름

06 시계열 분석

시계열모형

- 시계열이 모형은 자기회귀 모형(AR 모형), 이동평균 모형(MA 모형), 자기회귀누적이동평균 모형(**ARIMA** 모형)이 있음.

자기회귀누적이동평균 모형(**ARIMA** 모형, Autoregressive Integrated Moving Average Model)

- ARIMA는 ARMA 모델에 차분을 d 회 수행해준 모델이다.

$$ARIMA(p, d, q)$$

p : AR 모델의 차수, d : 차분, q : MA 모델의 차수

- $d = 0$ 이면, $ARMA(p, q)$ 모형이라고 부르고, 이 모형은 정상성을 만족함

- $p = 0$ 이면, $IMA(d, q)$ 모형이라고 부르고, d 번 차분하면 $MA(q)$ 모형 따름

- $q = 0$ 이면, $ARI(p, d)$ 모형이라고 부르고, d 차분한 시계열이 $AR(p)$ 모형 따름

06 시계열 분석

시계열모형

- 시계열이 모형은 자기회귀 모형(AR 모형), 이동평균 모형(MA 모형), 자기회귀누적이동평균 모형(**ARIMA** 모형)이 있음.

자기회귀누적이동평균 모형(**ARIMA** 모형, Autoregressive Integrated Moving Average Model)

- ARIMA는 ARMA 모델에 차분을 d 회 수행해준 모델이다.

$$ARIMA(p, d, q)$$

p : AR 모델의 차수, d : 차분, q : MA 모델의 차수

- $d = 0$ 이면, $ARMA(p, q)$ 모형이라고 부르고, 이 모형은 정상성을 만족함

- $p = 0$ 이면, $IMA(d, q)$ 모형이라고 부르고, d 번 차분하면 $MA(q)$ 모형 따름

- $q = 0$ 이면, $ARI(p, d)$ 모형이라고 부르고, d 차분한 시계열이 $AR(p)$ 모형 따름

Ⅲ. 정형 데이터 마이닝

01 데이터 마이닝

데이터 마이닝 개요

- 정의: 대용량 데이터에서 의미 있는 패턴을 파악하거나 예측하여 의사결정에 활용하는 방법
- 통계분석과 차이점: 가설이나 가정에 따른 분석, 검증을 하는 통계분석과 달리 데이터마이닝은 다양한 수리 알고리즘을 이용해 데이터베이스의 데이터로부터 의미있는 정보를 추출
- 활용분야: 분류, 예측, 군집화, 시각화 등
- 방법론: 의사결정나무, 로지스틱 회귀분석, 최근접 이웃법, 군집분석, 연관규칙분석 등

Ⅲ. 정형 데이터 마이닝

01 데이터 마이닝

데이터 마이닝 주요 알고리즘

- Supervised Learning VS Unsupervised Learning

Supervised Learning	Unsupervised Learning
- 의사결정나무 (Decision Tree) - 인공신경망(Artificial Neural Network) - 로지스틱 회귀분석(Logistic Regression) - 최근접 이웃법(k-Nearest Neighbor) - 사례기본 추론(Case-Based Reasoning)	- OLAP(On-Line Analytic Processing) - 연관 규칙 분석(Association Rule Analysis) - 군집분석(k-Means Clustering) - SOM(Self Organizing Map)

Ⅲ. 정형 데이터 마이닝

01 데이터 마이닝

데이터 마이닝 분석 유형

- 분류, 수치 예측, 군집화, 연관규칙 관점에서 구분할 수 있음

구분	설명
분류 (Classification)	범주형 및 연속형 등의 과거 데이터로부터 특성을 분석하여 결과값(실수, 연속형)을 예측하는 방법 다수의 속성 혹은 변수를 가지는 데이터(개체)들을 사전에 정해진 그룹이나 범주 중의 하나로 분류하는 방법
수치 (Regression)	범주형 및 연속형 등의 과거 데이터로부터 특성을 분석하여 결과값(실수, 연속형)을 예측하는 방법
군집화 (Clustering)	집단(군집)에 관한 사전정보가 전혀 없는 각 데이터에 대하여 각 데이터들 간의 유사성을 측정해, 집단으로 묶을 때(그룹핑) 사용되는 방법
연관규칙 (Association Rule)	데이터에 숨어있으면서 동시에 발생하는 사건 혹은 항목 간의 규칙을 수치화하는 분석기법(장바구니분석)이며, 대형 데이터 베이스 등에서 변수 간의 흥미로운 관계를 발견하기 위한 규칙(조건 - 결과) 기반 데이터 마이닝 학습방법

Ⅲ. 정형 데이터 마이닝

01 데이터 마이닝

데이터 마이닝 추진단계

주요 특징	설명
목적 설정	데이터 마이닝을 위한 명확한 목적 설정
데이터 준비	모델링을 위한 다양한 데이터를 준비, 데이터 정제를 통해 품질을 보장
데이터 가공	목적변수 정의, 모델링을 위한 데이터 형식으로 가공
기법 적용	데이터 마이닝 기법을 적용하여 정보를 추출
검증	마이닝으로 추출한 결과를 검정하고 업무에 적용해 기대효과를 전파

Ⅲ. 정형 데이터 마이닝

01 데이터 마이닝

데이터 마이닝 분할

주요 특징	설명
구축용(Training Data)	60%의 데이터 모델링을 위한 훈련용으로 활용
검증용(Validation Data)	20%의 데이터를 구축된 모형의 과대/과소 추정의 판정 목적으로 활용
시험용(Test Data)	20%의 데이터를 테스트 데이터나 과거 데이터를 활용하여 모델의 성능평가에 활용

Train Data (60%)	Validation Data (20%)	Test Data (20%)
---------------------	--------------------------	--------------------

Ⅲ. 정형 데이터 마이닝

01 데이터 마이닝

데이터 마이닝 분할

- 데이터의 양이 충분하지 않은 경우

홀드아웃(Hold-Out) 방법

- 주어진 데이터를 랜덤하게 두 개의 데이터로 구분하여 사용하는 방법으로 주로 학습용(Training Data)과 시험용(Test Data)로 분리하여 사용

k-fold 교차분석(Cross-Validation) 방법

- 주어진 데이터를 k 개의 하부집단으로 구분하여, $k-1$ 개의 집단을 학습용으로 나머지는 하부집단으로 검증용으로 설정하여 학습. k 번 반복 측정한 결과를 평균낸 값을 최종값으로 사용한다. 주로 10-fold 교차분석을 많이 사용.

Ⅲ. 정형 데이터 마이닝


01 데이터 마이닝

데이터 마이닝 분할

- 데이터의 양이 충분하지 않은 경우

k-fold 교차분석(Cross-Validation) 방법

- 주어진 데이터를 k 개의 하부집단으로 구분하여, $k-1$ 개의 집단을 학습용으로 나머지는 하부집단으로 검증용으로 설정하여 학습. k 번 반복 측정한 결과를 평균낸 값을 최종값으로 사용한다. 주로 10-fold 교차분석을 많이 사용.



Ⅲ. 정형 데이터 마이닝

01 데이터 마이닝

데이터 가공(변환) 기법

주요 기법	설명
평활화 (Smoothing)	노이즈(잡음) 제거를 위해 이상값들을 반환 → 데이터 분포를 매끄럽게 만듦(구간화, 군집화, 차원축소 등 사용)
일반화 (Generalization)	특정 구간에 분포하는 값으로 스케일을 변환. 범용 데이터에 적합한 모델을 만드는 기법. 이상값과 노이즈에 영향 적음
정규화 (Normalization)	데이터를 정해진 구간으로 변환(0 ~ 1사이) Min-Max 정규화 : 모든 데이터에 대해 최소값 0, 최대값 1 범위 내에서 0 ~ 1사이의 값으로 변환
표준화 (Standardization)	데이터를 0을 중심으로 양쪽으로 데이터를 분포시키는 방법(평균 0, 표준편차 1)
범주화 (Categorization)	이산형화 : 연속형 변수를 범주형 변수(다수 구간)로 변환하는 과정 이항변수화 : 1, 0 두개의 범주로 가변환(Dummy Variable)을 만드는 과정
차원축소 (Dimensionality Reduction)	데이터가 가지고 있는 특성의 개수를 줄여 나가면서 모델의 성능을 유지하는 방법 특성선택(Feature Selection), 특성추출(Feature Extraction)

02 모형평가

분류모델 평가지표

- 분류모델의 주목적은 주어진 데이터를 의도에 맞게 잘 분류(Classification) 해내기 위한 것이며, 평가하는 기준은 정확도(Accuracy), 정밀도(Precision), 재현율(Recall)을 사용
- 혼동행렬은 분류한 예측값(그룹 혹은 범주)과 실제값(그룹 혹은 범주)을 교차표 형태로 정리한 행렬로 구성됨. 분할표(Contingency Table) 또는 오차행렬(An Error Matrix)라고도 불리운다.

		실제 범주값(실제값)	
		Positive	Negative
예측 범주값(예측값)	Positive	TP(True Positive)	FP(False Positive)
	Negative	FN(False Negative)	TN(True Negative)

Positive = 1 = 양성; Negative = 0 = 음성

02 모형평가

분류모델 평가지표

		실제 범주값(실제값)	
		Positive	Negative
예측 범주값(예측값)	Positive	TP(True Positive)	FP(False Positive)
	Negative	FN(False Negative)	TN(True Negative)

Positive = 1 = 양성; Negative = 0 = 음성

- TP(True Positive) : 실제값 양성을 양성으로 옳게(True) 예측한 수
- FP(False Positive) : 실제값 음성을 양성으로 틀리게(False) 예측한 수
- FN(False Negative) : 실제값 양성을 음성으로 틀리게(False) 예측한 수
- TN(True Negative) : 실제값 음성을 음성으로 옳게(True) 예측한 수

02 모형평가

혼동행렬 평가지표

구분	수식	설명
정확도 (Accuracy)	$\frac{TP + TN}{TP + TN + FP + FN}$	실제값과 예측값이 얼마나 일치되지는 비율로 나타낸 평가지표
정밀도 (Precision)	$\frac{TP}{TP + FP}$	양성 예측의 정확도를 의미 양성이라고 예측한 값(TP + FP) 중 실제 양성인 값
재현율 (Recall)	$\frac{TP}{TP + FN}$	실제 양성 값(TP + FN) 중 양성으로 잘 예측한 값(TP)의 비율 재현율은 민감도라고 불리우기도 함
특이도 (Specificity)	$\frac{TN}{TN + FP}$	실제값이 음성인 값 중에 음성을 음성으로 옳게(TN) 판단한 비율
F1점수 (F1-Score)	$2 \times \frac{Precision \times Recall}{Precision + Recall}$	정밀도(Precision)와 재현율(Recall)의 조화평균. 범주 불균형 문제를 가지고 있는 데이터의 평가지표 시스템의 성능을 하나의 수치로 표현하기 위해 사용하는 점수 0~1 사이의 값을 가지며 1에 가까울수록 좋음

02 모형평가

ROC Curve와 AUC (Area Under the ROC Curve)

- ROC Curve는 민감도와 특이도를 이용하여 그린 그래프로 가로축은 거짓양성비율(FPR, 1-특이도), 세로축은 양성비율(민감도 또는 재현율)로 구성됨
- ROC Curve에 의해 설명되는 면적을 AUC라 하며, AUC는 ROC Curve를 점수로 환산한 값. 1에 가까울수록 좋은 분류모델을 의미함.
- AUC 값에 따른 모델 진단

AUC 점수 (Score)	평가 (Evaluation)
$0.9 \leq AUC \leq 1.0$	뛰어남(Excellent)
$0.8 \leq AUC \leq 0.9$	우수함(Good)
$0.7 \leq AUC \leq 0.8$	보통(Fair)
$0.6 \leq AUC \leq 0.7$	불량(Poor)
$0.5 \leq AUC \leq 0.6$	실패(Fail)

Ⅲ. 정형 데이터 마이닝

02 모형평가

향상도 차트(Life Chart)=이익차트 (Gain Chart)

- 목표 범주에 속하는 데이터(개체)들이 임의로 나눈 등급별로 얼마나 분포하고 있는지를 그래프로 나타내어 분류 정확도를 측정하는 평가방법
- 각 등급은 예측확률에 따른 순위이기 때문에 상위등급에서 더 높은 반응율을 보이는 것이 좋은 모델
- 향상도가 빠른 속도로 감소하는 것이 좋은 모델

평가항목	수식
기준향상도 (Baseline Lift)	전체 반응 데이터 수 / 전체 데이터 수
반응검출율(%) (Captured Response)	구간 내 반응 데이터 수 / 전체 반응 데이터 수
반응율(%) (Response)	구간 내 반응 데이터 수 / (전체 데이터 수 ÷ 분위 개수)
향상도 (Lift)	구간별 반응율 / 기준향상도

『향상도 차트의 주요 지표』

Ⅲ. 정형 데이터 마이닝

02 모형평가

회귀모형 평가지표

- 결과가 연속형 데이터(실수값)로 결정되기 때문에 데이터의 오차(Error)의 수치로 성능을 평가한다.
- 다음 주요 지표로 측정된 값이 적을수록 좋은 모델로 판단할 수 있음.

 y_i : i 번째 종속변수 실제값, $\hat{y}_i$: i 번째 종속변수 예측값

구분	수식	설명
평균절대오차(MAE) (Mean Absolute Error)	$\frac{1}{n} \sum_{i=1}^n y_i - \hat{y}_i $	실제값과 예측값 차이의 절대값 합의 평균(직관적 지표) 오차간 합이 0되는 것을 방지
평균제곱오차(MSE) (Mean Square Error)	$\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$	실제값과 예측값 차이의 제곱합의 평균(직관적 지표) 제곱을 하기 때문에 평균절대오차(MAE)와는 다르게 모델의 실제값 예측값과 차이의 면적의 합이 됨. 이런 차이로 특이값/이상값에 민감
평균제곱근오차(RMSE) (Root Mean Square)	$\sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$	MSE의 값이 커지는 것을 실제값의 단위와 맞게 조정 평균제곱오차(MSE)보다 특이값/이상값에 덜 민감함

Ⅲ. 정형 데이터 마이닝

02 모형평가

군집분석 평가지표

- 군집 내 높은 유사도(High Intra Cluster Similarity, 응집도)를 가지고, 군집 간 낮은 유사도(Low Inter Cluster Similarity, 분리도)를 가진 결과물에 높은 점수 부여


평가항목	설명
던지수 (Dunn Index)	- 군집 내(Inner Cluster) 최대거리에 군집 간(Inter Cluster)의 최소거리의 비군집 간 거리의 최소값을 분자로, 군집 내 요소간 최대값을 분모로 하는 지표 - 군집 간 거리가 멀수록, 데이터 간 거리가 가까울수록 큰 값을 가짐(군집 내 밀도가 높고 군집이 잘 나누어질수록)
실루엣계수 (Silhouette Coefficient)	- 군집 내의 응집도와 군집 간 분리도를 이용한 지표, 군집 내 데이터 간의 거리가 짧고 서로 다른 군집 간 거리가 멀수록 값이 커짐
단순계산법 (Rule of Thumb)	- 데이터의 수 n 을 이용하여 필요한 군집의 수 계산 방법
팔꿈치기법 (Elbow Method)	- 팔꿈치(Elbow) 모습을 나타내는 부분을 최적의 군집 수를 K 값으로 지정하는 방법 - 군집 간의 거리의 합을 나타내는 관성(Inertia)이 급격히 떨어지는 구간이 생기는 지점의 K 값을 군집의 개수로 사용 - 관성(Inertia): 각 군집의 군집 내 총 제곱합(Within Cluster Sum of Squares, WCSS)

Ⅲ. 정형 데이터 마이닝

03 분류 분석

분류분석 개요

- 데이터가 어떤 그룹에 속하는지 예측하는데 사용되는 기법
- 클러스터링과 유사하지만, 분류분석은 각 그룹이 정의
- 교사학습(Supervised Learning)에 해당하는 예측기법



03 분류 분석

분류분석 개요

기법 종류

- 신용평가모형(우량, 불량)
- 사기방지모형(사기, 정상)
- 고객세분화(WVIP, VIP, GOLD, SILVER, BRONZE)
- 이탈모형(이탈, 유지)

주요기법

- 로지스틱 회귀분석(Logistic Regression)
- 의사결정나무(Decision Tree)
- 서포트 벡터 머신(Support Vector Machine, SVM)
- K 최근접 이웃(K-Nearest Neighborhood, KNN)

03 분류 분석 – 로지스틱 회귀분석

개요

- 반응변수가 범주형인 경우에 적용되는 회귀분석모형
- 새로운 설명변수(또는 예측변수)가 주어질 때 반응변수의 각 범주(또는 집단)에 속할 확률이 얼마인지를 추정(예측모형)하여, 추정 확률을 기준치에 따라 분류하는 목적(분류모형)으로 활용됨.
- 어떤 사건(Event)이 발생할 지에 대한 직접 예측이 아닌 그 사건이 발생할 확률을 예측함.
- 이때 모형의 적합을 통해 추정된 확률을 사후확률(Posterior Probability)이라고 함

정의



- $p = P(\text{성공} | k\text{개의 독립변수}), k\text{개의 독립변수가 주어졌을 때의 1인 확률}$
- $1 - p = P(\text{실패} | k\text{개의 독립변수}), k\text{개의 독립변수가 주어졌을 때의 0인 확률}$
- 예측된 확률에 따라 가능성이 더 높은 범주로 분류하는 지도학습 기반의 알고리즘으로 정리할 수 있음.

Ⅲ. 정형데이터마이닝

03 분류 분석 - 로지스틱 회귀분석

원리

- 종속변수 Y 가 범주형 변수일 경우, 일반적인 선형회귀모델로는 범주값을 추정할 수 없음. 이유는 종속변수 Y 는 1과 0으로 이루어져 있고, 선형회귀모델은 $(-)$ 무한대에서 $(+)$ 무한대 $(-\infty, \infty)$ 사이의 값을 가지기 때문임.
- 따라서 독립변수가 $(-)$ 무한대에서 $(+)$ 무한대 $(-\infty, \infty)$ 에 포함되는 어떤 숫자이든 상관없이 종속변수값이 항상 $[0, 1]$ 사이의 범위에 있도록 하거나, 범주형 변수를 $(-)$ 무한대에서 $(+)$ 무한대의 값으로 변환해 주어야 함
- 이 과정은 오즈(odds)를 로짓(Logit) 변환함으로써 정의할 수 있는 로지스틱함수(Logistic Function)를 이용하여 변환함.



Ⅲ. 정형데이터마이닝

03 분류 분석 - 로지스틱 회귀분석


Odds 정의

- 오즈는 어떤 사건이 일어날 확률을 그 사건이 일어나지 않을 확률로 나눈 값이며, 특정 사건이 발생할 확률에 대한 그 사건이 발생하지 않을 확률의 비율을 의미함.
- 종속변수 Y가 성공(1)일 때, 오즈의 값의 범위는 다음 식으로 표현되며, 오즈는 0에서 (+)무한대($0, \infty$) 사이의 값을 가지게 한다.

$$Odds(Y = 1) = \frac{p}{1-p}, p: (y = 1|x)$$

$$0 \leq \text{오즈}(Odds) \leq \infty$$

x : 독립변수, y : 종속변수



III. 정형데이터마이닝

03 분류 분석 - 로지스틱 회귀분석

Logit 정의

- 로짓은 오즈에 로그를 취한 값으로, 오즈의 비대칭성을 대칭으로 변환해주는 과정으로 정의
- 오즈의 0의 값을 무한대 값으로 변환하여 (-)무한대에서 (+)무한대($-\infty, \infty$) 사이의 값을 가지게 하며, 범주형 종속변수를 로짓변환하면 선형회귀식으로 종속 변수 Y 에 대한 값을 추정할 수 있게 됨.
- 수식

$$Odds(Y = 1) = \frac{p}{1-p}, p: (y = 1|x)$$

$$0 \leq \text{오즈}(Odds) \leq \infty$$

x : 독립변수, y : 종속변수

$$Logit(p) = Log(odds) = \log \frac{p(X)}{1-p(X)}$$

$$= \beta_0 + \beta_1 X_1 + \dots + \beta_k X_k$$

$$-\infty \leq \text{로그오즈}(Log Odds) \leq \infty$$

03 분류 분석 - 로지스틱 회귀분석

로지스틱함수(Logistic Function) 정의

- 로지스틱함수는 로짓(Logit)의 역함수이다. 즉, 음의 무한대부터 양의 무한대까지의 값을 가지는 입력변수를 0부터 1사이의 값을 가지는 출력변수로 변환하는 역할을 한다.

- 수식

$$\begin{aligned} \text{Logit}(p) &= \text{Log(odds)} = \log \frac{p(X)}{1-p(X)} \\ &= \beta_0 + \beta_1 X_1 + \dots + \beta_k X_k \\ -\infty &\leq \text{로그오즈(Log Odds)} \leq \infty \end{aligned}$$

$$\begin{aligned} \text{Logit}(p)^{-1}(\beta_0 + \beta_1 X_1 + \dots + \beta_k X_k) &= \frac{1}{1 + \exp^{-(\beta_0 + \beta_1 X_1 + \dots + \beta_k X_k)}} \\ \text{Logit}(p)^{-1}(\beta_0 + \beta_1 X_1 + \dots + \beta_k X_k) &= \text{Logistic}(z) = \frac{1}{1 + \exp^{-z}} \end{aligned}$$


$$0 \leq \text{성공확률}(P) \leq 1$$

Ⅲ. 정형데이터마이닝

03 분류 분석 - 로지스틱 회귀분석

로지스틱함수(Logistic Function) 정의

- 로지스틱함수는 로짓(Logit)의 역함수이다. 즉, 음의 무한대부터 양의 무한대까지의 값을 가지는 입력변수를 0부터 1사이의 값을 가지는 출력변수로 변환하는 역할을 한다.
- 로지스틱함수는 연결함수(Link Function)의 한 종류인 시그모이드함수(Sigmoid Function)와 동의어임을 기억하자.
- 로지스틱회귀분석 결과로 나온 각 클래스의 확률은 분류를 목적으로 할 경우 0.5를 임계값으로 사용하여 0.5보다 크면 성공(1). 0.5보다 작으면 실패(0)으로 분류할 수 있다.



Ⅲ. 정형 데이터 마이닝

03 분류 분석 – 로지스틱 회귀분석

로지스틱회귀분석의 적합성검정

- 선형회귀분석과 로지스틱회귀분석의 회귀계수 추정방법과 적합성검정방법 차이는 다음과 같다.

구분	선형회귀분석	로지스틱회귀분석
목적	연속형 종속변수값 예측	비연속형 종속변수값 범주 예측
회귀계수 추정	최소제곱법	최대가능도(우도) 추정법
회귀계수, 유의성검정	t 검정	왈드(Wald) 통계량
모델 적합도	분산분석(F 검정)	호스머 레מש, 적합도검정(카이제곱검정 사용)
모델 설명력	결정계수(R^2), 수정된 결정계수(Adjust R^2)	로그우도함수 $\log(L)=LL$ 맥파든 의사결정계수(R^2_{pseudo})

Ⅲ. 정형데이터마이닝

03 분류 분석 – 로지스틱 회귀분석

오즈비 계산

- 오즈비(Odds)는 성공할 확률이 실패할 확률의 몇 배인지를 나타내는 확률이며, 오즈비는 두 오즈의 비율임
- 2018년 한국과 독일이 월드컵 16강에 진출을 성공/실패할 확률과 각각의 오즈와 오즈비는 다음과 같음


구분	16강 성공 확률	16강 실패 확률	Odds	Odds Ratio
독일	0.8	0.2	$\frac{0.8}{(1 - 0.8)} = \frac{0.8}{0.2} = 4$	$\frac{odds(독일)}{odds(한국)} = \frac{4}{1/9} = 36$
한국	0.1	0.9	$\frac{0.1}{(1 - 0.1)} = \frac{0.1}{0.9} = \frac{1}{9}$	

- 오즈비가 36으로 나타나 독일이 16강에 진출할 확률이 한국의 16강 진출 확률보다 36배 높다고 할 수 있음

04 분류 분석 – 의사결정나무(Decision Tree)

개요


- 의사결정나무(Decision Tree)는 데이터들이 가진 속성들로부터 분할기준 속성을 판별하고, 분할기준 속성에 따라 나무 형태로 모델링하는 분류 및 예측
- 주어진 입력값에 대하여 출력값을 예측하는 모델로 분류나무(Classification Tree)모델과 회귀나무(Regression Tree) 모델이 있음



구분	로지스틱회귀분석
뿌리노드 (Root Node)	나무구조가 시작되는 노드로 전체 자료로 구성
결정노드 (Decision Node)	규칙 노드라고도 불리며, 규칙 조건을 생성하는 노드
끝노드 (Terminal Node)	자식 노드가 있는 브랜치 노드 자식노드가 없는 노드 = 가지노드(Branch Node), 리프노드(잎, Leaf Node)
서브 트리 (Sub Tree)	새로운 규칙 조건마다 생성되는 트리

III. 정형 데이터 마이닝

04 분류 분석 – 의사결정나무(Decision Tree)



장점

구분	설명
해석의 용이성	구조에 의해 모델이 표현되기 때문에 해석 쉬움, 새로운 자료에 모델을 적합시키기 쉬움, 어떤 입력변수가 중요한지 파악이 쉬움
교호작용 효과	두 개 이상의 변수가 결합하여 종속변수에 어떠한 영향을 주는지 알기 쉬움
비모수적 모델	선형성, 정규성, 등분산성의 가정이 필요치 않음. 단지 순위만 분석에 영향을 주므로 이상치에 덜 민감

단점

구분	설명
비연속성	연속형 변수를 비연속적인 값으로 취급하여 예측오류가 클 가능성이 있음
선형성 주 효과의 결여	선형 또는 주 효과 모델에서와 같은 결과를 얻지 못함
비안정성	분석용 자료에만 의존하므로 새로운 자료의 예측에 불안정함

04 분류 분석 – 의사결정나무(Decision Tree)

불순도(Impurity)와 순수도(Purity) : 노드의 분리기준

- 불순도는 다양한 범주(Factor)들의 개체(데이터)들이 얼마나 포함되어 있는가를 의미하며, 여러 가지 범주들이 섞여 있는 정도를 말함
- 순수도(Purity)는 같은 범주들끼리 얼마나 많이 포함되어 있는가를 의미
- 부모노드의 불순도보다 자식노드의 불순도는 낮은 방향으로 분리됨

04 분류 분석 – 의사결정나무(Decision Tree)

의사결정나무의 유형

- 종속변수가 범주형인 분류(Classification Tree)와 종속변수가 연속형인 회귀(Regression Tree)로 구분됨
- 분류와 회귀의 알고리즘별 분리 기준

알고리즘	분류, 분리기준 (범주형 종속변수)	회귀 분리기준 (연속형 종속변수)
CHAID(다지분리)	카이제곱통계량	분산분석(ANOVA)의 F 통계량
CART(이진분리)	지니지수	분산감소량
ID3, C4.5/C5.0	엔트로피지수	-

04 분류 분석 – 의사결정나무(Decision Tree)

의사결정나무 분류 분리 기준

가) 카이제곱통계량

- 통계량이 매우 작다 → 각 독립변수에 따른 종속변수 분포가 서로 동일, 즉 독립변수가 종속변수의 분류에 영향을 주지 않음
- 통계량이 매우 작다 → 분리된 노드가 이질적이다.
- 따라서, 카이제곱통계량이 커지고 카이제곱통계량의 p-value가 작아지는 방향으로 노드를 분리함. 즉 관측도수와 기대도수의 차이가 커질수록 노드 간의 이질성은 높아지고, 노드 내의 순수도는 높아져 좋은 분리(Split)가 됐다고 봄

04 분류 분석 – 의사결정나무(Decision Tree)

의사결정나무 분류 분리 기준

나) 지니지수(Gini Index)

- 지니지수가 0.5에 가까울수록 불순도가 높고, 0에 가까울수록 불순도 낮음
- 노드 분리 시, 불순도가 낮아지는 방향으로 분리하거나 불순도의 감소폭이 높은 쪽으로 분리함
- 양성 및 음성을 분류할 때, 예를 들어서 성별의 지니지수가 0.32, 나이의 지니지수가 0.48이라고 가정한다면, 성별로 자료는 나누는 것이 나이를 기준으로 분할하는 것보다 불순도 감소폭이 더 크기 때문에 분할에 유리함

$$\text{지니지수 (Gini Index)} = 1 - \sum_i^c p_i^2, 0 \leq G \leq \frac{1}{2}$$

c : 종속변수의 범주 수, p : 범주비율

04 분류 분석 – 의사결정나무(Decision Tree)

의사결정나무 분류 분리 기준

다) 엔트로피지수(Entropy Index)

- 엔트로피 값이 클수록 불순도가 높으며, 불순도가 클수록 자식노드 내의 이질성이 큼을 의미하기 때문에 작은 방향으로 분리함
- 엔트로피지수의 범위는 0~1 사이이며, 0에 가까울수록 노드 내의 데이터들이 동질적임을 의미함

$$\text{엔트로피지수 (Entropy Index)} = -\sum_i^c \log_2 p_i^2, 0 \leq E \leq 1$$

c : 종속변수의 범주 수, p : 범주비율

04 분류 분석 – 의사결정나무(Decision Tree)

의사결정나무 회귀 분리 기준

가) 분산분석 (ANOVA)의 F 통계량

- F통계량을 계산하는 절차는 일반적으로 많이 알려진 통계분석법인 분산분석(ANOVA)과 동일한 방법이다.
- CHIAD 알고리즘은 F통계량의 P값(P-value)을 기준으로 범주형 종속변수인 경우와 유사하게 병합과 분리를 계속하여 P값이 가장 작은 독립변수와 그때의 최적 분리에 의해서 자식노드가 형성됨
- F통계량의 P값이 자유도(유의수준)에 비해서 크다 → 독립변수의 각 범주에 따른 종속변수의 평균값 차이가 존재하지 않다는 것 의미. 따라서, 독립변수가 종속변수의 예측에 영향을 주지 않는다고 결론 내릴 수 있음
- 반대로 통계량 P값이 자유도(유의수준)에 비해서 작다는 것은 독립변수가 예측에 영향을 준다고 결론지을 수 있어, 이 때는 노드를 분리하게 된다

04 분류 분석 – 의사결정나무(Decision Tree)

의사결정나무 회귀 분리 기준

나) 분산감소량

- 특정한 노드를 분리함으로써 분산이 줄어든다는 것은 동질적 성격을 가지고 있는 개체들은 같은 집단으로 이질적 성격을 가지고 있는 개체들은 다른 집단으로 나뉘었다는 것을 의미함
- 가장 분산을 크게 감소시키는 분리조합이 최선의 분리를 이끌어 냄

05 앙상블 분석(Ensemble Analysis)

앙상블의 개념


- 주어진 자료로부터 여러 개의 예측모형들을 만든 후 예측모형들을 조합하여 하나의 최종 예측 모형을 만드는 방법으로 다중 모델 조합(Combining Multiple Models), 분류기 조합(Classifier Combination)이 있다.
- 분류분석 및 회귀분석 등 지도학습의 과적합 문제에 대한 극복방법으로 고안되었다.
- 크게 여러 알고리즘을 다양하게 구성한 앙상블 방식, 하나의 알고리즘을 사용하지만 데이터를 다양하게 구성한 앙상블 방식 2가지 방식이 있다.
- 앙상블을 활용하여 전체적인 예측값의 분산을 감소시켜, 정확도 향상(과적합 감소, 일반화 성능)을 이끌어내는 것이 주 목적이다.

05 앙상블 분석(Ensemble Analysis)

앙상블의 유형

가) 보팅(Voting)

- 다른 모델들이 각각 예측한 값을 합쳐 최종결과를 도출해내는 방법
- 하드보팅(Hard Voting) : 다수의 분류기(모델)가 예측한 결과값을 최종결과로 선정
- 소프트보팅(Soft Voting) : 모든 분류기(모델)가 예측한 레이블값의 결정 확률평균을 구한 뒤 가장 확률이 높은 레이블값을 최종결과로 선정



05 앙상블 분석(Ensemble Analysis)

앙상블의 유형

나) 배깅(Bagging)

- 주어진 데이터에서 여러 개의 부트스트랩(Bootstrap) 자료를 생성하고, 각 자료를 모델링 후 결합(Aggregating)하여 최종 예측모델을 만드는 방법
- 부트스트랩(중복 허용한 샘플링방식)으로 데이터의 다양성을 확보하여 다양한 결과를 분류 및 예측
- 종속변수가 범주형 데이터(Categorical Data): 하드보팅 적용
- 종속변수가 연속형 데이터(Continuous Data): 소프트보팅 적용
- 대표적인 배깅방식: 랜덤포레스트 알고리즘

05 앙상블 분석(Ensemble Analysis)

앙상블의 유형

다) 부스팅(Boosting)


- 배깅은 각각의 모델들이 학습 시, 상호영향을 주지 않은 상황에서(독립적) 학습이 끝난 다음 결과를 종합하는 기법
- 부스팅은 이전 모델의 학습결과를 토대로 다음 모델에서 사용할 학습 데이터의 가중치(weight)를 높게 조정(update)하여 학습을 진행하는 앙상블방법(배깅 대비 분산은 높아질 수 있으나 편향은 작아짐)
- 부스팅 종류: Adaptive Boost, Gradient Boost Machine, XGBoost, LightGBM

III. 정형 데이터 마이닝

05 앙상블 분석(Ensemble Analysis)

앙상블의 유형

나, 다) 배깅(Baggig) vs. 부스팅(Boosting)




III. 정형 데이터 마이닝

05 앙상블 분석(Ensemble Analysis)

앙상블의 유형

라) 랜덤포레스트(Random Forests)

- 배깅처럼 데이터를 복원추출할 뿐 아니라, 거기에 더해 변수 또한 랜덤(Random)하게 추출하여 다양한 모델을 만드는 앙상블 방법
- 의사결정나무의 특징인 분산이 크다는 점을 고려하여 배깅과 부스팅보다 더 많은 무작위성을 주어 여러 개의 약한 학습기들을 생성하고 이를 결합해 최종적으로 종속변수를 분류하거나 예측하는 앙상블 방법



Ⅲ. 정형 데이터 마이닝


05 앙상블 분석(Ensemble Analysis)

앙상블의 유형

마) 스택킹(Stacked Generalization)

- 배깅이나 부스팅과는 달리 일반적으로 서로 다른 타입의 모델들을 사용하여 예측값을 도출하고 이 예측값이 학습 데이터가 되어 '또 다른 모델'을 학습시켜 최종결과를 도출하는 앙상블방법(보팅이 아닌 메타러너 사용)

- 1단계 : 원본 데이터를 n개의 모델을 훈련시켜 예측값 산출
- 2단계 : 각 예측값은 메타러너(Meta Learner, 블렌더)의 입력값으로 정의. 메타러너는 또다른 모델로 Level1의 모델들의 예측값으로 학습. 메타러너는 최종 예측값 도출



III. 정형 데이터 마이닝

06 인공지능망 분석(Artificial Neural Network)

기본 개념

ANN 연구 역사

- (1943) 매컬렉(McCulloch)과 피츠(Pitts) : 인간의 뇌를 수많은 신경세포가 연결된 하나의 디지털 네트워크 모형으로 간주하고 신경세포의 신호처리 과정을 모형화하여 단순 패턴분류 모형을 개발
- (1949) 헵(Hebb) : 신경세포(뉴런) 사이의 연결강도(Weight)를 조정하여 학습규칙을 개발
- (1955) 로젠블랫(Rosenblatt) : 퍼셉트론(Perceptron)이라는 인공세포 개발
- 비선형성의 한계점 발생 : XOR(Exclusive OR, 배타적 논리합) 문제를 풀지 못하는 한계 발견
- (1986) 러멜하트(Rumelhart), 힌튼(Hinton) : 역전파알고리즘(Backpropagation)을 활용하여 비선형성을 극복한 다계층 퍼셉트론으로 새로운 인공지능망 모형 등장

Ⅲ. 정형 데이터 마이닝

06 인공지능망 분석(Artificial Neural Network)

기본 개념

ANN 학습

- 신경망은 가중치를 반복적으로 조정하며 학습함
- 인공 신경망은 신경망의 가중치를 초기화하고 훈련 데이터를 통해 가중치를 갱신하여 신경망의 구조를 선택하고, 활용할 학습 알고리즘을 결정한 후 신경망을 훈련시킴

ANN 주요 용어

- 퍼셉트론(Perceptron)
- 다층퍼셉트론(Multi Layer Perceptron)
- 역전파 알고리즘(Back Propagation)
- 손실함수(Loss Function) = 비용함수(Cost Function)
- 인공신경망 활성화함수(Activation Function)
- 기울기 소멸 문제(Vanishing Gradient Problem)


Ⅲ. 정형 데이터 마이닝

06 인공지능망 분석(Artificial Neural Network)

주요 용어

퍼셉트론(Perceptron)

- 목표값(Ideal)을 정하고 현재 계산된 값(Output)이 목표값과 다르면 그 만큼의 오차를 다시 퍼셉트론에 반영하여 오차를 줄여나가는 알고리즘
- 인간의 신경망과 유사하게 만든 입력층, 출력층으로 구성되어 학습능력을 가진 신경망 모델로 정의
- 퍼셉트론에서는 활성화함수(Activation Function, 출력제한함수)가 순 입력함수(Linear Combination)의 반환값을 임계값과 비교하여 그 결과에 따라 1 또는 -1을 출력함
- 퍼셉트론의 가중치 업데이트는 학습 데이터에 대한 활성화함수(Active Function)의 리턴값과 학습 데이터의 실제 결괏값이 같은지 다른지에 따라 이루어짐



06 인공지능망 분석(Artificial Neural Network)

주요 용어

XOR 문제 (exclusive OR)

- 논리 연산을 통해 문제를 해결하는 ANN은 XOR 게이트 문제를 해결하지 못함


AND 진리표			OR 진리표			XOR 진리표		
$x1$	$x2$	결괏값	$x1$	$x2$	결괏값	$x1$	$x2$	결괏값
0	0	0	0	0	0	0	0	0
0	1	0	0	1	1	0	1	1
1	0	0	1	0	1	1	0	1
1	1	1	1	1	1	1	1	0

06 인공신경망 분석(Artificial Neural Network)

주요 용어

XOR 문제 (exclusive OR)

- 논리 연산을 통해 문제를 해결하는 ANN은 XOR 게이트 문제를 해결하지 못함




Copyright © Gilbut, Inc. All rights reserved.

06 인공지능망 분석(Artificial Neural Network)

주요 용어

다층퍼셉트론(Multi Layer Perceptron)

- 다층퍼셉트론을 사용하면 여러 개의 선으로 분류하는 효과를 얻을 수 있기 때문에 XOR의 분류문제를 해결할 수 있게 됨.
- 다층퍼셉트론은 중간에 은닉층(Hidden Layer)이라 불리는 층을 더 추가함
- 은닉층이 존재할 경우, XOR 게이트는 기존의 AND, OR 게이트의 조합으로 만들 수 있기 때문에 퍼셉트론에서 층을 추가하면서 만들 수 있다.
- 각 층에서 발생하는 오차는 역전파 알고리즘(Back Propagation)을 통해 업데이트해 나간다.





III. 정형데이터마이닝

06 인공지능망 분석(Artificial Neural Network)

주요 용어

역전파 알고리즘(Back Propagation)

- 다층퍼셉트론(MLP) 구조를 이용해 어떤 결과가 예측되었을 때 그 예측이 틀리다면 은닉층 노드들의 오차를 확인하고 오차가 작아지는 방향으로 역전파(Backward)시켜 가중치와 편향값을 학습시키는 신경망을 제안하여 XOR문제를 해결함.
- 딥러닝(Deep Learning)의 가중치 학습의 개념 정립
- 속도는 느리지만, 모델의 안정적인 결과를 얻을 수 있는 장점
- MLP 은닉층 학습한계 해결(XOR 문제 해결)




III. 정형 데이터 마이닝

06 인공지능망 분석(Artificial Neural Network)

주요 용어

손실함수(Loss Function) = 비용함수(Cost Function)

- 모델이 예측한 값과 실제 정답의 차이를 비교하기 위한 함수
- '학습 중에 알고리즘이 얼마나 잘못 예측하는 정도'를 확인하기 위한 함수로서 파라미터를 최적화(Optimization)하기 위해 손실점수(Loss Score)를 최소화하는 것이 목적
- 오차값 조정하여 파라미터(가중치) 조정할 수 있게 학습 알고리즘으로 전달
- 손실점수를 파라미터(가중치)에 최적화시키기 위한 알고리즘으로 경사하강법(Gradient Descent) 등을 사용함







06 인공지능망 분석(Artificial Neural Network)

주요 용어

인공신경망 활성화함수(Activation Function)

- 입력된 데이터의 가중합을 출력신호로 변환, 은닉층의 출력값을 특정 범위의 실수값으로 정규화, 은닉층과 출력층에서 각 출력값을 제한하기 위해 사용됨
- 과거 퍼셉트론은 입력과 가중치들의 곱을 모두 더한 뒤 활성화함수를 적용해서 그 값이 0보다 크면 1, 0보다 작으면 -1을 출력하는 선형분류기의 구조였음
- 활성화 함수를 이용해 출력을 결정하며 입력신호의 가중치 합을 계산하여 임계값과 비교



Ⅲ. 정형 데이터 마이닝

06 인공지능망 분석(Artificial Neural Network)

주요 용어

인공신경망 활성화함수(Activation Function)

구분	수식	설명
부호 (Sign Function)	$y = -1(if, x < 0)$ $y = +1(if, x \geq 0)$	입력의 가중값 x 가 0보다 크면 1, 작으면 0을 출력
시그모이드 (Sigmoid Function)	$y = \frac{1}{1 + e^{-x}}$	0과 1사이의 범위의 값을 출력하는 함수
하이퍼볼릭탄젠트 (Hyperbolic Tangent Function)	$y = \tanh(x)$	시그모이드 함수와 유사하게 -1과 1사이 범위의 값을 출력하는 함수
렐루(ReLU) (Rectified Linear Unit Function)	$y = 0(if, x < 0)$ $y = x(if, x \geq 0)$	x 값이 음수일 경우 0을 출력하고 양수이면 입력값 그대로 출력

06 인공지능망 분석(Artificial Neural Network)

주요 용어

인공신경망 활성화함수(Activation Function) – 소프트맥스 함수 (Softmax Function)

시나리오		설명
[1.2]	[0.46]	각 output node의 출력값을 0~1로 제한
[0.9]	→ [Softmax Function] → [0.34]	($0 < softmax(x) < 1$ 사이 실수값)
[0.4]	[0.20]	각 클래스의 출력의 모든 합은 항상 1
	합계 : 1	$y_i = \frac{\exp(z_j)}{\sum_{i=1}^L \exp(z_i)}, j = 1, \dots, L$

Ⅲ. 정형데이터마이닝

06 인공지능망 분석(Artificial Neural Network)

주요 용어

기울기 소멸 문제(Vanishing Gradient Problem) 및 해결방법

- 기울기 소멸 문제란 역전파 알고리즘으로 가중치를 수정할 때, 은닉층으로 오차가 거의 전달되지 않는 문제.
- 활성화함수의 출력값이 곱해지다 보면 가중치에 따른 결과값의 기울기가 0이 되어, 경사하강법을 이용할 수 없게 되는 문제라 정의할 수 있음
- 기울기 소멸 문제의 주요 발생원인은 다음과 같이 정리됨

구분	설명
시그모이드 함수	시그모이드 함수는 0과 1사이의 값 출력 역전파 알고리즘 수행 위해 경사하강법을 이용하여 은닉층의 출력값을 반복적으로 미분하면 0에 가까운 값이 되어 가중치를 학습하지 못함
초기 파라미터(가중치) 정확도 낮음	초기 파라미터(가중치) 정확도가 낮아, 가중치가 모델에 적합되기 위해 많은 학습량 필요
연산량 부족	당시(1980~1990년대)의 컴퓨팅 파워로는 모델을 적합시키기 위해서 무한한 시간 필요 알고리즘의 활용 한계로 불필요한 인공지능망 노드를 모두 학습하여 연산량을 증가시킴

06 **인공신경망 분석(Artificial Neural Network)**

주요 용어

딥러닝(Deep Learning)

- 인공신경망은 학습과정에서 최적의 파라미터를 찾기 어렵고 학습시간이 느린 문제가 존재
- 인공신경망의 여러 문제가 해결되면서 모델 내 은닉층을 늘려 학습의 결과를 향상시키는 방법이 등장함.
- 이를 심층신경망(Deep Neural Network, DNN)이라고 함
- 심층 신경망은 은닉층을 2개 이상 지닌 학습 방법을 뜻하며 컴퓨터가 스스로 분류 레이블을 만들어내고, 데이터를 구분짓는 과정을 반복하여 최적의 구분선을 도출함
- 심층 신경망, 합성곱 신경망, 순환신경망, 장단기 메모리신경망, 생성적 적대신경망, GPT

Ⅲ. 정형데이터마이닝

07 군집 분석(Clustering Analysis)

개요

- 군집분석은 여러 개체(데이터) 중에서 유사한 속성을 지닌 대상을 몇 개의 집단으로 그룹화한 다음, 각 집단의 성격을 파악함으로써 데이터 전체의 구조에 대해 이해하고자 하는 탐색적 분석방법(비지도학습)
- 군집분석의 장단점은 다음과 같이 요약할 수 있다.

구분	설명
장점	- 탐색적인 기법 - 다양한 형태 데이터에 적용 가능
단점	- 분석 - 분석가에 의해 결과가 달라질 수 있음 - 가중치 및 거리의 정의가 어려움 - 초기 군집 수 K 결정이 어려움(비계층적 군집화)

Ⅲ. 정형 데이터 마이닝

07 군집 분석(Clustering Analysis)

척도

- 군집분석은 데이터의 유사한 혹은 동질의 군집(Cluster)화 작업이기 때문에 데이터 간 유사성을 판단해야 함

비유사도(거리 기반 척도, **Distance**, 연속형 변수)

- 비 유사도는 두 데이터(개체)의 다른 정도에 대한 수치적인 척도로 두 데이터의 쌍이 더 닮을수록 유사함

- 두 데이터의 쌍의 떨어진 정도가 크다는 것은 서로 거리가 멀다는 것을 나타내며, 이는 유사하지 않다는 것을 의미한다. 거리(Distance)는 비유사도와 동의어, 하한값은 0 상한값은 제한이 없음

유사도(**Similarity**, 범주형 변수)

- 유사도는 두 데이터(개체)의 닮은 정도에 대한 수치적인 척도로 음이 아닌 수, 0과 1사이의 값으로 표현할 수 있는 척도

- 1에 가까우면 유사함을 의미하고 0에 가까우면 유사하지 않음을 의미

Ⅲ. 정형 데이터 마이닝

07 군집 분석(Clustering Analysis)

비유사도 거리 종류

구분	설명
유클리디안 거리 (Euclidean Distance)	데이터간의 유사성을 측정할 때 많이 사용하는 거리. 통계적 개념이 내포되어 있지 않아 변수들의 산포 정도가 전혀 감안되어 있지 않음
표준화 거리 (Statistical Distance)	해당변수의 표준편차로 척도 변환한 후 유클리디안 거리를 계산하는 방법. 표준화하게 되면 척도의 차이, 분산의 차이로 인한 왜곡을 피할 수 있음
마할라노비스 거리 (Mahalanobis)	통계적 개념이 포함된 거리이며 변수들의 산포를 고려하여 이를 표준화한 거리(Standardized Distance). 변수의 표준편차와 더불어 변수 간 상관성(Correlation)까지 고려한 거리척도 표준편차 σ 가 1이면 마할라노비스거리는 유클리드거리와 같음
맨하탄 거리 (Manhattan)	좌표간의 차이를 절대값으로 계산. 유클리디안 거리와 함께 가장 많이 사용되는 거리로 맨하탄 도시에서 건물에서 건물을 가기 위한 최단 거리를 구하기 위해 고안된 거리
민코우스키 거리 (Minkowski)	맨하탄 거리와 유클리디안 거리를 한번에 표현한 거리 척도. L1 거리(맨하탄거리), L2 거리(유클리디안 거리)

Ⅲ. 정형 데이터 마이닝

07 군집 분석(Clustering Analysis)

유사도 거리 종류

구분	설명
코사인 유사도 (Cosine Similarity)	벡터와 벡터 간의 유사도를 비교할 때 두 벡터간의 사이각을 구해서 얼마나 유사한지를 수치로 나타낸 척도 벡터방향이 동일한 방향이면 서로 유사 (1) 벡터방향이 90도 일때는 관련성이 없음 (0)) 벡터방향이 180도, 반대 관계이면 (-1) 코사인거리 : 코사인유사도를 코사인거리로 변환하기 위해 1에서 코사인유사도 값을 빼줌
자카드 유사도 (Jaccard Similarity)	두 문장을 각각 단어의 집합으로 만든 뒤, 두 집합을 통해 유사도를 측정하는 방식 자카드거리 : 1에서 자카드 유사도를 빼줌

07 군집 분석(Clustering Analysis)

군집분석(Clustering Analysis) 유형

- 군집 안의 부분 군집 존재유무에 따라, 부분집합이 존재하면 계층적 군집(Hierarchical Clustering), 그렇지 않으면 비계층적 군집(Non-Hierarchical Clustering)으로 나뉨

계층적 군집(Hierarchical Clustering)

- 계층적 군집은 여러 개의 군집 중에서 가장 유사도가 높은 혹은 거리가 가까운 군집 두개를 선택하여 하나로 합치면서 군집 개수를 줄여나감
- 계층적 군집 방법은 응집형방법(Agglomerative, Bottom-Up Method)과 분리형방법(Divisive, Top-Down Method)이 존재하지만, 일반적으로는 응집형방법을 주로 사용함
- 계층적 군집을 시각화하는 방법으로 덴드로그램(Dendrogram)을 활용하여, 가까운 두 데이터(개체) 혹은 데이터와 군집을 묶어 가면서 군집을 이루어나가는 과정을 시각화할 수 있음
- 덴드로그램을 보고 군집의 개수를 변화해 가면서 적절한 군집수를 선정한다.
- 군집의 수는 분석 목적에 따라 선정할 수 있지만 대부분 5개 이상의 군집은 잘 활용하지 않는다.

07 군집 분석(Clustering Analysis)

군집분석(Clustering Analysis) 유형

- 군집 안의 부분 군집 존재유무에 따라, 부분집합이 존재하면 계층적 군집(Hierarchical Clustering), 그렇지 않으면 비계층적 군집(Non-Hierarchical Clustering)으로 나뉨

계층적 군집(Hierarchical Clustering)

구분	설명
최단연결법 (Single Linkage)	- $n \times n$ 거리행렬에서 거리가 가장 가까운 데이터를 묶은 후 군집 형성 - 군집과 군집 또는 데이터와 거리 계산 시 최단거리(min)를 거리로 계산하여 거리행렬 수정을 진행 후 가장 가까운 데이터를 군집으로 형성
최장연결법 (Complete Linkage)	- 군집과 군집 또는 데이터와의 거리를 계산할 때 최장거리(max)를 거리로 계산하여 거리행렬을 수정하는 방법
평균연결법 (Average Linkage)	- 군집과 군집 또는 데이터와의 거리를 계산할 때 평균(mean)을 거리로 계산하여 거리행렬을 수정하는 방법

07 군집 분석(Clustering Analysis)

군집분석(Clustering Analysis) 유형

- 군집 안의 부분 군집 존재유무에 따라, 부분집합이 존재하면 계층적 군집(Hierarchical Clustering), 그렇지 않으면 비계층적 군집(Non-Hierarchical Clustering)으로 나뉨

계층적 군집(Hierarchical Clustering)

구분	설명
중심연결법 (Centroid Linkage)	- 두 군집의 중심 간의 거리를 측정 - 두 군집이 결합될 때 새로운 군집의 평균근 가중 평균을 통해 구함 - 계산량이 적고, 중심 사이의 거리를 한 번만 계산
와드 연결법 (Ward Linkage)	- 군집 내 편차들의 제곱합을 고려한 방법 - 병합된 군집의 오차제곱합이 병합 이전 군집의 오차제곱합에 비해 증가한 정도가 작아지는 방향으로 군집을 형성 - 군집 간 정보의 손실을 최소화하기 위해 군집화를 진행

Ⅲ. 정형 데이터 마이닝


07 군집 분석(Clustering Analysis)

군집분석(Clustering Analysis) 유형

- 군집 안의 부분 군집 존재유무에 따라, 부분집합이 존재하면 계층적 군집(Hierarchical Clustering), 그렇지 않으면 비계층적 군집(Non-Hierarchical Clustering)으로 나뉨

덴드로그램(Dendrogram)

- 덴드로그램을 보고 군집의 개수를 변화해 가면서 적절한 군집수를 선정한다.
- 군집의 수는 분석 목적에 따라 선정할 수 있지만 대부분 5개 이상의 군집은 잘 활용하지 않는다.



Ⅲ. 정형 데이터 마이닝

07 군집 분석(Clustering Analysis)

군집분석(Clustering Analysis) 유형

- 군집 안의 부분 군집 존재유무에 따라, 부분집합이 존재하면 계층적 군집(Hierarchical Clustering), 그렇지 않으면 비계층적 군집(Non-Hierarchical Clustering)으로 나뉨

비 계층적 군집(Non Hierarchical Clustering)

구분	설명
프로토타입 기반 군집 (Prototype)	미리 정해 놓은 각 군집에 각 데이터(개체)가 얼마나 유사한가를 가지고 군집 예) K-평균 군집 알고리즘, K-중앙개체군집 알고리즘
분포 기반 군집 (Distribution)	각 데이터가 혼합분포 중 어느 모형으로부터 나왔을 확률이 높은지에 따라 군집 예) 기대값 최대화 알고리즘
밀도 기반 군집 (Density)	서로 근접하게 분포할 것이라는 가정을 기반으로 군집 예) DBSCAN 알고리즘
그래프 기반 군집 (Graph)	신경망 기술을 활용하여 고차원의 데이터를 저차원의 뉴런으로 정렬, 지도의 형태로 형상화해서 군집 예) 자기조직화지도 알고리즘

07 군집 분석(Clustering Analysis)

비 계층적 군집(Non-Hierarchical Clustering)

1) 프로토타입 기반 군집, K-Means Clustering

- n 개의 데이터를 K 개의 군집으로 분류하기 위해 거리 기반으로 반복적으로 계산해 나가는 군집 알고리즘
- 다음과 같은 목적 함수 값이 최소화될 때까지 군집의 중심위치와 각 데이터가 소속될 군집을 반복해서 찾음. 이 값을 관성(Inertia)라 함
- 비유사도 측정은 일반적으로 유클리드거리를 사용함
- K-Means 알고리즘의 특징은 거리 기반, 중심점(Centroid)의 사용, 데이터 양자화, 반복적 최적해 산출로 요약할 수 있으며, 활용사례는 다음과 같음

장점	단점
✓ 구현이 간단하고 군집이 직관적임	✓ 초기 군집에 민감하여 결과 다를 수 있음
✓ 대용량 데이터에도 적용 가능	✓ 클러스터 수를 사용자가 지정
✓ 대체로 빠른 수행속도	✓ 군집중심이 선택되는 초기 위치에 따라 속도 느릴 수 있음
✓ 군집결과를 해석하기 쉬움	✓ 이상값/노이즈에 민감
✓ 유클리드거리 등 다양한 거리 측정방법 사용	✓ 볼록체(Convex Hull) 모양이 아닌 데이터셋에도 정확도 떨어짐 (예: 초승달 모양 데이터셋)

07 군집 분석(Clustering Analysis)


비 계층적 군집(Non-Hierarchical Clustering)

2) 프로토타입 기반 군집, K-Medoids Clustering

- K-Means Clustering 알고리즘이 극도로 큰 값(혹은 작은 값)에 의해 데이터 분포를 사실상 왜곡할 수 있기 때문에 이상값(노이즈)에 민감한 단점을 개선한 알고리즘
- 군집에서 객체들의 평균값을 취하는 대신에 군집에서 가장 중심에 위치한 객체인 Medoid를 사용하여 n 개의 객체(데이터)중에서 k 개의 군집을 찾음
- 실데이터 중심점으로 노이즈 처리가 우수한 것이 장점인 반면, K-Means 알고리즘에 비해 연산량이 많다.

07 군집 분석(Clustering Analysis)

K-Means Clustering vs K-Medoids Clustering



07 군집 분석(Clustering Analysis)

비 계층적 군집(Non-Hierarchical Clustering)

3) 분포 기반 군집, 기대값 최대화(Expectation-Maximization, EM)

- EM 알고리즘은 관측되지 않는 잠재변수에 의존하는 확률모델에서 최대가능도(Maximum Likelihood)나 최대사후확률(Maximum a Posteriori)을 갖는 매개변수를 찾는 반복적 알고리즘
- 매개변수에 관한 추정값으로 로그가능도(Log Likelihood)의 기대값을 계산하는 기대값(E)단계와 이 기대값을 최대화하는 최대화(M) 단계를 반복 적용
- 확률적 적합성 평가. Likelihood의 값 최대화가 목표
- 가능도 값이 일정값 수준으로 향상되면 로그함수로 종료평가 수렴 허용
- 가우시안 정규분포(Gaussian Mixture Model) 적용
- 데이터 집합이 여러 개의 분포에서 생성된 것 가정, 각 분포 확률밀도함수 추정

Ⅲ. 정형 데이터 마이닝

07 군집 분석(Clustering Analysis)

비 계층적 군집(Non-Hierarchical Clustering)

4) 밀도 기반 군집, DBSCAN

- DBSCAN(Density Based Spatial Clustering of Application with Noise) 알고리즘은 어느 점을 기준으로 반경 x 내에 점이 n 개 이상 있으면 하나의 군집으로 인식하는 방식
- 군집 수를 미리 정하지 않아도 되는 장점이 존재
- 군집의 밀도를 사용해 기하학적 모양을 가지는 군집도 찾을 수 있으며, 잡음포인트(Noise Point)를 통해 이상값(Outlier) 검출이 용이함

구분	설명
핵심포인트 (Core Point)	일정 기준 이상의 밀도를 갖는 데이터 핵심(Core)에서 핵심(Core)으로 탐색
잡음포인트 (Noise Point)	일정 기준 미만의 밀도를 가지고, 군집에도 속하지 않는 데이터(점)
경계포인트 (Border Point)	일정 기준 미만의 밀도를 갖고 있지만, 군집에 속하지 않는 데이터 경계(Border)를 만나면 군집에서 탐색 중지
엡실론 주변 영역 (Epsilon)	주어진 개체들의 반경. 밀도는 엡실론 안에 있는 다른 좌표점의 수
최소 데이터 개수 (Min Points)	엡실론 반경 내 군집 위해 필요한 객체 수. 어떤 좌표점이 군집을 형성할 수 있는 최소 좌표점의 수

07 군집 분석(Clustering Analysis)

비 계층적 군집(Non-Hierarchical Clustering)

5) 그래프 기반 군집, 자기조직화지도(Self-Organizing Map, SOM)

- 코호넨(Kohonen)에 의해 제시 및 개발됨
- SOM은 비지도 신경망으로 고차원의 데이터를 이해하기 쉬운 저차원의 뉴런으로 정렬하여 지도의 형태로 형상화
- SOM 모델은 위의 그림과 같이 두 개의 인공신경망 층으로 구성 (입력층, 경쟁층)
- 입력 벡터의 특성에 따라 벡터가 한 점으로 클러스터링되는 경쟁신경망(Competitive Network) 이용하여, 승자전유(Winner-Take-All)과정을 통해 입력벡터에 가장 가까운 가중치벡터를 가지는 노드를 승자로 선언
- 그 값이 입력벡터에 더 가까워지도록 가중치 조정
- 입력 변수의 위치 관계를 그대로 보존하기 때문에 실제 데이터가 유사하면 지도상에서 가깝게 표현.


07 군집 분석(Clustering Analysis)

비 계층적 군집(Non-Hierarchical Clustering)

5) 그래프 기반 군집, 자기조직화지도(Self-Organizing Map, SOM)

- 신경망 모형과 SOM의 차이점

평가항목	신경망 모형	SOM
학습 방법	오차역전파법	경쟁학습방법
구성	입력층, 은닉층, 출력층	입력층, 2차원 격자(Grid) 형태의 경쟁층
기계학습 방법	지도학습 (Supervised Learning)	비지도 학습 (Unsupervised Learning)



『SOM』

III. 정형 데이터 마이닝

08 연관성 분석(Association Analysis)

기본 개념 및 형태

기본 개념

- 연관성 분석은 흔히 장바구니분석 또는 서열분석이라고 불린다.
- 기업의 데이터베이스에서 상품의 구매, 서비스 등 일련의 거래 또는 사건들 간의 규칙을 발견하기 위해 적용한다.
- 장바구니 분석: '장바구니에 무엇이 같이 들어 있는지에 대한 분석'
- 서열 분석: 'A를 산 다음에 B를 산다.'

연관규칙의 형태

- 조건과 반응의 형태(if-then)로 이루어져 있다.

(Item set A) → (Item set B)

If A then B : 만일 A가 일어나면 B가 일어난다.

- '아메리카노를 마시는 손님 중 10%가 브라우니를 먹는다.'
- '샌드위치를 먹는 고객의 30%가 탄산수를 함께 마신다.'

08 연관성 분석(Association Analysis)

연관규칙의 측도

- 산업의 특성에 따라 지지도, 신뢰도, 향상도 값을 잘 보고 규칙을 선택해야 한다.

1) 지지도(Support)

- 전체 거래 중 항목 A와 항목 B를 동시에 포함하는 거래의 비율로 정의한다.

- 1에 가까울수록 동시 포함

$$\text{지지도} = P(A \cap B) = \frac{\text{A와 B가 동시에 포함된 거래수}}{\text{전체 거래수}} = \frac{A \cap B}{\text{전체}}$$

08 연관성 분석(Association Analysis)

연관규칙의 측도

- 산업의 특성에 따라 지지도, 신뢰도, 향상도 값을 잘 보고 규칙을 선택해야 한다.

2) 신뢰도(Confidence)

- 항목 A를 포함한 거래 중에서 항목 A와 항목 B가 같이 포함될 확률이다. 연관성의 정도를 파악할 수 있다.
- 1에 가까울수록 품목 A와 품목 B는 동시 포함

$$\text{신뢰도} = \frac{P(A \cap B)}{P(A)} = \frac{A \text{와 } B \text{가 동시에 포함된 거래수}}{A \text{를 포함하는 거래수}} = \frac{\text{지지도}}{P(A)}$$

08 연관성 분석(Association Analysis)

연관규칙의 측도

- 산업의 특성에 따라 지지도, 신뢰도, 향상도 값을 잘 보고 규칙을 선택해야 한다.

3) 향상도(Lift)

- A가 구매되지 않았을 때 품목 B의 구매확률에 비해 A가 구매됐을 때 품목 B의 구매확률이 증가 비이다. 연관규칙 $A \rightarrow B$ 는 품목 A와 품목 B의 구매가 서로 관련이 없는 경우에 향상도가 1이 된다.

구분	절차
향상도 = 1	독립에 가까운 관계
향상도 > 1	양의 상관관계(데이터 간 연관성 높음)
향상도 < 1	음의 상관관계(데이터 간 연관성 낮음)

$$\begin{aligned}\text{향상도} &= \frac{P(B|A)}{P(B)} = \frac{P(A \cap B)}{P(A) \times P(B)} = \frac{A \text{와 } B \text{가 동시에 포함된 거래수}}{A \text{를 포함하는 거래수} \times B \text{를 포함하는 거래수}} \\ &= \frac{\text{신뢰도}}{P(B)}\end{aligned}$$

Ⅲ. 정형데이터마이닝

08 연관성 분석(Association Analysis)

연관분석 사례

- 산업의 특성에 따라 지지도, 신뢰도, 향상도 값을 잘 보고 규칙을 선택해야 한다.
- 향상도 1.33은 1보다 크므로 기저귀(A)와 맥주(Y)는 양의 상관관계를 가짐(연관성 높음)

거래번호	구매상품		구분	설명	계산식
1	기저귀, 맥주, 빵	➔	지지도	전체 거래 4건 중 기저귀(A)와 맥주(B)를 동시에 구입한 거래는 2건	$P(A \cap B) = \frac{2}{4} = 0.5$
2	기저귀, 맥주		신뢰도	기저귀(A)가 구매되었을 때, 맥주(B)가 추가로 구매될 확률	$\frac{P(A \cap B)}{P(A)} = \frac{0.5}{\frac{3}{4} = 0.75} = 0.67$
3	기저귀, 빵, 음료수		향상도	기저귀(A)를 구매할 때, 맥주(B)도 구매하는지 서로 간의 연관성을 파악	$\frac{P(A \cap B)}{P(A) \times P(B)} = \frac{0.5}{0.75 \times 0.5} = 1.33$
4	빵, 음료수, 커피				

『기저귀와 맥주의 연관분석』

08 연관성 분석(Association Analysis)

『기저귀와 맥주의 연관분석』

연관분석 사례

거래번호	구매상품
1	A, F
2	A, C, E, F
3	A, C, D, F
4	A, C, F
5	B, E, F

항목	거래수	지지도
A	4	80
C	3	60
F	5	100
A, C	3	60
A, F	4	80
C, F	3	60
A, C, F	3	60

항목	지지도	P(A)	신뢰도	향상도
$A \rightarrow C$	60	80	0.75	1.25
$C \rightarrow A$	60	60	1	1.25
$A \rightarrow F$	80	80	1	1
$F \rightarrow A$	80	100	0.8	1
$A \rightarrow C, F$	60	80	0.75	1.25
$C, F \rightarrow A$	60	60	1	1.25
$C \rightarrow F$	60	60	1	1
$F \rightarrow C$	60	100	0.6	1
$C \rightarrow A, F$	60	60	1	1.25
$A, F \rightarrow C$	60	80	0.75	1.25
$F \rightarrow A, C$	60	100	0.6	1
$A, C \rightarrow F$	60	60	1	1

Ⅲ. 정형 데이터 마이닝

08 연관성 분석(Association Analysis)

연관규칙 절차

- 최소 지지도보다 큰 집합만을 대상으로 높은 지지도를 갖는 품목 집합을 찾는 것이다.
- 처음에는 5%로 잡고 규칙이 충분히 도출되는지를 보고 다양하게 조절하여 시도한다.
- 처음부터 너무 낮은 최소 지지도를 선정하는 것은 많은 리소스가 소모되므로 적절하지 않다.

단계	절차
1단계	최소 지지도 결정
2단계	품목 중 최소 지지도를 넘는 품목 분류
3단계	2가지 품목 집합 생성
4단계	반복적으로 수행해 빈발품목 집합을 찾음

08 연관성 분석(Association Analysis)

연관규칙 장단점

장점

- 탐색적인 기법으로 조건 반응으로 표현되는 연관성 분석의 결과를 쉽게 이해할 수 있다.
- 강력한 비목적성 분석기법으로 분석 방향이나 목적이 특별히 없는 경우 목적변수가 없으므로 유용하게 활용된다.
- 사용이 편리한 분석 데이터의 형태로 거래 내용에 대한 데이터를 변환 없이 그 자체로 이용할 수 있는 간단한 자료 구조를 갖는다.
- 분석을 위한 계산이 간단하다.

08 연관성 분석(Association Analysis)

연관규칙 장단점

단점 및 개선방안

단점	개선방안
품목수가 증가하면 분석에 필요한 계산은 기하급수적으로 늘어난다.	• 이를 개선하기 위해 유사한 품목을 한 범주로 일반화한다. • 연관규칙의 신뢰도 하한을 새롭게 정의해 실제 드물게 관찰되는 의미가 적은 연관규칙은 제외한다.
너무 세분화한 품목을 갖고 연관성 규칙을 찾으면 의미 없는 분석 가능성	• 적절히 구분되는 큰 범주로 구분해 전체분석에 포함시킨 후 그 결과 중에서 세부적으로 연관규칙을 찾는 작업을 수행할 수 있다.
거래량이 적은 품목은 당연히 포함된 거래수가 적을 것이고, 규칙 발견 시 제외하기 쉽다.	• 이런 경우, 그 품목이 관련성을 살펴보고자 하는 중요한 품목이라면 유사한 품목들과 함께 범주로 구성하는 방법 등을 통해 연관성 규칙의 과정에 포함시킬 수 있다.

08 연관성 분석(Association Analysis)

최근 연관성 분석 동향

- 거래 내역에 포함되어 있는 모든 품목의 개수가 n 개일 때, 품목들의 전체집합에서 추출할 수 있는 품목 부분집합의 개수는 $2^n - 1$ (공집합 제외)개다. 그리고 가능한 모든 연관규칙의 개수는 $3^n - 2^{n+1} + 1$ 개다.
- 이 때 모든 가능한 품목 부분집합의 개수를 줄이는 방식으로 작동하는 것이 Apriori 알고리즘이며, 거래내역 안에 포함된 품목의 개수를 줄여 비교하는 횟수를 줄이는 방식으로 작동하는 것이 FP-Growth 알고리즘이다.

Apriori 알고리즘(선형적 규칙 알고리즘)

- 전체 항목(Item)에서 최소 N 번의 트랜잭션(사건, 거래)이 일어난 항목집합들을 발견하는 알고리즘.
- 최소 지지도보다 큰 지지도 값을 갖는 품목의 집합을 빈발항목집합이라고 한다. 최소 지지도 이상의 빈발항목집합을 찾은 후 그것들에 대해서만 연관규칙을 계산
- 만약, K 개의 품목이 존재한다고 할 때, 조합이 가능한 품목집합은 2^K 개 존재
- K 가 아주 크다면 이 모든 집합 중에 지지도가 높은 집합을 찾아 연관성을 분석하는 것은 현실적으로 불가능
- 따라서, 비빈발항목집합(전체)에서 빈발항목집합을 도출하게 됨

08 연관성 분석(Association Analysis)

최근 연관성 분석 동향

- 거래 내역에 포함되어 있는 모든 품목의 개수가 n 개일 때, 품목들의 전체집합에서 추출할 수 있는 품목 부분집합의 개수는 $2^n - 1$ (공집합 제외)개다. 그리고 가능한 모든 연관규칙의 개수는 $3^n - 2^{n+1} + 1$ 개다.
- 이 때 모든 가능한 품목 부분집합의 개수를 줄이는 방식으로 작동하는 것이 Apriori 알고리즘이며, 거래내역 안에 포함된 품목의 개수를 줄여 비교하는 횟수를 줄이는 방식으로 작동하는 것이 FP-Growth 알고리즘이다.

Apriori 알고리즘(선형적 규칙 알고리즘)

구분	과정	설명
규칙	규칙1	한 항목집합이 빈발항목이면, 모든 부분집합은 빈발항목
	규칙2	한 항목집합이 빈발항목이면, 모든 부분집합은 비빈발항목
알고리즘	조인(Join)	항목집합을 생성하기 위해 항목을 결합하는 과정
	가지치기(Pruning)	생성된 항목집합이 최소지지도를 만족하지 못한 경우 부분집합까지 삭제하는 과정

08 연관성 분석(Association Analysis)

최근 연관성 분석 동향

- 거래 내역에 포함되어 있는 모든 품목의 개수가 n 개일 때, 품목들의 전체집합에서 추출할 수 있는 품목 부분집합의 개수는 $2^n - 1$ (공집합 제외)개다. 그리고 가능한 모든 연관규칙의 개수는 $3^n - 2^{n+1} + 1$ 개다.
- 이 때 모든 가능한 품목 부분집합의 개수를 줄이는 방식으로 작동하는 것이 Apriori 알고리즘이며, 거래내역 안에 포함된 품목의 개수를 줄여 비교하는 횟수를 줄이는 방식으로 작동하는 것이 FP-Growth 알고리즘이다.

FP-Growth 알고리즘(빈발패턴성장 알고리즘)

- 후보 빈발항목집합을 생성하지 않음
- FP-Tree를 만든 후 분할정복 방식을 통해 Apriori 알고리즘 보다 데이터베이스를 스캔하는 횟수가 작음
- 더 빠르게 빈발항목집합을 추출할 수 있는 방법이다.

08 연관성 분석(Association Analysis)

최근 연관성 분석 동향

- 거래 내역에 포함되어 있는 모든 품목의 개수가 n 개일 때, 품목들의 전체집합에서 추출할 수 있는 품목 부분집합의 개수는 $2^n - 1$ (공집합 제외)개다. 그리고 가능한 모든 연관규칙의 개수는 $3^n - 2^{n+1} + 1$ 개다.
- 이 때 모든 가능한 품목 부분집합의 개수를 줄이는 방식으로 작동하는 것이 Apriori 알고리즘이며, 거래내역 안에 포함된 품목의 개수를 줄여 비교하는 횟수를 줄이는 방식으로 작동하는 것이 FP-Growth 알고리즘이다.

FP-Growth 알고리즘(빈발패턴성장 알고리즘)

단계	과정	절차
1	최소지지도 기반 선택	모든 거래를 확인해 각 아이템마다의 서포트를 계산하고 최소지지도 이상의 아이템만 선택
2	빈도 수 기반 정렬	모든 거래에서 빈도가 높은 아이템 순서대로 순서를 정렬(여기서부터 달라짐)
3	나무 생성	부모노드를 중심으로 거래를 자식노드로 추가해주면서 나무구조를 생성
4	나무 시작 및 확장	새로운 아이템이 나올 경우에는 부모노드부터 시작하고, 그렇지 않으면 기존의 노드에서 확장
5	빈발품목집합 도출	위의 과정을 모든 거래에 대해 반복하여 FP Tree를 만들고 최소지지도 이상의 패턴만을 추출

참고자료

ADsP 참고자료

