

머신러닝을 위한 선형대수학

07 특이값 분해

목차 07 특이값 분해

1. 특이값 분해 예제
2. 특이값 분해 이론
3. SVD의 머신러닝에서의 응용: 영상압축

1. 특이값 분해 예제



예제 1: $A = \begin{pmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$ 라 하자.

step 1: $A^T = \begin{pmatrix} 1 & 0 \\ 1 & 0 \\ 0 & 1 \end{pmatrix}$ 이고 $A^T A = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$ 이고 $A^T A$ 는 positive semidefinite matrix 이다.



정의 6.11: 대칭행렬 A ($A^T = A$)가 (2) $x^T A x \geq 0$ 이면 A 을 양의 준정부호 행렬(positive semidefinite matrix)라고 부른다. 이러한 행렬을 PSDM로 표시하자.

보기 (2) 임의의 행렬 A 에 대하여 $A^T A, A A^T$ 는 양의 준정부호 행렬이다.

[증명] (1) $x^T A^T A x = (Ax)^T Ax \geq 0$

(2) $x^T A A^T x = (A^T x)^T A^T x \geq 0$



정리 6.15: $n \times n$ 행렬 A 에 대하여 다음 세 가지 명제는 동치인 명제이다.

- (1) 행렬 A 가 양의 준정부호 행렬(positive semi definite matrix)이다.
- (2) A 의 모든 eigenvalue는 음의 실수가 아니다.
- (3) 행렬 U 가 존재하여 $A = U^T U$ 이다.
- (4) A 의 모든 sub-determinant는 음의 실수가 아니다.



정리 6.8: 대칭행렬의 직교 고유벡터[Orthogonal Eigenvectors of Symmetric matrix]

$n \times n$ 대칭행렬 A 에 대하여, $Av_1 = \lambda_1 v_1$, $Av_2 = \lambda_2 v_2$, $\lambda_1 \neq \lambda_2$ 라고 하면

$v_1 \cdot v_2 = v_1^T v_2 = 0$ 이다.

핵심정리 6.9: $n \times n$ 행렬 A 가 대칭행렬이면 정규직교행렬 $Q (Q^T Q = I,)$ 가 존재하여 대각화 가능하다. 즉,

$$A = Q^T D Q, \text{ } D \text{는 대각행렬, } Q^T = Q^{-1}$$



step 2: $A^T A = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$

$$|\lambda I - A^T A| = \begin{vmatrix} \lambda - 1 & -1 & 0 \\ -1 & \lambda - 1 & 0 \\ 0 & 0 & \lambda - 1 \end{vmatrix}$$

$$= (\lambda - 1)^3 - (\lambda - 1)$$

$$= (\lambda - 1)[(\lambda - 1)^2 - 1]$$

$$= (\lambda - 1)(\lambda^2 - \lambda) = (\lambda - 2)(\lambda - 1)\lambda = 0 \text{에서}$$

$$\lambda = 2, 1, 0$$



$$(i) \lambda = 2: \lambda I - A^T A = \begin{pmatrix} 1 & -1 & 0 \\ -1 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \rightarrow \begin{pmatrix} 1 & -1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

$$\begin{pmatrix} 1 & -1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \rightarrow \begin{cases} x - y = 0 \\ z = 0 \end{cases}$$

$$v_1 = \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix} \text{에서 크기가 1인 벡터로 대치 } v_1 = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \\ 0 \end{pmatrix}$$



$$(ii) \quad \lambda = 1: \lambda I - A^T A = \begin{pmatrix} 0 & -1 & 0 \\ -1 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix} \rightarrow \begin{pmatrix} 0 & -1 & 0 \\ -1 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}$$

$$v_2 = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}$$



$$(iii) \quad \lambda = 0: \lambda I - A^T A = \begin{pmatrix} -1 & -1 & 0 \\ -1 & -1 & 0 \\ 0 & 0 & -1 \end{pmatrix} \rightarrow \begin{pmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

$$\begin{pmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \rightarrow \begin{cases} x + y = 0 \\ z = 0 \end{cases}$$

$$v_3 = \begin{pmatrix} -1 \\ 1 \\ 0 \end{pmatrix} \text{에서 크기가 1인 벡터로 대치 } v_3 = \begin{pmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \\ 0 \end{pmatrix}$$



$$V = (v_1 \ v_2 \ v_3) = \begin{pmatrix} \frac{1}{\sqrt{2}} & 0 & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & 0 & \frac{1}{\sqrt{2}} \\ 0 & 1 & 0 \end{pmatrix} \text{라 하면}$$

V 는 직교행렬($VV^T = V^T V = I$)이고

$$A^T A V = V \begin{pmatrix} 2 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix}$$



이때 $u_i = \frac{1}{\sqrt{\lambda_i}} A v_i$ 로 하자. 따라서 여기서는 $\lambda = 2, 1$ 만 가능하다

$$A v_1 = \begin{pmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \\ 0 \end{pmatrix} = \begin{pmatrix} \sqrt{2} \\ 0 \end{pmatrix} = \sqrt{2} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \sqrt{2} u_1, \quad u_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix} \dots \textcircled{1}$$



$$Av_2 = \begin{pmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} = \sqrt{1} \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \sqrt{1} u_2, \quad u_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix} \dots \textcircled{2}$$

$$Av_3 = \begin{pmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \dots \textcircled{3}$$

$$U = (u_1 \ u_2) = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \text{이라 하자. } U \text{는 직교행렬이다, } UU^\top = U^\top U = I.$$



①, ②, ③식을 합해서 쓰면

$$A(v_1 \ v_2 \ v_3) = (u_1 \ u_2) \begin{pmatrix} \sqrt{2} & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix}$$

$$\Rightarrow A V = U \begin{pmatrix} \sqrt{2} & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix}$$

$$\Rightarrow U^T A V = \begin{pmatrix} \sqrt{2} & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix}$$



예제 2: $B = \begin{pmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{pmatrix}$

$$B^{\top} = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \end{pmatrix}, \quad B^{\top} B = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$$

$$|\lambda I - B^{\top} B| = \begin{vmatrix} \lambda - 2 & -1 \\ -1 & \lambda - 2 \end{vmatrix} = (\lambda - 2)^2 - 1 = (\lambda - 3)(\lambda - 1) = 0 \text{에서}$$

$$\lambda = 3, 1$$



$$(i) \lambda = 3: \lambda I - B^T B = \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix} \rightarrow \begin{pmatrix} 1 & -1 \end{pmatrix}$$

$$\rightarrow \begin{pmatrix} 1 & -1 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \text{에서 } v_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix} \text{에서 크기가 1인 벡터로 대치 } v_1 = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix}$$

$$(ii) \lambda = 1: \lambda I - B^T B = \begin{pmatrix} -1 & -1 \\ -1 & -1 \end{pmatrix} \rightarrow \begin{pmatrix} 1 & 1 \end{pmatrix}$$

$$v_2 = \begin{pmatrix} -1 \\ 1 \end{pmatrix} \text{에서 크기가 1인 벡터로 대치 } v_2 = \begin{pmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix}$$



$$V = (v_1 \ v_2) = \begin{pmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix} \text{라 하면}$$

V 는 직교행렬($VV^T = V^T V = I$)이고

$$B^T B V = \begin{pmatrix} 3 & 0 \\ 0 & 1 \end{pmatrix} V \text{이다.}$$



이때 $u_i = \frac{1}{\sqrt{\lambda_i}} Bv_i$ 로 하자. $B = \begin{pmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{pmatrix}$

$$Bv_1 = \begin{pmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix} = \begin{pmatrix} \frac{\sqrt{2}}{2} \\ \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix} = \sqrt{3} \begin{pmatrix} \frac{\sqrt{2}}{\sqrt{3}} \\ \frac{1}{\sqrt{6}} \\ \frac{1}{\sqrt{6}} \end{pmatrix} = \sqrt{3} u_1, \quad u_1 = \begin{pmatrix} \frac{\sqrt{2}}{\sqrt{3}} \\ \frac{1}{\sqrt{6}} \\ \frac{1}{\sqrt{6}} \end{pmatrix} \dots \textcircled{1}$$

$$Bv_2 = \begin{pmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix} = \begin{pmatrix} 0 \\ \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix} = \sqrt{1} u_2, \quad u_2 = \begin{pmatrix} 0 \\ \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix} \dots \textcircled{2}$$



$u_1 \times u_2 = u_3$ 라 하자.

※ 벡터곱: u_3 는 u_1, u_2 에 수직인 벡터이다. 위키백과 “벡터곱 참고”

$$u_3 = u_1 \times u_2 = \begin{pmatrix} \frac{1}{\sqrt{3}} \\ -\frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{3}} \end{pmatrix}$$

$$U = (u_1 \ u_2 \ u_3) = \begin{pmatrix} \frac{\sqrt{2}}{\sqrt{3}} & 0 & \frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{3}} \end{pmatrix}$$



$$B(v_1 \ v_2) = (u_1 \ u_2 \ u_3) \begin{pmatrix} \sqrt{3} & 0 \\ 0 & 1 \\ 0 & 0 \end{pmatrix}, \quad BV = U \begin{pmatrix} \sqrt{3} & 0 \\ 0 & 1 \\ 0 & 0 \end{pmatrix}$$

$$U^{\top} BV = \begin{pmatrix} \sqrt{3} & 0 \\ 0 & 1 \\ 0 & 0 \end{pmatrix}$$



예제 3: $A = \begin{pmatrix} 4 & 0 \\ 3 & -5 \end{pmatrix}, \quad A^{\top} = \begin{pmatrix} 4 & 3 \\ 0 & -5 \end{pmatrix}$

$$A^{\top} A = \begin{pmatrix} 4 & 3 \\ 0 & -5 \end{pmatrix} \begin{pmatrix} 4 & 0 \\ 3 & -5 \end{pmatrix} = \begin{pmatrix} 25 & -15 \\ -15 & 25 \end{pmatrix}$$

$$\det(\lambda I - A^{\top} A) = \begin{vmatrix} \lambda - 25 & 15 \\ 15 & \lambda - 25 \end{vmatrix} (\lambda - 25)^2 - 15^2 = 0$$

$$\lambda = 40, 10$$



$$\lambda = 40 \quad \lambda I - A^T A = \begin{pmatrix} 15 & 15 \\ 15 & 15 \end{pmatrix} \quad v_1 = \begin{pmatrix} 1 \\ -1 \end{pmatrix} \text{에서 크기가 1인 벡터로 대치} \quad v_1 = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{pmatrix}$$

$$\lambda = 41 \quad \lambda I - A^T A = \begin{pmatrix} -15 & 15 \\ 15 & -15 \end{pmatrix} \quad v_2 = \begin{pmatrix} 1 \\ 1 \end{pmatrix} \text{에서 크기가 1인 벡터로 대치} \quad v_2 = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix}$$

$$V = \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix}$$



이때 $u_i = \frac{1}{\sqrt{\lambda_i}} Bv_i$ 로 하자.

$$A = \begin{pmatrix} 4 & 0 \\ 3 & -5 \end{pmatrix} v_1 = \begin{pmatrix} 4 & 0 \\ 3 & -5 \end{pmatrix} \begin{pmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{pmatrix} = \begin{pmatrix} \frac{4}{\sqrt{2}} \\ \frac{8}{\sqrt{2}} \end{pmatrix} = \sqrt{40} \begin{pmatrix} \frac{4}{\sqrt{80}} \\ \frac{8}{\sqrt{80}} \end{pmatrix}, \quad u_1 = \begin{pmatrix} \frac{4}{\sqrt{80}} \\ \frac{8}{\sqrt{80}} \end{pmatrix}$$

$$A = \begin{pmatrix} 4 & 0 \\ 3 & -5 \end{pmatrix} v_2 = \begin{pmatrix} 4 & 0 \\ 3 & -5 \end{pmatrix} \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix} = \begin{pmatrix} \frac{4}{\sqrt{2}} \\ \frac{2}{\sqrt{2}} \end{pmatrix} = \sqrt{10} \begin{pmatrix} \frac{4}{\sqrt{20}} \\ \frac{2}{\sqrt{20}} \end{pmatrix}, \quad u_2 = \begin{pmatrix} \frac{4}{\sqrt{20}} \\ \frac{2}{\sqrt{20}} \end{pmatrix}$$



$$A(v_1 \ v_2) = (u_1 \ u_2 \ u_3) \begin{pmatrix} \sqrt{40} & 0 \\ 0 & \sqrt{10} \end{pmatrix}, \quad A V = U \begin{pmatrix} \sqrt{40} & 0 \\ 0 & \sqrt{10} \end{pmatrix}$$

2. 특이값 분해 이론



보조정리: A 가 $m \times n$ 행렬이라고 하면 $A : R^n \rightarrow R^m$ 인 선형함수이고 $A^\top : R^m \rightarrow R^n$ 인 함수이다. 그러면 다음 성질을 만족한다.

- (1) $x \in R^n, y \in R^m$ 이면 $\langle Ax, y \rangle = \langle x, A^\top y \rangle$ 이다.
- (2) $A(R^n)^\perp = N(A^\top)$ [$A(R^n)^\perp$: $A(R^n)$ 의 직교 여공간]
- (3) $[A^\top(R^m)]^\perp = N(A)$



[증명] (1) 직접 계산해 보면 된다.

(2) 먼저 $N(A^T) \subset A(R^n)^\perp$ 임을 보이자. $y \in N(A^T)$ 이면 $A^T y = 0$ 이다.

$\langle Ax, y \rangle = \langle x, A^T y \rangle = \langle x, 0 \rangle = 0$ 따라서 $y \in A(R^n)^\perp$ 이다.

이번은 $A(R^n)^\perp \subset N(A^T)$ 임을 보이자.

$y \in A(R^n)^\perp$ 라 하면 모든 x 에 대하여 $\langle Ax, y \rangle = 0$

$0 = \langle Ax, y \rangle = \langle x, A^T y \rangle$ 이므로 $A^T y = 0$ 이다.

따라서 $y \in N(A^T)$



정리 7.1: 행렬의 특이값 분해 (Singular Value Decomposition, SVD)는 $m \times n$ 행렬 A 을 아래와 같이 분해된 행렬로 표현하는 방법이다.

$$A = U \Lambda V^{\top}$$

U : $m \times m$ 직교행렬 ($UU^{\top} = U^{\top}U = I_{m \times m}$)

Λ : $m \times n$ 대각행렬 ($m \times n$)

V : $n \times n$ 직교 행렬 ($VV^{\top} = V^{\top}V = I_{n \times n}$)

$p = \min(m, n)$ 이라 하면 $\Sigma = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_p)$ 이고

$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_p \geq 0$ 이다.

$\sigma_1, \sigma_2, \dots, \sigma_p$ 를 특이값(singular value)이라고 부른다.



$$m = 2, n = 3 \text{ 이면 } A = \begin{pmatrix} \sigma_1 & 0 & 0 \\ 0 & \sigma_2 & 0 \end{pmatrix},$$

$$m = 3, n = 2 \text{ 이면 } A = \begin{pmatrix} \sigma_1 & 0 \\ 0 & \sigma_2 \\ 0 & 0 \end{pmatrix}$$

인 형태이다.

$$A = \begin{pmatrix} \sigma_1 & 0 & 0 \\ 0 & \sigma_2 & 0 \end{pmatrix} \text{라 하면 } A^T = \begin{pmatrix} \sigma_1 & 0 \\ 0 & \sigma_2 \\ 0 & 0 \end{pmatrix} \text{에서}$$

$$A^T A = \begin{pmatrix} \sigma_1^2 & 0 & 0 \\ 0 & \sigma_2^2 & 0 \\ 0 & 0 & 0 \end{pmatrix} \text{이고 } A A^T = \begin{pmatrix} \sigma_1^2 & 0 \\ 0 & \sigma_2^2 \end{pmatrix} \text{인 모양이다. 이 모양을 기억하면서 다음 식들을}$$

계산해 보자. 즉, $m \times n$ 행렬 A 에서 $A^T A$ 는 $n \times n$ 행렬인 대각행렬 $A A^T$ 는 $m \times m$ 행렬인 대각행렬이다.



$$A^{\top} A = (U \Lambda V^{\top})^{\top} U \Lambda V^{\top} = V \Lambda^{\top} U^{\top} U \Lambda V^{\top} = V \Lambda^{\top} \Lambda V^{\top} \text{에서}$$

$$\Lambda_1 = \Lambda^{\top} \Lambda = \text{diag}(\sigma_1^2, \sigma_2^2, \dots, \sigma_n^2) \text{라 하면}$$

$$(A^{\top} A) V = V \Lambda_1 \dots \textcircled{1}$$

①식에서 $\sigma_i^2, i = 1, 2, \dots, n$ 은 고유치가 되고 V 의 열벡터들은 $A^{\top} A$ 의 고유벡터가 된다.

같은 방법으로 $AA^{\top}$ 을 계산해보면

$$(AA^{\top}) U = U \Lambda_2 \dots \textcircled{2} (\Lambda_2 = \Lambda \Lambda^{\top} = \text{diag}(\sigma_1^2, \sigma_2^2, \dots, \sigma_m^2))$$

②식에서 $\sigma_i^2, i = 1, 2, \dots, m$ 은 고유치가 되고 U 의 열벡터들은 $AA^{\top}$ 의 고유벡터가 된다.



[증명] $A^T A$ 는 양의 준정부호 행렬이므로 직교행렬 V 가 존재하여

$$A^T A V = V \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_n)$$

으로 표현가능하다. 이때, V 의 열벡터들은 고유벡터가 된다.

$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ 이고 $\sigma_{r+1} = \dots = \sigma_n = 0$ 라 하자.



$i = 1, \dots, r$ 에 대하여 $u_i = \frac{Av_i}{\sqrt{\sigma_i}} \in R^m$ 이라 정의하자.

$$u_i^\top u_j = \frac{(Av_i)^\top (Av_j)}{\sqrt{\sigma_i} \sqrt{\sigma_j}} = \frac{v_i^\top A^\top A v_j}{\sqrt{\sigma_i \sigma_j}} = \frac{\sigma_j v_i^\top v_j}{\sqrt{\sigma_i \sigma_j}}$$

에서 $i = j$ 이면 $u_i^\top u_i = 1$, $i \neq j$ 이면 $u_i^\top u_j = 0$ 이다. 또한

$$AA^\top u_i = AA^\top \frac{Av_i}{\sqrt{\sigma_i}} = A \sqrt{\sigma_i} v_i = \sigma_i u_i \text{이므로 } u_i \text{는 } AA^\top \text{의 고유벡터이다.}$$

만약 $r = m$ 인 경우 $\text{rank}(AA^\top) = m$ 이 되어 u_i , $i = 1, \dots, m$ 은 R^m 의 정규직교기저가 되고 $U = (u_1, u_2, \dots, u_m)$ 은 직교행렬이다.



만약 $r < m$ 이면 $\text{rank}(AA^\top) = r$ 이고 $\dim N(AA^\top) = m - r$ 이다. 이때 우리는 $m - r$ 의 벡터 $u_{r+1}, \dots, u_m$ 를 $N(AA^\top)$ 에서 택하여 $u_1, \dots, u_r, u_{r+1}, \dots, u_m$ 이 정규직교 기저개가 되도록 할 수 있다. 이 경우

$U = (u_1, \dots, u_r, u_{r+1}, \dots, u_m)$ 는 직교행렬이고 $i > r$ 이면 $AA^\top u_i = 0$ 이다.



마지막으로 $U^T A V = \Sigma$, $\Sigma = \text{diag}(\sqrt{\sigma_1}, \sqrt{\sigma_2}, \dots, \sqrt{\sigma_n})$ 임을 보이자.

$$i \leq r \text{이면 } u_i^T A v_j = \frac{1}{\sqrt{\sigma_i}} v_i^T A^T A v_j = \frac{\sigma_j}{\sqrt{\sigma_i}} v_i^T v_j = \frac{\sigma_j}{\sqrt{\sigma_i}} \delta_{ij}$$

$$r < i \leq m \text{이면 } A A^T u_i = 0 \text{ 이므로 } A^T u_i \in N(A) \quad (3) \quad A^T (R^m)^\perp = N(A)$$

보조정리 의해서 $A^T u_i \in [A^T (R^m)]^\perp$ 이고 동시에 $A^T u_i \in A^T (R^m)$

따라서 $A^T u_i = 0$

$$u_i^T A v_j = (u_i^T A v_j)^T = v_j^T A^T u_i = 0 \text{ 이므로}$$

$U^T A V = \Sigma$ 을 만족한다.



정리 7.2: $m \times n$ 행렬 A 의 특이값 분해가 아래와 같다고 하자.

$$A = U \Lambda V^T$$

그러면 행렬 V 의 열벡터는 $A^T A$ 의 고유벡터이다.

[증명] $A^T A = (U \Lambda V^T)^T U \Lambda V^T = V \Lambda^T U^T U \Lambda V^T = V \Lambda^T \Lambda V^T$ 에서

$\Lambda_1 = \Lambda^T \Lambda = \text{diag}(\sigma_1^2, \sigma_2^2, \dots, \sigma_n^2)$ 라 하면

$$(A^T A) V = V \Lambda_1 \dots \textcircled{1}$$

①식에서 $\sigma_i^2, i = 1, 2, \dots, n$ 은 고유치가 되고 V 의 열벡터들은 $A^T A$ 의 고유벡터가 된다.



보기1: 행렬 $A = \begin{pmatrix} 9.5 & 1.4 & 7 & 0.3 \\ 4 & 4 & 9 & 8 \\ 8 & 9.1 & 6.5 & 9.3 \end{pmatrix}$ 을 MatLab 명령어

$[U \ D \ V] = svd(A)$ 하면 행렬 A 을 다음 3개의 행렬로 분해 해준다.

$$U = \begin{pmatrix} -0.4239 & -0.9054 & 0.0239 \\ -0.5599 & 0.2412 & -0.7927 \\ -0.7119 & 0.3493 & 0.6092 \end{pmatrix}$$

$$D = \begin{pmatrix} 22.7036 & 0 & 0 & 0 \\ 0 & 7.7065 & 0 & 0 \\ 0 & 0 & 4.3594 & 0 \end{pmatrix}$$

$$V = \begin{pmatrix} -0.5269 & -0.6283 & 0.4427 & 0.3629 \\ -0.4101 & 0.3732 & 0.5521 & -0.6227 \\ -0.5565 & -0.2461 & -0.6898 & -0.3925 \\ -0.4945 & 0.6367 & -0.1533 & 0.514 \end{pmatrix}$$

이때, $A = U D V^T$ 이다.

$[V1 \ D1] = eig(A^T A)$ 라면

$$V1 = \begin{pmatrix} -0.3629 & 0.4427 & -0.6283 & 0.5269 \\ 0.6227 & 0.5521 & 0.3732 & 0.4101 \\ 0.3925 & -0.6898 & -0.2461 & 0.5565 \\ -0.5714 & -0.1533 & 0.6367 & 0.4945 \end{pmatrix}$$

$$D1 = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 19.0043 & 0 & 0 \\ 0 & 0 & 59.3906 & 0 \\ 0 & 0 & 0 & 515.4550 \end{pmatrix}$$

3. SVD의 머신러닝에서의 응용: 영상압축



Rank가 1인 행렬과 외적

머신러닝을 위한
선형대수학

07 특이값 분해

3. SVD의 머신러닝에서
의 응용: 영상압축

	1	2	3	4
1	1	2	3	4
-1	-1	-2	-3	-4
2	2	4	6	8
10	10	20	30	40

⇒

	1	2	3	4
1				
-1				
2				
10				

위 그림은 rank가 1인 행렬이다. 오른쪽과 같이 두 벡터의 외적으로 처음 행렬을 표시할 수 있다. 즉 16개의 원소를 8개의 원소로 표현할 수 있다는 얘기이다.

만약 $100 \times 100 = 10000$ 이데 오른 쪽과 같이 두 벡터의 외적으로 표시할 수 있다면 2×100 으로 표현가능 한 것이다. 이것은 $n \times n$ 차원을 $2n$ 으로 줄이는 차원축소 (dimension reduction)라 할 수 있다.



모든 행렬을 이렇게 만들 수는 없다. 특히 행렬식값이 0이 아닌 행렬은 full rank를 가지므로 차원 축소가 어렵다. 지금부터 설명할 것은 SVD를 이용하면 모든 행렬을 rank가 1인 행렬의 합으로 근사화 할 수 있다는 것이다.

3	1	4	1
5	9	2	6
5	3	5	8
9	9	9	3

$\Rightarrow$



+



...



$$\begin{bmatrix} & & & \\ & A & & \\ & & & \\ & & & \end{bmatrix} = \begin{bmatrix} & & & \\ & & & \\ & & & \\ & & & \end{bmatrix} \begin{bmatrix} & & & \\ & & & \\ & & & \\ & & & \end{bmatrix} \begin{bmatrix} & & & \\ & & & \\ & & & \\ & & & \end{bmatrix}$$

$$\begin{bmatrix} & & & \\ & A & & \\ & & & \\ & & & \end{bmatrix} = \begin{bmatrix} u_1 & u_2 & u_3 & u_4 \\ & & & \\ & & & \\ & & & \end{bmatrix} \begin{bmatrix} \sigma_1 & & & \\ & \sigma_2 & & \\ & & \sigma_3 & \\ & & & \sigma_4 \end{bmatrix} \begin{bmatrix} v_1^\top \\ v_2^\top \\ v_3^\top \\ v_4^\top \end{bmatrix}$$

$A =$

$$\sigma_1 \begin{bmatrix} u_1 \end{bmatrix} \begin{bmatrix} v_1^\top \end{bmatrix} + \sigma_2 \begin{bmatrix} u_2 \end{bmatrix} \begin{bmatrix} v_2^\top \end{bmatrix} + \sigma_3 \begin{bmatrix} u_3 \end{bmatrix} \begin{bmatrix} v_3^\top \end{bmatrix} + \sigma_4 \begin{bmatrix} u_4 \end{bmatrix} \begin{bmatrix} v_4^\top \end{bmatrix}$$

$$A = \sigma_1 u_1 v_1^\top + \sigma_2 u_2 v_2^\top + \sigma_3 u_3 v_3^\top + \sigma_4 u_4 v_4^\top$$



정리 7.3: A 는 $m \times n$ 이다. $rank(A) = 1$ 일 필요충분조건은 $u \in R^n$, $v \in R^m$ 이 존재
해서 $A = uv^T$ 이다.

[증명] ($\Rightarrow$)

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix} \text{이고 } rank(A) = 1 \text{ 이라 하자.}$$

따라서

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ u_2 a_{11} & u_2 a_{12} & \cdots & u_2 a_{1n} \\ \vdots & \vdots & & \vdots \\ u_m a_{11} & u_m a_{12} & \cdots & u_m a_{1n} \end{pmatrix} \text{이다.}$$

$$v^T = (a_{11} \ a_{12} \ \cdots \ a_{1n}), \ u = \begin{pmatrix} 1 \\ u_2 \\ \vdots \\ u_m \end{pmatrix} \text{이라 하면 } A = uv^T \text{ 이다.}$$



($\Leftarrow$) $A : R^n \rightarrow R^m$ 이므로 $x \in R^n$ 에 대하여

$$Ax = uv^T x = u(v^T x) = \langle v, x \rangle u$$

따라서 $\dim(A(R^n)) = 1$ 이고 정리 5.9에서

$$n = \dim(N(A)) + \dim(A(R^n)) \Rightarrow \dim(N(A)) = n - 1$$

따름 정리 5.13에 의해서

$$n = \dim\{x \in R^n \mid Ax = 0\} + \text{rank} A \text{ 이므로 } \text{rank}(A) = 1 \text{ 이다.}$$



$A = \sigma_1 u_1 v_1^\top + \sigma_2 u_2 v_2^\top + \sigma_3 u_3 v_3^\top + \sigma_4 u_4 v_4^\top$ 에서

$\sigma_1 \geq \sigma_2 \geq \sigma_3 \geq \sigma_4 \geq 0$ 인데 σ_3, σ_4 가 상대적으로 σ_1, σ_2 에 비해 매우 작다면

$$A \approx \sigma_1 u_1 v_1^\top + \sigma_2 u_2 v_2^\top$$

와 같이 근사화 가능하다.

이런 원리를 가지고 SVD에 의해 압축이 가능하다.



3	1	4	1
5	9	2	6
5	3	5	8
9	9	9	3

을 SVD하면

-0.2037	0.3291	-0.3247	-0.8630	21.9785	0	0	0
-0.5088	-0.5680	0.5677	-0.3101	0	6.1108	0	0
-0.4561	-0.4473	-0.7387	0.2151	0	0	5.2536	0
-0.7012	0.6075	0.1628	0.3359	0	0	0	0.0510
-0.5344	0.2255	-0.0692	-0.8116				
-0.5670	-0.1076	0.7679	0.2780				
-0.4742	0.5582	-0.4552	0.5062				
-0.4099	-0.7912	-0.4453	0.0880				



이때,

$$\sigma_1 \mathbf{u}_1 \mathbf{v}_1^\top, \sigma_1 \mathbf{u}_1 \mathbf{v}_1^\top + \sigma_2 \mathbf{u}_2 \mathbf{v}_2^\top, \sigma_1 \mathbf{u}_1 \mathbf{v}_1^\top + \sigma_2 \mathbf{u}_2 \mathbf{v}_2^\top + \sigma_3 \mathbf{u}_3 \mathbf{v}_3^\top$$

을 각각 구해보면

2.3927	2.5385	2.1233	1.8351
5.9764	6.3406	5.3034	4.5836
5.3568	5.6832	4.7535	4.1083
8.2359	8.7377	7.3084	6.3164

2.8462	2.3222	3.2458	0.2442
5.1936	6.7140	3.3657	7.3297
4.7403	5.9772	3.2278	6.2706
9.0731	8.3383	9.3808	3.3795

2.9643	1.0122	4.0223	1.0039
4.9872	9.0044	2.0080	6.0014
5.0089	2.9970	4.9944	7.9990
9.0139	8.9952	8.9913	2.9985

3	1	4	1
5	9	2	6
5	3	5	8
9	9	9	3

$\sigma_1 \mathbf{u}_1 \mathbf{v}_1^\top + \sigma_2 \mathbf{u}_2 \mathbf{v}_2^\top + \sigma_3 \mathbf{u}_3 \mathbf{v}_3^\top$ 는 원 행렬값과 유사한 것 알 수 있다.



정리 7.4: $m \times n$ 행렬 A 을 아래와 같이 SVD로 분해된 행렬이고 $\text{rank}(A) = k$ 라 하자.

$$k \leq \min(m, n) \sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_k \geq 0 \geq \dots \geq 0$$

$$A = U \Lambda V^{\top} \text{ 에서 } \Lambda = \begin{pmatrix} \sigma_1 & 0 & \dots & 0 \\ 0 & \sigma_2 & \dots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \sigma_k & 0 \\ 0 & 0 & \dots & 0 \end{pmatrix} \text{ 이고}$$

$$A = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^{\top} + \sigma_2 \mathbf{u}_2 \mathbf{v}_2^{\top} + \dots + \sigma_k \mathbf{u}_k \mathbf{v}_k^{\top} \text{ 이다.}$$



영상압축 예제



위 영상은 203×233 크기의 흑백영상이다. 위 영상을 A 라고 표현하자. $\text{rank}(A) = 5$ 이다.

$[U \Lambda V] = \text{svd}(A)$ 해서 Λ 의 5개의 대각선 값을 보여주고 있다.

$203 \times 233 = 47299$ 을 $5 \times (203 + 233) = 2180$ 축소 가능하다.



SVD를 활용한 압축


머신러닝을 위한
선형대수학

07 특이값 분해


3. SVD의 머신러닝에서
의 응용: 영상압축

3.7583	0	0	0	0	0
0	1.3709	0	0	0	0
0	0	0.8983	0	0	0
0	0	0	0.8079	0	0
0	0	0	0	0.4966	0
0	0	0	0	0	0.0000
0	0	0	0	0	0
-	-	-	-	-	-


$$\sigma_1 u_1 v_1^\top$$



$$\sigma_1 u_1 v_1^\top + \sigma_2 u_2 v_2^\top$$



$$\sigma_1 u_1 v_1^\top + \sigma_2 u_2 v_2^\top + \sigma_3 u_3 v_3^\top$$





SVD를 활용한 압축

머신러닝을 위한
선형대수학

07 특이값 분해

3. SVD의 머신러닝에서
의 응용: 영상압축

$$\sigma_1 u_1 v_1^\top + \sigma_2 u_2 v_2^\top + \sigma_3 u_3 v_3^\top + \sigma_4 u_4 v_4^\top$$



$$\sigma_1 u_1 v_1^\top + \sigma_2 u_2 v_2^\top + \sigma_3 u_3 v_3^\top + \sigma_4 u_4 v_4^\top + \sigma_5 u_5 v_5^\top$$



