

머신러닝을 위한 선형대수학

08 주성분 분석(PCA)을 이용한 데이터 표현과 특징 추출

목차 08 주성분 분석(PCA)을 이용한 데이터 표현과 특징 추출

1. PCA는 무엇인가?
2. 결합 확률과 공분산
3. 주성분분석(PCA)
4. PCA응용: Eigenface와 영상인식응용

1. PCA는 무엇인가?



PCA (Principal Component Analysis, 주성분 분석)는 다양한 분야에서 유용하게 활용되는 차원 축소 기법이다. 여러 가지 유용성이 있지만, 그 중에서도 주로 다음과 같은 이점들이 있다.

차원 축소: PCA는 고차원 데이터를 저차원 공간으로 변환하여 데이터의 차원을 축소하는데 사용된다. 이는 데이터의 복잡성을 줄이고, 계산 효율성을 향상시킬 수 있다. 또한, 차원 축소는 노이즈를 제거하고 데이터의 중요한 특징을 추출하는 데 도움이 될 수 있다.

주성분 추출: PCA는 데이터의 주성분을 추출하는 데 사용됩니다. 주성분은 데이터의 변동성을 가장 많이 설명하는 방향 벡터들을 의미하며, 이를 통해 데이터의 주요 특징을 파악할 수 있다. 주성분 방향벡터는 데이터의 분산을 최대화하는 방향으로 정의된다.



데이터 시각화: PCA는 데이터를 저차원 공간으로 변환하여 시각화하는 데 유용하다. 고차원 데이터는 시각화가 어렵기 때문에 PCA를 사용하여 데이터를 2D 또는 3D로 축소하여 시각화하면 데이터의 패턴과 구조를 더 잘 이해할 수 있다.

특징 선택: PCA는 데이터에서 가장 중요한 특징이 무엇인지를 결정하는 데 사용될 수 있습니다. 데이터의 주성분들은 데이터의 분산을 통해 설명할 수 있는 특징들이므로, 이를 기반으로 특징을 선택하거나 중요도를 결정할 수 있습니다.

노이즈 제거: PCA는 데이터에서 노이즈를 제거하는 데 도움이 될 수 있습니다. 주성분은 데이터의 변동성을 가장 많이 설명하는 방향으로 정의되기 때문에, 노이즈는 주성분의 작은 변화로 표현되며, 이를 제거할 수 있습니다.

이러한 이점들로 인해 PCA는 데이터 분석, 패턴 인식, 이미지 처리, 의료 영상 분석 등 다양한 분야에서 널리 사용되고 있다.

2. 결합 확률과 공분산



주성분분석(PCA)은 이론적으로 확률변수를 취급한다. 데이터의 다양한 Feature들은 각각이 하나의 확률변수 이기도 하도 이들 확률변수들을 결합해서 생각하기도 한다. 그래서 여기서는 간단하게 주성분분석에 필요한 확률 개념들을 다루고자 한다. 자 그럼 구체적인 예를 들어 설명해 보자.



100명의 학생을 표본공간이라고 생각해보자. 우리는 여기서 다양한 것 에 관심을 가지게 된다. 예를 들면 학생들의 키, 학생들의 몸무게, 학생들의 운동시간, 학생들의 하루 스마트폰 사용시간, 수학성적, 영어성적, 국어성적 등등이다. 이들 하나 하나는 확률의 분포를 가지는 하나의 확률변수이다. 모집단 내에서 무수히 많은 확률변수가 존재하게 마련이다. 어떤 경우는 각각의 확률변수에 주목도 하지만 어떤 경우는 동시에 두 가지 또는 세 가지의 확률변수들을 동시에 관찰할 때도 있게 된다. 예를 들면 학생들의 키와 학생들의 몸무게 사이에는 연관성이 있는지 알고 싶을 수도 있다. 학습시간과 수학성적과의 연관성이 있는지 또는 수학성적과 영어성적사이에도 무슨 연관성이 있는지 등 다양한 관심을 가지고 표본공간을 들여다 볼 수 있다. 이렇게 동시에 여러 개의 확률 변수를 다루는 것을 결합분포라 한다.



우리는 확률 변수들을 $X, Y, Z, \dots$ 또는 $X_1, X_2, X_3, \dots$ 등으로 표시한다.

특히 주목하는 것은 두 확률변수 X, Y 의 연관성을 알 수 있는 공분산 $Cov(X, Y)$ 개념과 여러 개의 공분산 $Cov(X_1, X_2), Cov(X_1, X_3), Cov(X_1, X_4), \dots$ 을 동시에 다루는 공분산 행렬 그리고 확률변수의 선형결합 $a_1X_1 + a_2X_2 + \dots + a_nX_n$ 등의 개념들에 대해 공부하고 이를 이용하여 이번 이론의 핵심주제인 PCA(주성분분석)을 공부할 것이다.



100명의 학생을 표본으로 하는 표본공간을 $S = \{s_1, s_2, \dots, s_{100}\}$ 라 하자.

보기1: 학생들의 키 정보

계급표시	H_1	H_2	H_3	H_4	H_5
키(cm) 이상-미만	155-160	160-165	165-170	170-175	175-180
학생 수(명)	10	20	32	24	14

참고로, 학생들의 키가 $H(s_1) = 171cm, H(s_2) = 173cm, \dots, H(s_{100}) = 179cm$ 이라 하였다.



보기2: 학생들의 몸무게 정보

계급표시	W_1	W_2	W_3	W_4	W_5
몸무게(kg) 이상-미만	50-55	55-60	60-65	65-70	70-75
학생 수(명)	10	19	37	23	11

참고로 학생들의 몸무게가 $W(s_1) = 65kg$, $W(s_2) = 64kg$, $\dots$, $W(s_{100}) = 70kg$ 이라 하였다.



계급표시	H_1	H_2	H_3	H_4	H_5
키(cm) 이상-미만	155-160	160-165	165-170	170-175	175-180
학생 수(명)	10	20	32	24	14

계급표시	W_1	W_2	W_3	W_4	W_5
몸무게(kg) 이상-미만	50-55	55-60	60-65	65-70	70-75
학생 수(명)	10	19	37	23	11

보기 1,2에서 우리는 학생들의 키와 몸무게를 계급을 나누어 분포를 확인하였다. 이번에는 각 학생들의 키와 몸무게를 함께(joint) 표현하는 방법을 알아보자. $H(s_1) = 171cm$, $W(s_1) = 65kg$ 이므로 $(H(s_1), W(s_1)) = (H_4, W_4)$ 가 된다.

같은 방법으로 $H(s_2) = 173cm$, $W(s_2) = 64kg$ 이므로 $(H(s_2), W(s_2)) = (H_4, W_3)$ 가 된다.



모든 $s_i, i = 1, 2, \dots, 100$ 에 대하여 $(H(s_i), W(s_i))$ 을 생각할 수 있다. 이것은 두 확률변수 H, W 을 결합해서 생각하는 방식으로 말 그대로 결합분포이다. 결합분포도 하나의 함수로 표현된다. $S \rightarrow R^2: s_i \rightarrow (H(s_i), W(s_i))$. 두 확률변수의 순서쌍 (H, W) 을 **확률벡터**라 부른다.

다음 표는 모든 $s_i, i = 1, 2, \dots, 100$ 에 대하여 $(H(s_i), W(s_i))$ 값을 표로 정리한 것이다.

	H_1	H_2	H_3	H_4	H_5	합계
W_1	6	2	2			10
W_2	2	12	5			19
W_3	1	4	20	12		37
W_4	1	2	5	8	7	23
W_5				4	7	11
합계	10	20	32	24	14	100

$[H_i: \text{키}, W_i: \text{몸무게}]$



두 확률변수 H, W 가 각각 표본공간을 분할하고 분할된 각 사건에게 확률값을 부여하는 것과 같은 방법으로, 위 표를 가지고도 표본공간을 분할하고 각 사건에 대하여 확률값을 부여할 수 있다. 예를 들면 (H_1, W_1) 의 확률값은

$$P(H_1, W_1) = \frac{6}{100},$$

(H_2, W_2) 의 확률값은 $P(H_2, W_2) = \frac{12}{100}$ 이다.

$A = \{(H_1, W_1), (H_2, W_2)\}$ 라 하면

$$P(A) = \{(H_1, W_1), (H_2, W_2)\} = \frac{6}{100} + \frac{12}{100} = \frac{18}{100} \text{이 된다.}$$

일반적으로 확률분포 함수를 f 라 표시하면 확률벡터 (H, W) 의 확률은

$$f(H_1, W_1) = P(H_1, W_1) = \frac{6}{100},$$

$$f(H_1, W_2) = P(H_1, W_2) = \frac{2}{100},$$

$$f(H_1, W_3) = P(H_1, W_3) = \frac{1}{100},$$

...

으로 구할 수 있다.

	H_1	H_2	H_3	H_4	H_5	합계
W_1	6	2	2			10
W_2	2	12	5			19
W_3	1	4	20	12		37
W_4	1	2	5	8	7	23
W_5				4	7	11
합계	10	20	32	24	14	100



위 방법을 일반화 하면

$X = (X, Y)$: 대응 확률함수 $f(x, y)$,

$X = (X, Y, Z)$: 대응 확률함수 $f(x, y, z)$,

$\vdots$

$X = (X_1, X_2, \dots, X_n)$: 대응 확률함수 $f(x_1, x_2, \dots, x_n)$

이 된다.

정의[기댓값] 8.1: X 가 확률분포 $f(x)$ 를 가지는 확률변수라 하자.

X 가 이산형인 경우 X 의 평균(또는 기댓값)은

$$\mu = E[X] = \sum_x x f(x) = \sum_x x p(X=x)$$

X 가 연속인 경우 X 의 (평균 또는 기댓값)은

$$\mu = E[X] = \int_{-\infty}^{\infty} x f(x) dx$$



정의[분산(Variance)] 8.2: X 가 확률분포 $f(x)$ 를 가지는 확률변수라 하자.

X 의 기댓값 $\mu = E[X]$ 에 대하여

X 가 이산형인 경우 X 의 분산(variance) $E[(X - \mu)^2] = \sum_x (x - \mu)^2 f(x)$

X 가 연속인 경우 X 의 분산(variance) $E[(X - \mu)^2] = \int_{-\infty}^{\infty} (x - \mu)^2 f(x) dx$


분산은 확률변수 X 의 분포가 평균을 중심으로 밀집된 정도를 나타내는 척도가 된다. 이때 분산을 $Var(X)$ 또는 σ^2 으로 표시한다. 이때 표준편차(standard deviation)은 다음과 같이 정의 된다.

$$\sigma = \sqrt{E[(x - \mu)^2]}$$




분산공식은 다음과 같이 변형된다.

$$\begin{aligned}\sigma^2 &= E[(X - \mu)^2] = E[X^2 - 2\mu X + \mu^2] \\ &= E[X^2] - 2\mu E[X] + \mu^2 \\ &= E[X^2] - \mu^2\end{aligned}$$



[분산이 작다]



[분산이 크다]



정의[두 확률변수의 공분산] 8.3: 두 확률변수 X, Y 에 대하여

$E[X] = \mu_X, E[Y] = \mu_Y$ 라 하자. 이때

$E[(X - \mu_X)(Y - \mu_Y)]$ 을 두 확률변수 X, Y 의 **공분산(Covariance)**이라 부르고,

$Cov(X, Y)$ 로 표시한다. 즉,

$$Cov(X, Y) = E[(X - \mu_X)(Y - \mu_Y)]$$

$$Cov(X, Y) = E[(X - \mu_X)(Y - \mu_Y)]$$

$$= E[XY - \mu_X Y - \mu_Y X + \mu_X \mu_Y]$$

$$= E[XY] - \mu_X E[Y] - \mu_Y E[X] + \mu_X \mu_Y$$

$$= E[XY] - \mu_X \mu_Y$$



정의 8.4: 상관계수(Correlation Coefficient)

$$\begin{aligned}\rho_{XY} &= \frac{Cov(X, Y)}{\sigma_X \sigma_Y} \\ &= \frac{E[(X - \mu_X)(Y - \mu_Y)]}{\sqrt{E[(X - \mu_X)^2]} \sqrt{E[(Y - \mu_Y)^2]}} \\ &= \frac{E[XY] - \mu_X \mu_Y}{\sqrt{E[X^2] - \mu_X^2} \sqrt{E[Y^2] - \mu_Y^2}}\end{aligned}$$

ρ_{XY} 을 두 확률변수 X, Y 의 상관계수라 한다.



정리 8.5: $-1 \leq \rho_{X,Y} \leq 1$ 이고

$\rho_{X,Y} > 0$ 이면 X, Y 는 양(positive)의 상관관계가 있다고 하고,

$\rho_{X,Y} < 0$ 이면 X, Y 는 음(negative)의 상관관계가 있다고 한다.

$\rho_{X,Y} = 0$ 이면 X, Y 는 상관관계가 없다(uncorrelated)고 한다.

특히, 두 확률변수 X, Y 가 독립이면 $Cov(X, Y) = 0$ 으로 $\rho_{X,Y} = 0$ 이다.









상관계수

머신러닝을 위한
선형대수학

08 주성분 분석(PCA)을
이용한 데이터 표현과 특
징 추출

2. 결함 확률과 공분산





정의[공분산 행렬] 8.6: 확률변수 $X_1, X_2, \dots, X_n$ 에 대하여 다음의 $n \times n$ 행렬을 공분산 행렬이라고 한다.

$$\Sigma = \begin{pmatrix} Var(X_1) & Cov(X_1, X_2) & \dots & Cov(X_1, X_n) \\ Cov(X_2, X_1) & Var(X_2) & \dots & Cov(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ Cov(X_n, X_1) & Cov(X_n, X_2) & \dots & Var(X_n) \end{pmatrix}$$

분산과 공분산을 동시에 표현하는 것이 공분산 행렬(Covariance matrix)이다.



(1) 확률변수 X_1, X_2 의 공분산 행렬의 정의는 다음과 같다.

$$\Sigma = \begin{pmatrix} Var(X_1) & Cov(X_1, X_2) \\ Cov(X_2, X_1) & Var(X_2) \end{pmatrix}, \quad Cov(X_1, X_2) = Cov(X_2, X_1)$$

(2) 확률변수 X_1, X_2, X_3 의 공분산 행렬의 정의는 다음과 같다.

$$\Sigma = \begin{pmatrix} Var(X_1) & Cov(X_1, X_2) & Cov(X_1, X_3) \\ Cov(X_2, X_1) & Var(X_2) & Cov(X_2, X_3) \\ Cov(X_3, X_1) & Cov(X_3, X_2) & Var(X_3) \end{pmatrix}, \quad Cov(X_i, X_j) = Cov(X_j, X_i)$$



정리[기댓값 연산자] 8.7: 확률변수 $X_1, X_2, \dots, X_n$ 에 대하여 기댓값 연산자 E 는 선형연산자이다. 특히, 다음 두 가지 연산을 사용할 것이다.

$$(1) \quad E[a_1 X_1 + a_2 X_2 + \dots + a_n X_n] = a_1 E[X_1] + a_2 E[X_2] + \dots + a_n E[X_n]$$

$$(2) \quad E[a_1 g_1(X_1) + a_2 g_2(X_2) + \dots + a_n g_n(X_n)] \\ = a_1 E[g_1(X_1)] + a_2 E[g_2(X_2)] + \dots + a_n E[g(X_n)]$$



예제3: $Var[aX_1 + bX_2 + cX_3] = E[(aX_1 + bX_2 + cX_3 - E[aX_1 + bX_2 + cX_3])^2]$

$E[aX_1 + bX_2 + cX_3] = aE[X_1] + bE[X_2] + cE[X_3]$ 을 이용

$(a[X_1 - E(X_1)] + b[X_2 - E(X_2)] + c[X_3 - E(X_3)])^2$ 을 전개하면



$$\begin{aligned} & a^2 [X_1 - E(X_1)]^2 + b^2 [X_2 - E(X_2)]^2 + c^2 [X_3 - E(X_3)]^2 \\ & + 2ab[X_1 - E(X_1)][X_2 - E(X_2)] \\ & + 2bc[X_2 - E(X_2)][X_3 - E(X_3)] \\ & + 2ca[X_2 - E(X_2)][X_3 - E(X_3)] \end{aligned}$$



E 가 선형연산자 이므로

$$\begin{aligned} & a^2 E([X_1 - E(X_1)]^2) + b^2 E([X_2 - E(X_2)]^2) + c^2 E([X_3 - E(X_3)]^2) \\ & \quad + 2ab E([X_1 - E(X_1)][X_2 - E(X_2)]) \\ & \quad + 2bc E([X_2 - E(X_2)][X_3 - E(X_3)]) \\ & \quad + 2ca E([X_2 - E(X_2)][X_3 - E(X_3)]) \\ & = a^2 \text{Var}(X_1) + b^2 \text{Var}(X_2) + c^2 \text{Var}(X_3) \\ & \quad + 2ab \text{Cov}(X_1, X_2) + 2bc \text{Cov}(X_2, X_3) + 2ca \text{Cov}(X_2, X_3) \end{aligned}$$

3. 주성분분석(PCA)



어떤 고등학교에서 학생들을 대상으로 고전, 국어, 영어, 수학, 물리 시험 성적의 데이터를 가지고 있다고 하자.

자료의 연구 목적은 고전, 국어, 영어 성적이 연관성이 있는지, 아니면 고전, 국어 또는 국어, 영어 성적이 연관성이 있는지 또는 수학 물리 성적이 연관성이 있는지 알고 싶다고 생각해 보자.





이렇게 5개의 변수를 가지면 이를 5차원 벡터로 표시할 수 있다. 5차원 벡터는 시각적으로 3차원으로 보기는 어렵다. 어쩌면 2차원 데이터로 표현한다면 상당히 보기가 편할 수 있다.

$x = (\text{고전}, \text{국어}, \text{영어}, \text{수학}, \text{물리})$



고전과 국어성적을 2차원으로 표현해 봤더니 다음과 같은 그래프를 가졌다고 하자.





그림에서 보듯이 한 직선에 직교사영 해서 봐도 고전성적과 국어성적이 밀접한 관계가 있음을 알 수 있다. 위 비스듬한 직선은

$$\alpha(\text{고전성적}) + \beta(\text{국어성적})$$

과 같이 1차원 표시로도 알 수 있다.




$\alpha(\text{고전 성적}) + \beta(\text{국어 성적})$ 는 하나의 언어능력으로 묶어서 생각해도 무방하다.

즉, 고전, 국어 성적이 좋다는 뜻은 언어능력이 "좋다"란 말로 바꾸어 설명할 수 있다. 이것은 역으로 언어능력이 본질이 돼서 언어 성적들이 좋다고 생각할 수도 있다. 이런 의미에서 크게 원본 데이터의 특성을 보존하면서 차원을 줄이는 방법을 차원 축소라 한다. 이 경우 2차원에서 1차원으로 차원이 축소된 경우이다.


$\alpha(\text{고전 성적}) + \beta(\text{국어 성적}) + \gamma(\text{영어 성적})$ 인 경우를 생각하면 3차원에서 1차원으로 축소된 경우이다.




자!! 그럼 어떻게 일차결합으로 차원축소 선을 찾을 수 있을 까?라는 방법을 생각해 보자.
앞에 있는 그림을 다시 보면 평균에 붙어 있을수록 분산이 적고 반대인 경우는 분산이 크다.



[분산이 작다]



[분산이 크다]



위 두 정사영 중 어느 쪽이 분산이 크냐고 생각하면 두 번째가 분산이 크다.

이러한 자료의 특징을 포함하는 것이 공분산 행렬이다. 주성분 분석(pca)은 공분산 행렬에서 주성분들을 찾아내는 방법이다.



지금부터 단순하고 구체적인 예를 가지고 주성분분석 이론을 설명해보자.

여덟 명의 학생에 대해 키 몸무게 그리고 학점을 조사한 자료가 있다.

	X_1 :확률변수	X_2 :확률변수	X_3 :확률변수	$X = (X_1, X_2, X_3)$: 확률벡터
학생	x_1 : 키	x_2 : 몸무게	x_3 :학점	$x = (x_1, x_2, x_3)$
1	170	60	4.1	$x_1 = (170, 60, 4.1)$
2	165	55	3.0	$x_2 = (165, 55, 3.0)$
3	174	75	2.8	$x_3 = (174, 75, 2.8)$
4	169	67	2.9	$x_4 = (169, 67, 2.9)$
5	155	49	3.1	$x_5 = (155, 49, 3.1)$
6	172	63	3.6	$x_6 = (172, 63, 3.6)$
7	166	58	3.7	$x_7 = (166, 58, 3.7)$
8	168	61	4.0	$x_8 = (168, 61, 4.0)$
평균	167.375	61	3.4	
분산	33.6964	60.8571	0.2629	

샘플평균: $\mu_x = \frac{1}{n}(x_1 + x_2 + \dots + x_n) = \frac{1}{n} \sum_{i=1}^n x_i$

샘플분산: $Var(x) = \sigma_x^2 = \frac{1}{n-1}((x_1 - \mu)^2 + (x_2 - \mu)^2 + \dots + (x_n - \mu)^2)$

$$= \frac{1}{n-1} \sum_{i=1}^n (x_i - \mu)^2$$



두 확률변수 x, y 의 샘플 공분산:

x 의 샘플 데이터를 $x_1, x_2, \dots, x_n$

y 의 샘플 데이터를 $y_1, y_2, \dots, y_n$

x 의 평균을 $\mu_x = \frac{1}{n} \sum_{i=1}^n x_i$

y 의 평균을 $\mu_y = \frac{1}{n} \sum_{i=1}^n y_i$ 라 하면



샘플 공분산은 다음과 같다.

$$\begin{aligned} Cov(\mathbf{x}, \mathbf{y}) &= \frac{1}{n-1} [(x_1 - \mu_{\mathbf{x}})(y_1 - \mu_{\mathbf{y}}) + (x_2 - \mu_{\mathbf{x}})(y_2 - \mu_{\mathbf{y}}) + \cdots + ((x_n - \mu_{\mathbf{x}})(y_n - \mu_{\mathbf{y}}))] \\ &= \frac{1}{n-1} \sum_{i=1}^n (x_i - \mu_{\mathbf{x}})(y_i - \mu_{\mathbf{y}}) \end{aligned}$$

관찰: $Cov(\mathbf{y}, \mathbf{x}) = Cov(\mathbf{x}, \mathbf{y})$, $Cov(\mathbf{x}, \mathbf{x}) = Var(\mathbf{x}) = \sigma_{\mathbf{x}}^2$ 이다.

주어진 샘플데이터에서

$$Cov(x_1, x_2) = 39.4286, \quad Cov(x_1, x_3) = 0.3714, \quad Cov(x_2, x_3) = -0.9429$$

이다.



주어진 샘플데이터에서

$$Cov(x_1, x_2) = 39.4286, \quad Cov(x_1, x_3) = 0.3714, \quad Cov(x_2, x_3) = -0.9429$$

이다.

$$\Sigma = \begin{pmatrix} 33.696 & 39.429 & 0.371 \\ 39.429 & 60.857 & -0.942 \\ 0.371 & -0.942 & 0.263 \end{pmatrix} \quad (\text{위 예제의 공분산 행렬})$$



$$\mathbf{x} = (x_1, x_2, x_3)$$

확률변수 x_1, x_2, x_3 의 평균을 각각 $\bar{x}_1, \bar{x}_2, \bar{x}_3$ 라 하자.

$\hat{\mathbf{x}} = (x_1, x_2, x_3) - \bar{\mathbf{x}} = (x_1 - \bar{x}_1, x_2 - \bar{x}_2, x_3 - \bar{x}_3)$ 하면 외적을 사용하면

$$\hat{\mathbf{x}}^\top \hat{\mathbf{x}} = \begin{pmatrix} x_1 - \bar{x}_1 \\ x_2 - \bar{x}_2 \\ x_3 - \bar{x}_3 \end{pmatrix} \begin{pmatrix} x_1 - \bar{x}_1 & x_2 - \bar{x}_2 & x_3 - \bar{x}_3 \end{pmatrix}$$

$$= \begin{pmatrix} (x_1 - \bar{x}_1)^2 & (x_1 - \bar{x}_1)(x_2 - \bar{x}_2) & (x_1 - \bar{x}_1)(x_3 - \bar{x}_3) \\ (x_2 - \bar{x}_2)(x_1 - \bar{x}_1) & (x_2 - \bar{x}_2)^2 & (x_2 - \bar{x}_2)(x_3 - \bar{x}_3) \\ (x_3 - \bar{x}_3)(x_1 - \bar{x}_1) & (x_3 - \bar{x}_3)(x_2 - \bar{x}_2) & (x_3 - \bar{x}_3)^2 \end{pmatrix}$$

따라서 $\sum = \frac{1}{7} [\hat{\mathbf{x}}_1^\top \hat{\mathbf{x}}_1 + \hat{\mathbf{x}}_2^\top \hat{\mathbf{x}}_2 + \dots + \hat{\mathbf{x}}_8^\top \hat{\mathbf{x}}_8]$ 로 얻을 수 있다.



$$\hat{X} = \begin{pmatrix} \hat{x}_1 \\ \hat{x}_2 \\ \hat{x}_3 \\ \hat{x}_4 \\ \hat{x}_5 \\ \hat{x}_6 \\ \hat{x}_7 \\ \hat{x}_8 \end{pmatrix} = \begin{pmatrix} \hat{x}_{11} & \hat{x}_{12} & \hat{x}_{13} \\ \hat{x}_{21} & \hat{x}_{22} & \hat{x}_{23} \\ \hat{x}_{31} & \hat{x}_{32} & \hat{x}_{33} \\ \vdots & \vdots & \vdots \\ \hat{x}_{81} & \hat{x}_{82} & \hat{x}_{83} \end{pmatrix} \text{라 하면 } \Sigma = \frac{1}{7} \hat{X}^\top \hat{X} \text{가 된다.}$$




주성분분석 예제

머신러닝을 위한
선형대수학

08 주성분 분석(PCA)을
이용한 데이터 표현과 특
징 추출

3. 주성분분석(PCA)



x_1 : 키 , x_2 : 몸무게 , x_3 : 학점

$$Cov(x_1, x_2) = 39.4286, Cov(x_1, x_3) = 0.3714,$$

$$Cov(x_2, x_3) = -0.9429$$

이다.

$$\Sigma = \begin{pmatrix} 33.696 & 39.429 & 0.371 \\ 39.429 & 60.857 & -0.942 \\ 0.371 & -0.942 & 0.263 \end{pmatrix}$$




주성분분석 예제

머신러닝을 위한
선형대수학

08 주성분 분석(PCA)을
이용한 데이터 표현과 특
징 추출

3. 주성분분석(PCA)



x_1 : 키 , x_2 : 몸무게 , x_3 : 학점

$Cov(x_1, x_2) = 39.4286$, $Cov(x_1, x_3) = 0.3714$,

$Cov(x_2, x_3) = -0.9429$

이다.

$$\Sigma = \begin{pmatrix} 33.696 & 39.429 & 0.371 \\ 39.429 & 60.857 & -0.942 \\ 0.371 & -0.942 & 0.263 \end{pmatrix}$$




주성분분석 예제

머신러닝을 위한
선형대수학

08 주성분 분석(PCA)을
이용한 데이터 표현과 특
징 추출

3. 주성분분석(PCA)



x_1 : 키 , x_2 : 몸무게 , x_3 : 학점

$$Cov(x_1, x_2) = 39.4286, Cov(x_1, x_3) = 0.3714,$$

$$Cov(x_2, x_3) = -0.9429$$

이다.

$$\Sigma = \begin{pmatrix} 33.696 & 39.429 & 0.371 \\ 39.429 & 60.857 & -0.942 \\ 0.371 & -0.942 & 0.263 \end{pmatrix}$$




주성분분석 예제

머신러닝을 위한
선형대수학

08 주성분 분석(PCA)을
이용한 데이터 표현과 특
징 추출

3. 주성분분석(PCA)





지금부터 일차결합 확률변수 $ax_1 + bx_2 + cx_3$ 의 분산값을 구해보자. 우리의 목적은 분산 값을 최대화 하는 a, b, c 을 찾는 것이다.

기호로는 $Var[ax_1 + bx_2 + cx_3]$ 으로 표시한다.

$$Var[ax_1 + bx_2 + cx_3] = E[(ax_1 + bx_2 + cx_3 - E[ax_1 + bx_2 + cx_3])^2]$$

$E[ax_1 + bx_2 + cx_3] = aE[x_1] + bE[x_2] + cE[x_3]$ 을 이용

$(a[x_1 - E(x_1)] + b[x_2 - E(x_2)] + c[x_3 - E(x_3)])^2$ 을 전개하면



$$\begin{aligned} & a^2 [x_1 - E(x_1)]^2 + b^2 [x_2 - E(x_2)]^2 + c^2 [x_3 - E(x_3)]^2 \\ & + 2ab [x_1 - E(x_1)][x_2 - E(x_2)] \\ & + 2bc [x_2 - E(x_2)][x_3 - E(x_3)] \\ & + 2ca [x_2 - E(x_2)][x_3 - E(x_3)] \end{aligned}$$



E 가 선형연산자 이므로

$$\begin{aligned} & a^2 E([x_1 - E(x_1)]^2) + b^2 E([x_2 - E(x_2)]^2) + c^2 E([x_3 - E(x_3)]^2) \\ & + 2ab E([x_1 - E(x_1)][x_2 - E(x_2)]) \\ & + 2bc E([x_2 - E(x_2)][x_3 - E(x_3)]) \\ & + 2ca E([x_2 - E(x_2)][x_3 - E(x_3)]) \end{aligned}$$



$$= a^2 Var(x_1) + b^2 Var(x_2) + c^2 Var(x_3)$$

$$2ab Cov(x_1, x_2) + 2bc Cov(x_2, x_3) + 2ca Cov(x_1, x_3)$$

$$= (a \ b \ c) \begin{pmatrix} Var(x_1) & Cov(x_1, x_2) & Cov(x_1, x_3) \\ Cov(x_2, x_1) & Var(x_2) & Cov(x_2, x_3) \\ Cov(x_3, x_1) & Cov(x_3, x_2) & Var(x_3) \end{pmatrix} \begin{pmatrix} a \\ b \\ c \end{pmatrix},$$

$$v = \begin{pmatrix} a \\ b \\ c \end{pmatrix} \text{라 하면}$$

$$= v^T \Sigma v$$



사실 우리는 벡터 $v = \begin{pmatrix} u \\ b \\ c \end{pmatrix}$ 의 방향만 필요하기 때문에

Lagrange multiplier 방법을 이용하여 문제를 해결 할 수 있다.

$$\operatorname{argmax}_v v^T \sum v \quad \text{s.t.} \quad v^T v = 1, \quad \sum^T = \sum$$

$$L(v, \lambda) = v^T \sum v - \lambda(v^T v - 1)$$

$$0 = \frac{\partial}{\partial v} L(v, \lambda) = \frac{\partial}{\partial v} [v^T \sum v - \lambda(v^T v - 1)]$$

$$= \frac{\partial}{\partial v} [v^T \sum v - \lambda v^T v + \lambda] = 2 \sum v - 2 \lambda v$$



따라서 $\sum v = \lambda v$ 즉, v 는 고유벡터가 된다.

$$v^T \sum v = v^T \lambda v = \lambda v^T v = \lambda \text{ 에서}$$

고유값이 큰 고유벡터가 위 조건식을 만족한다.

$\sum$ 가 positive definite 행렬이면 모든 고유치 값은 0보다 크다.

공분산 행렬 $\sum$ 이 대칭행렬이므로 고유치가 다른 고유벡터들은 모두 직각을 이룬다.



마지막으로 $\Sigma = \frac{1}{7} \hat{X}^\top \hat{X}$

$\hat{X}$ svd를 $\hat{X} = U \Lambda V^\top$ 라 하자.

U : 8×8 직교행렬, Λ : 8×3 대각행렬, V : 3×3 직교행렬이다.

특히, $\Lambda = \begin{pmatrix} \sigma_1 & 0 & 0 \\ 0 & \sigma_2 & 0 \\ 0 & 0 & \sigma_3 \\ \vdots & \vdots & \ddots \\ 0 & 0 & 0 \end{pmatrix}$, $\sigma_1 \geq \sigma_2 \geq \sigma_3 \geq 0$, $\Lambda^\top \Lambda = \begin{pmatrix} \sigma_1^2 & 0 & 0 \\ 0 & \sigma_2^2 & 0 \\ 0 & 0 & \sigma_3^2 \end{pmatrix}$



$$\begin{aligned}\Sigma &= \frac{1}{7} \hat{X}^\top \hat{X} = \frac{1}{7} (U \Lambda V^\top)^\top (U \Lambda V^\top) \\ &= \frac{1}{7} (V \Lambda^\top U^\top) (U \Lambda V^\top) = \frac{1}{7} V \Lambda^\top \Lambda V^\top \\ &= V \begin{pmatrix} \frac{\sigma_1^2}{7} & 0 & 0 \\ 0 & \frac{\sigma_2^2}{7} & \\ 0 & 0 & \frac{\sigma_3^2}{7} \end{pmatrix} V^\top\end{aligned}$$



$\sum V = V \begin{pmatrix} \frac{\sigma_1^2}{7} & 0 & 0 \\ 0 & \frac{\sigma_2^2}{7} & \\ 0 & 0 & \frac{\sigma_3^2}{7} \end{pmatrix}$ 에서 V 의 열벡터가 공분산 행렬 $\sum$ 의 고유벡터임을 알 수 있다.



$\hat{X} = U \Lambda V^T$ 에서 V 의 열벡터가 주축(principal axes)가 된다.

$$\hat{X} = \begin{bmatrix} 2.6250 & -1.0000 & 0.7000 \\ -2.3750 & -6.0000 & -0.4000 \\ 6.6250 & 14.0000 & -0.6000 \\ 1.6250 & 6.0000 & -0.5000 \\ -12.3750 & -12.0000 & -0.3000 \\ 4.6250 & 2.0000 & 0.2000 \\ -1.3750 & -3.0000 & 0.3000 \\ 0.6250 & 0 & 0.6000 \end{bmatrix}$$

$$U = \begin{bmatrix} -0.0283 & 0.4420 & 0.2941 & 0.1761 & 0.7128 & -0.3569 & -0.0593 & -0.2177 \\ 0.2509 & 0.2316 & -0.7138 & 0.0692 & 0.1434 & -0.3158 & 0.1115 & 0.4862 \\ -0.6110 & -0.4398 & -0.0824 & -0.3695 & 0.4269 & -0.0726 & 0.2194 & 0.2330 \\ -0.2337 & -0.3491 & -0.1328 & 0.8932 & 0.0602 & 0.0495 & 0.0340 & -0.0286 \\ 0.6793 & -0.4957 & 0.0832 & -0.0470 & 0.4592 & 0.2642 & -0.0131 & 0.0536 \\ -0.1728 & 0.4126 & -0.1881 & 0.0262 & 0.2506 & 0.8335 & 0.0295 & 0.0734 \\ 0.1299 & 0.1041 & 0.1916 & 0.0705 & -0.0817 & 0.0100 & 0.9605 & -0.0351 \\ -0.0144 & 0.0942 & 0.5482 & 0.1480 & -0.0720 & 0.0238 & -0.1054 & 0.8072 \end{bmatrix}$$

$$\Lambda = \begin{bmatrix} 24.9574 & 0 & 0 \\ 0 & 6.3208 & 0 \\ 0 & 0 & 0.9423 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

$$V = \begin{bmatrix} -0.5806 & 0.8050 & -0.1219 \\ -0.8142 & -0.5729 & 0.0945 \\ 0.0062 & 0.1541 & 0.9880 \end{bmatrix}$$

$$\frac{1}{7} \Lambda^T \Lambda = \begin{bmatrix} 88.9820 & 0 & 0 \\ 0 & 5.7076 & 0 \\ 0 & 0 & 0.1269 \end{bmatrix}$$



주성분분석 이론 예제

머신러닝을 위한
선형대수학


08 주성분 분석(PCA)을
이용한 데이터 표현과 특
징 추출

3. 주성분분석(PCA)

주축으로 투영

$x = (x_1, x_2, x_3)$ 을 $v = (v_1, v_2, v_3)$ 을 축으로 하는 직선에 수직투영한 식은 $\langle x, v \rangle v$ 이다.

이식을 이용 주축 $v = \begin{pmatrix} -0.5806 \\ -0.8142 \\ 0.0062 \end{pmatrix}$ 식의 그림은 다음과 같다.



결론: 여덟 명의 학생에 대해 키 몸무게 그리고 학점을 조사한 자료를 가지고 주성분 분석하는 방법을 설명했다.



8.3-4: 주성분 분석 알고리즘

X 을 $n \times p$ 의 데이터행렬이라고 하자. 여기서 n 은 표본(sample)의 개수이고, p 는 데이터의 특성을 나타내는 확률변수 $\{x_1, x_2, \dots, x_p\}$ 의 개수이다.

$$X = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix}$$



Step1: 각 확률변수의 평균을 구한다.

$$\overline{x_1} = \frac{1}{n}(x_{11} + x_{21} + \dots + x_{n1}), \dots, \overline{x_p} = \frac{1}{n}(x_{1p} + x_{2p} + \dots + x_{np})$$

Step2: X 에서 각 샘플들에서 평균을 빼고 이를 다시 X 라 하자.

$$X = \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1p} \\ x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \dots & x_{np} \end{pmatrix} - \begin{pmatrix} \overline{x_1} & \overline{x_2} & \dots & \overline{x_p} \\ \overline{x_1} & \overline{x_2} & \dots & \overline{x_p} \\ \vdots & \vdots & \ddots & \vdots \\ \overline{x_1} & \overline{x_2} & \dots & \overline{x_p} \end{pmatrix}$$

step3: $[U \Lambda V] = svd(X)$

4. PCA응용: Eigenface와 영상인식응용



PCA의 응용으로 영상인식을 생각해 보자.

지금 45×40 의 영상 20장을 가지고 있다. 20장의 영상은 어느 보안회사에 근무하는 직원들의 얼굴이다. 우리는 20장의 영상을 가지고 cctv에 촬영된 영상을 비교하여 회사 보안직원이 맞는지를 판별하는 시스템을 PCA알고리즘을 가지고 구현할 여고 한다.





이미지에서 픽셀 밝기값을 일렬로 연결하여 벡터로 만들면 이들 각각의 얼굴 이미지는 $45 \times 40 = 1,800$ 차원의 벡터로 생각할 수 있다. 주어진 영상을 모두 흑백영상으로 변환한다.






Step 1: 20장의 영상으로 20×1800 인 행렬 X 을 만든다.

Step 2: 각 열벡터의 평균을 구하고 m 이라 하자.

$$A = X - m$$

Step3: 공분산 행렬 $\frac{1}{19} A^T A$ 의 고유치가 큰 고유벡터를 20개 구한다.

고유벡터 $v_1, v_2, \dots, v_{20}$



고유벡터에 의해서 구해진 영상을 흔히 eigenface라 부른다.



실제 위 이미지에 대해 얻어진 1,800개의 eigenface들 중 분산이 큰 순서대로 처음 20개를 나열한 것이다. 위 그림에서 볼 수 있듯이 앞부분 eigenface들은 데이터들에 공통된 요소(얼굴의 전반적인 형태)를 나타내고 뒤로 갈수록 세부적인 차이 정보를 나타낸다. 그리고 더 뒤로 가면 거의 노이즈(noise)성 정보를 나타낸다.



원 영상에 대하여 흑백으로 변형



$m = c_1v_1 + c_2v_2 + \dots + c_{20}v_{20}$ 에서

$c_1, c_2, \dots, c_{20}$ 을 계산하고 저장해 둔다.