

머신러닝을 위한 선형대수학

09 확률의 기초와 머신러닝 응용

목차 09 확률의 기초와 머신러닝 응용

1. 확률이론
2. 확률변수 (Random Variables)
3. 결합확률분포 (Joint probability distribution)
4. 나이브 베이즈 분류기와 마르코프 결정과정

1. 확률이론



우리 손 안에 한 개의 주사위가 있다고 하자. 주사위를 던지기 전에 우리는 어떤 숫자가 나올지 결과를 알 수 없다. 이러한 실험을 확률실험(random experiment)이라 부른다. 하지만 1,2,3,4,5,6중 하나가 나온다는 것을 알고 있다. 나올 수 있는 모든 경우를 포함하는 것을 표본공간(sample space)이라 부른다. 다음은 표본공간의 예이다.

(1) 확률실험: 주사위를 한 번 던지는 실험을 한다.

표본공간: $S = \{1, 2, 3, 4, 5, 6\}$

(2) 확률실험: 동전 두 개를 동시에 던지는 실험을 한다.

표본공간: $S = \{(H, H), (H, T), (T, H), (T, T)\}$

(3) 확률실험: 서로 다른 두 개의 주사위를 동시에 던지는 실험을 한다.

표본공간: $S = \left\{ \begin{array}{l} (1,1), (1,2), (1,3), (1,4), (1,5), (1,6), \\ (2,1), (2,2), (2,3), (2,4), (2,5), (2,6), \\ (3,1), (3,2), (3,3), (3,4), (3,5), (3,6), \\ (4,1), (4,2), (4,3), (4,4), (4,5), (4,6), \\ (5,1), (5,2), (5,3), (5,4), (5,5), (5,6), \\ (6,1), (6,2), (6,3), (6,4), (6,5), (6,6) \end{array} \right\}$



(4) 확률실험: 어느 스마트폰 가게에서 하루 동안 삼성스마트폰이 몇 개 팔리는지 관찰한다.

표본공간: $S = \{0, 1, 2, 3, \dots\}$

(5) 확률실험: 키, 몸무게, 학업 성적등을 조사하기 위해서 100명의 학생을 모집했다고 생각해보자. 사실 우리는 학생의 이름엔 큰 관심이 없다. 따라서 100의 학생들을 차례로 $s_1, s_2, \dots, s_{100}$ 라 하자.

표본공간: $S = \{s_1, s_2, \dots, s_{100}\}$



주사위를 한 번 던지는 실험을 생각해 보자. 이때 표본공간은 $S = \{1, 2, 3, 4, 5, 6\}$ 이다. 주사위를 던져서 1이 나올 확률은 특별한 경우가 아니라면 $\frac{1}{6}$ 이 된다. 주사위를 던져서 1 또는 3이 나올 확률을 생각하면 $\frac{2}{6} = \frac{1}{3}$ 이 된다. 이와 같이 표본공간 S 와 S 의 부분집합을 생각한다면 우리는 각각의 부분집합에 확률값을 부여할 수 있게 된다. 표본공간 S 의 부분집합 A 를 흔히 **사건(event)**이라 한다. 확률의 기본개념은 확률실험을 할 수 있는 곳에 표본공간이 존재하고 표본공간의 각 사건마다 확률값을 줄 수 있다는 가정에서 출발 한다.

많은 책들이 예외 없이 표본공간 개념에서부터 시작을 한다. 그리고 각 사건마다 어떻게 확률값을 부여하는지를 설명하고 있다. 여기에 기초적인 집합의 연산법칙이 사용된다. 아래 정의 되어있는 사건(events)은 수학적으로 정형화된 형식이다.



표본공간 S 의 부분집합 A 를 확률적인 용어로는 **사건(event)**이라 한다. 사건 A, B 에 대하여 $A \cap B$ 을 **곱사건(intersection of events)**, $A \cup B$ 을 **합사건(union of events)**, $S - A = A^c$ 을 **여사건(complementary events)**이라 부른다. 만약 $A \cap B = \emptyset$ 이면 A 와 B 는 서로 **배반사건(mutually exclusive events)**이라 부른다. 또한 $A_1, A_2, A_3, \dots$ 에 대하여

$$A_1 \cup A_2 \cup A_3 \cup \dots = \bigcup_{i=1}^{\infty} A_i$$

$$A_1 \cap A_2 \cap A_3 \cap \dots = \bigcap_{i=1}^{\infty} A_i$$

과 같이 무수히 많은 사건들에 대한 합사건 곱사건도 생각할 수 있다.

$A_1, A_2, A_3, \dots$ 에서 $A_i \cap A_j = \emptyset, i \neq j, i, j = 1, 2, 3, \dots$

이면 $\{A_i | i = 1, 2, 3, \dots\}$ 를 쌍마다 배반사건(pairwisely mutually exclusive events)이라 부른다.




우리가 본 대부분의 표본공간 S 에서 그리 어렵지 않게 각각의 사건 A 에 대하여 확률 $P(A)$ 를 계산할 수 있다. 몇 가지 예들을 살펴보자.

(1) 주사위를 한 번 던지는 실험에서 표본공간 $S = \{1, 2, 3, 4, 5, 6\}$ 이고 $A = \{1\}$ 에 대한 확률 $P(A) = \frac{1}{6}$ 과 같이 단순히 비율개념이 확률이 된다.



(2) 하나의 예를 더 살펴보자. 이번에는 10cm 선분 AB 위에 길이가 5cm 인 선분 CD 가 있다. 선분 AB 위에 어느 점을 임의의 선택할 때 선택될 가능성은 같다고 하자. 선분 AB 위에 임의의 한 점을 선택할 때 선분 CD 위에 점이 선택될 확률은

$$P(\overline{CD}) = \frac{\text{선분 } CD \text{의 길이}}{\text{선분 } AB \text{의 길이}} = \frac{5}{10} = \frac{1}{2}$$



이라고 할 수 있다.



두 예제에서 보듯이 확률값을 계산하는 방식이 다른 일도 있다는 것을 알 수 있다. 아마 많은 표본공간에서 확률을 계산하는 방법들이 여러 가지일 수 있다. 우리가 필요한 구체적인 표본공간에서 어떻게 확률값을 계산해야 하는지는 상황에 따라서 달라진다. 하지만 공통점도 있다. 표본공간이 있고 표본공간의 부분집합에 확률값이 있어야 한다. 이처럼 확률의 이론을 논리적으로 전개하는 데 있어서 어떤 성질을 가지면 큰 문제 없이 확률이론을 전개할 수 있느냐? 하는 문제에 학자들의 관심을 끌게 된다. 그래서 다음과 같이 공리론적 선택을 두고 이론을 전개한다. 공리론적 선택이란 “인간은 모든 표본공간에서 모든 확률을 정의할 수 있는 함수를 발견할 수 있는지는 의문이다. 하지만 이론을 계속 전개하자면 묻지도 말고 따지지도 말고 그렇다고 받아들이자.” 정도오 보면 정확히 이해된 것이다.



정의 9.1: 표본공간 S 안의 각 사건 A 에 대하여 하나의 양의 실수 $P(A)$ 를 대응하는 집합함수(set function) P 가 다음의 조건을 만족하면 P 를 확률(probability)이라 하고 함숫값 $P(A)$ 를 사건 A 의 확률(probability of the event A)이라고 한다.

(1) $0 \leq P(A) \leq 1$

(2) $P(S) = 1$

(3) $A \cap B = \emptyset$ 이면 $P(A \cup B) = P(A) + P(B)$ 이다.

(4) 쌍마다 배반인 사건들 $A_1, A_2, A_3, \dots$ 에 대하여

$$P(A_1 \cup A_2 \cup \dots) = \sum_{n=1}^{\infty} P(A_n)$$



참고: 여기서 P 를 확률(probability)이라고 부르나 최근 참고문헌 들은 P 를 probability measure라는 용어를 사용한다. 이는 수학의 한분야인 해석학에서 쓰는 용어로 "확률을 재는" 정도로 생각하면 될 것 같다. 이러한 움직임은 확률개념들을 좀 더 엄격한 개념중심의 공리화를 추구하는 것 같다.



조건부확률개념은 상당히 많은 응용분야를 가지고 있다. 꼼꼼히 공부해 두면 정말 유용하게 쓰인다. $A \subset S$ 라 하자. 조건부 확률개념은 A 라는 사건(부분집합)을 (제한된) 표본공간이라고 생각하고 그 안에서 확률을 생각하는 것이다. $P(B|A)$ 란 표시는 A 라는 제한된 표본공간에서 사건 B 가 일어나는 확률을 계산해 보자는 것이다. 이런 개념으로 생각해 보면 $P(B) = P(B|S)$ 와 같은 것이다. 즉, $P(B)$ 는 전체 표본공간 S 에서 B 의 확률값을 계산하는 것이다. 다음 예제가 잘 이해간다면 조건부 확률 개념을 잘 이해한 것이다.



예제 1: 남자와 여자가 합하여 60명이 있는 집단에서 남자는 35명 여자는 25명이다. 남자 중 안경을 쓴 사람은 10명이고 여자 중 안경을 쓴 사람도 10명이다. 일단 표를 그려 보면 알아보기가 쉽다.

	남자	여자	합계
안경착용	10	10	20
안경 미착용	25	15	40
합계	35	25	60

여기서 몇 가지 확률계산을 해보자.

(1) 전체 인원에서 안경 낀 사람의 확률은?

$$P(\text{안경 낀 사람}) = \frac{20}{60} = \frac{1}{3} \text{이다.}$$



	남자	여자	합계
안경착용	10	10	20
안경 미착용	25	15	40
합계	35	25	60

(2) 조건부 확률이란 제한된 상황에서 확률을 계산하는 방법이다. 남자 중 안경을 쓴 사람의 확률은 얼마일까?

$$P(\text{안경 낀 사람} \mid \text{남자 중}) = \frac{10}{35} = \frac{2}{7}$$

여자 중 안경을 낀 사람의 확률도 조건부 확률이다.

$$P(\text{안경 낀 사람} \mid \text{여자 중}) = \frac{10}{25} = \frac{2}{5}$$



	남자	여자	합계
안경착용	10	10	20
안경 미착용	25	15	40
합계	35	25	60

(3) 안경 낀 사람 중 남자의 확률 또는 안경 낀 사람 중 여자의 확률 얼마일까?

$$P(\text{남자}|\text{안경 낀 사람}) = \frac{10}{20}, \quad P(\text{여자}|\text{안경 낀 사람}) = \frac{10}{20}$$



고등학교 조건부 확률의 복습:

어느 정도 조건부확률에 대한 이해가 갔으면 고등학교 때 배운 조건부 확률을 복습해 보자.

표본공간의 두 사건 A, B 에 대하여 $P(B|A)$ 는 주어진 사건 A 에 대한 사건 B 의 조건부 확률이라고 다음과 같은 계산 법칙이 성립한다.

$$P(B|A) = \frac{P(B \cap A)}{P(A)}.$$



예제 2: 두 개의 주사위를 던지는 실험에서 두 주사위의 눈의 합을 X 라 하자. X 가 홀수라고 할 때 X 가 8보다 적은 확률을 구해보자.

[풀이] X 가 홀수인 사건을 A , X 가 8보다 적은 사건을 B 라 하자. 그러면 우리가 구하는 확률은 $P(B|A)$ 이다. 처음이니까 다 한번 나열해 보자.

A 가 일어날 사건은 $A = 3, 5, 7, 9, 11$ 이고 B 가 일어날 사건은 $B = 3, 5, 7$ 이다.

A 사건을 모두 나열해 보면

$A = 3$: $(1, 2), (2, 1)$

$A = 5$: $(1, 4), (2, 3), (3, 2), (4, 1)$

$A = 7$: $(1, 6), (2, 5), (3, 4), (4, 3), (5, 2), (6, 1)$

$A = 9$: $(3, 6), (4, 5), (5, 4), (6, 3)$

$A = 11$: $(5, 6), (6, 5)$

모두 18가지가 있다. 이중 B 사건은 12가지이다.



따라서 $P(B|A) = \frac{12}{18} = \frac{2}{3}$ 이다.

$P(B|A) = \frac{P(B \cap A)}{P(A)}$ 인 공식을 사용하면


$$\begin{aligned} P(A) &= P(A=3) + P(A=5) + P(A=7) + P(A=9) + P(A=11) \\ &= \frac{2}{36} + \frac{4}{36} + \frac{6}{36} + \frac{4}{36} + \frac{2}{36} = \frac{1}{2} \end{aligned}$$

$$\begin{aligned} P(A \cap B) &= P(A \cap B=3) + P(A \cap B=5) + P(A \cap B=7) \\ &= \frac{2}{36} + \frac{4}{36} + \frac{6}{36} = \frac{1}{3} \end{aligned}$$

따라서 $P(B|A) = \frac{P(B \cap A)}{P(A)} = \frac{2}{3}$



그림과 같이 표본공간 S 가 네 개의 사건 A_1, A_2, A_3, A_4 으로 분할(partition)되었다고 하자. 여기서 분할이란 의미는 $S = A_1 \cup A_2 \cup A_3 \cup A_4$ 이고 $A_i \cap A_j = \emptyset, i \neq j$ 인 경우를 말한다. 이 경우 확률 $P(B)$ 을 구하는 경우를 생각해보자.



조건부 확률공식 $P(B|A) = \frac{P(B \cap A)}{P(A)}$ 을 변형하여 $P(B \cap A) = P(A)P(B|A)$ 인 공식을 사용한다.



$$\begin{aligned}P(B) &= P(B \cap S) \\&= P(B \cap (A_1 \cup A_2 \cup A_3 \cup A_4)) \\&= P([B \cap A_1] \cup [B \cap A_2] \cup [B \cap A_3] \cup [B \cap A_4]) \\&= P(B \cap A_1) + P(B \cap A_2) + P(B \cap A_3) + P(B \cap A_4) \\&= \sum_{i=1}^4 P(B \cap A_i) = \sum_{i=1}^4 P(A_i)P(B | A_i)\end{aligned}$$

정리[전확률공식] 9.2: 사건 $A_1, A_2, \dots, A_n$ 이 표본공간 S 의 분할이고 $P(A_i) > 0$,
($i = 1, 2, \dots, n$)이면 임의의 사건 B 에 대하여 다음 확률공식이 성립한다.

$$P(B) = \sum_{i=1}^n P(A_i)P(B | A_i)$$



예제1: 세 개의 종이상자 B_1, B_2, B_3 에 각각 4개의 공이 들어있다. B_1 에는 빨간공 2개 파란공 2개, B_2 에는 빨간공 3개 파란공 1개, B_3 에는 빨간공 1개 파란공 3개가 들어있다. 세 종이상자 중 우연히 하나를 선택하여 공을 꺼낼 때 꺼낸 공이 빨간공일 확률을 구하라.

[풀이] 구하는 확률을 $P(Red)$ 라 하자.

$$\begin{aligned} P(Red) &= P(B_1 \cap Red) + P(B_2 \cap Red) + P(B_3 \cap Red) \\ &= P(B_1)P(Red | B_1) + P(B_2)P(Red | B_2) + P(B_3)P(Red | B_3) \\ &= \frac{1}{3} \times \frac{2}{4} + \frac{1}{3} \times \frac{3}{4} + \frac{1}{3} \times \frac{1}{4} = \frac{1}{3} \times \frac{6}{4} = \frac{1}{2} \end{aligned}$$



예제2: 남자가 40% 여자가 60%인 모임에서 어떤 시험을 봤는데 남자의 50%, 여자의 70%가 시험에 통과 했다고 한다. 그러면 전체 인원 중 시험에 통과한 인원은 몇 %인가?

[풀이] 시험에 통과한 인원의 확률을 $P(Pass)$ 로 하자.

$$\begin{aligned} P(Pass) &= P(\text{남자} \cap Pass) + P(\text{여자} \cap Pass) \\ &= P(\text{남자})P(Pass | \text{남자}) + P(\text{여자})P(Pass | \text{여자}) \\ &= 0.4 \times 0.5 + 0.6 \times 0.7 = 0.62 \end{aligned}$$

따라서 통과인원은 62%이다.



예제3: 인구의 5%가 독감바이러스 보균자이고 95%는 보균자가 아니다. 독감바이러스 감별시약이 개발되었는데 독감바이러스 보균자에게는 95% 양성반응을 보이고 보균자가 아닌 경우는 1%의 양성반응을 보인다고 한다. 임의로 한사람을 택하여 시약테스트를 할 때 양성인 나올 %는 얼마인가?

[풀이] 시약테스트 하여 양성인 나올 확률을 $P(Positive)$ 라 하자.

$$\begin{aligned}P(Positive) &= P(Positive \cap \text{보균자}) + P(Positive \cap \text{비보균자}) \\&= P(\text{보균자})P(Positive | \text{보균자}) + P(\text{비보균자})P(Positive | \text{비보균자}) \\&= 0.05 \times 0.95 + 0.95 \times 0.01 = 0.057\end{aligned}$$

따라서 양성인 나올 확률은 5.7%이다.



예제4: 500원 짜리 동전이 5개 있다. 이 중 하나의 동전이 위조되어 양면이 모두 학이 그려져 있다. 5개의 동전 중 무작위로 하나를 택하여 던졌을 때 학모양이 나올 확률은 얼마인가?



[풀이] 사건 A_1 을 위조되지 않은 동전, 사건 A_2 을 위조된 동전이라 하자,

$$P(A_1) = 0.8, P(A_2) = 0.2 \text{이다.}$$

5개의 동전 중 하나를 선택하여 던질 때 학모양이 나오는 사건을 B 라 하자.

$$\text{그러면 } P(B) = P(B \cap A_1) + P(B \cap A_2)$$

$$= P(A_1)P(B|A_1) + P(A_2)P(B|A_2)$$

$$= 0.8 \times \frac{1}{2} + 0.2 \times 1 = 0.6$$

이 된다.



공식 $P(B|A) = \frac{P(B \cap A)}{P(A)}$ 에서 A, B 을 바꾸면 $P(A|B) = \frac{P(A \cap B)}{P(B)}$ 이다.

위 두 식에서

$$P(B \cap A) = P(A)P(B|A), \quad P(A \cap B) = P(B)P(A|B)$$

이고 $P(A \cap B) = P(B \cap A)$ 이므로

$$P(A \cap B) = P(B)P(A|B) = P(A)P(B|A) \text{ 이다.}$$

따라서 베이즈 정리라 부르는 다음 식을 얻는다.

$$P(A|B) = \frac{P(A)P(B|A)}{P(B)}$$

베이즈 공식은 쉽게 이해될 것 같으면서 이해하기 어렵게 느껴지는 공식이다.



예제1: 어느 농장에 아주 가끔 멧돼지가 출몰하여 곡물창고를 부수는 일이 있다. 이일 때문에 농장주인은 경보기를 설치하였다. 멧돼지의 출현확률은 1%이다. 멧돼지를 포함한 야생동물의 출몰로 인하여 경보기가 울리는 확률은 10%이다. 멧돼지의 출몰로 인하여 경보가 울리는 확률은 90%이다. 그러면 경보가 울렸을 때 진짜 멧돼지가 출몰할 확률은 몇 %인가?

[풀이] 구하는 확률을 $P(\text{멧돼지 출현} \mid \text{경보})$ 라 하자. 그러면 베이즈 정리에 의해서

$$\begin{aligned} P(\text{멧돼지 출현} \mid \text{경보}) &= \frac{P(\text{멧돼지 출현})P(\text{경보} \mid \text{멧돼지 출현})}{P(\text{경보})} \\ &= \frac{0.01 \times 0.9}{0.1} = 0.09 \end{aligned}$$

따라서 $P(\text{멧돼지 출현} \mid \text{경보}) = 9\%$ 이다.



예제2: 모처럼 자전거를 타고 멀리가려고 한다. 그런데 하늘을 보니 구름이 끼어 있다. 비 오면서 구름이 끼는 확률은 50% 이다. 하지만 이지방의 특성상 40%의 확률로 항상 구름이 낀다. 최근 이 지방에서 비올 확률은 10% 이다. 그러면 구름이 낀 상태에서 비올 확률은 몇 %인가?

[풀이] 구하는 확률을 $P(Rain | Cloud)$ 라 하자. 그러면 베이즈 정리에 의해서

$$\begin{aligned} P(Rain | Cloud) &= \frac{P(Rain)P(Cloud | Rain)}{P(Cloud)} \\ &= \frac{0.1 \times 0.5}{0.4} = 0.125 \end{aligned}$$

따라서 $P(Rain | Cloud) = 12.5\%$ 이다.



예제3: 50-60대 남성들을 대상으로 조사했더니 남성의 10%가 간질환을 가지고 있었다. 또한 남성의 5%는 알콜중독 증상을 보였다. 그리고 간질환자 중 7%은 알콜 중독자 였다. 그러면 알콜중독자 중 간질환자는 몇 %인가?

[풀이] 구하는 확률을 $P(\text{간 질환자} | \text{알콜 중독자})$ 라 하자.

$$\begin{aligned} P(\text{간 질환자} | \text{알콜 중독자}) &= \frac{P(\text{간 질환자})P(\text{알콜중독자} | \text{간 질환자})}{P(\text{알콜 중독자})} \\ &= \frac{0.1 \times 0.07}{0.05} = 0.14 \end{aligned}$$

따라서 알콜 중독자 중 간질환자는 14%이다.



이번에는 베이즈 정리를 좀 더 일반화 해보자.

사건 $A_1, A_2, \dots, A_n$ 이 표본공간 S 의 분할이다. 즉, $S = A_1 \cup A_2 \cup \dots \cup A_n$ 이고 $i \neq j$ 이면 $A_i \cap A_j = \emptyset$ 이다. 또한 $P(A_i) > 0$ 이라고 하자. 임의의 사건 B , $P(B) > 0$ 에 대하여 베이즈 정리에 의해서

$$P(A_k | B) = \frac{P(A_k)P(B | A_k)}{P(B)}$$

이 성립한다.



$$\begin{aligned}\text{여기서 } P(B) &= P(B \cap S) = P(B \cap (A_1 \cup A_2 \cup \dots \cup A_n)) \\ &= P([B \cap A_1] \cup [B \cap A_2] \cup \dots \cup [B \cap A_n]) \\ &= P(B \cap A_1) + P(B \cap A_2) + \dots + P(B \cap A_n) \\ &= \sum_{i=1}^n P(B \cap A_i) \\ &= \sum_{i=1}^n P(A_i)P(B | A_i)\end{aligned}$$

따라서 $P(A_k | B) = \frac{P(A_k)P(B | A_k)}{\sum_{i=1}^n P(A_i)P(B | A_i)}$ 이 성립한다.



정리[베이지 정리] 9.3: 사건 $A_1, A_2, \dots, A_n$ 이 표본공간 S 의 분할이고 $P(A_i) > 0$,
($i = 1, 2, \dots, n$)이면 임의의 사건 B , $P(B) > 0$ 에 대하여 다음 확률공식이 성립한다.

$$P(A_k | B) = \frac{P(A_k)P(B | A_k)}{\sum_{i=1}^n P(A_i)P(B | A_i)}$$



예제4: 어느 공장에서 두 대의 기계 M_1, M_2 를 이용하여 제품을 생산하는데 각각 전제품의 10%, 90%을 생산한다고 한다. 제품의 불량률은 각각 10%, 4%라고 한다. 이 공장에서 생산된 제품들 중에서 무작위로 하나를 선택했는데 불량품이었다고 한다면 이 불량품이 M_1 기계에서 나올 확률은 얼마인가?

[풀이] 두 대의 기계 M_1, M_2 에서 생산 되는 사건을 각각 M_1, M_2 라 하자. B 을 불량품 일 사건이라 하자. 그러면 구하는 확률은 $P(M_1 | B)$ 이다.

$$P(M_1 | B) = \frac{P(M_1)P(B | M_1)}{P(M_1)P(B | M_1) + P(M_2)P(B | M_2)} \text{이고}$$

$P(M_1) = 0.1, P(M_2) = 0.9, P(B | M_1) = 0.1, P(B | M_2) = 0.04$ 에서

$$P(M_1 | B) = \frac{0.1 \times 0.1}{0.1 \times 0.1 + 0.9 \times 0.04} = 0.22$$



예제5: 어느 나라의 총 인구의 1%는 유전적 결함이 있는 것으로 알려져 있다. 최근개발된 유전자 결함 검사 방법은 유전자 결함이 있는 사람을 테스트 하면 90%의 양성반응을 나타낸다. 하지만 유전자 결함이 없는 사람들에게도 9.6% 비율로 양성반응을 나타낸다. 무작위로 뽑힌 사람이 테스트 결과 양성 반응을 보였다. 그러면 이 사람이 유전적 결함이 있을 확률은 얼마인가?

[풀이] A : 인구 중 유전적 결함이 있는 사건

X : 검사 결과 양성일 사건

우리가 구하는 확률은 $P(A | X)$ 이다.

$$\begin{aligned} P(A | X) &= \frac{P(A)P(X | A)}{P(X)} \\ &= \frac{P(A)P(X | A)}{P(X \cap A) + P(X \cap A^c)} \\ &= \frac{P(A)P(X | A)}{P(A)P(X | A) + P(A^c)P(X | A^c)} \\ &= \frac{0.01 \times 0.9}{0.01 \times 0.9 + 0.99 \times 0.096} = 0.0865 \text{ (8.65\%)} \end{aligned}$$



예제6: 어느 나라의 40세 여성이 유방암에 걸린 확률은 통계적으로 0.4%라고 한다. 유방암 조기 진단을 위해서는 X선 검사가 있다. 유방암이 있는 경우 X선 검사가 양성반응을 보이는 확률은 80%라 한다. 유방암이 없는 경우도 10%의 양성반응을 보인다고 한다. 그러면 어떤 사람이 X선 검사가 양성반응을 보였을 때 유방암일 확률은 얼마인가?

[풀이] A : 유방암 환자의 사건

X : 검사 결과 양성일 사건

우리가 구하는 확률은 $P(A | X)$ 이다.

$$\begin{aligned} P(A | X) &= \frac{P(A)P(X | A)}{P(A)P(X | A) + P(A^c)P(X | A^c)} \\ &= \frac{0.004 \times 0.8}{0.004 \times 0.8 + 0.996 \times 0.01} = 0.0311 \text{ (3.11\%)} \end{aligned}$$



1.9 베이즈 정리(Bayes's theorem) 와 MLE 그리고 MAP

MLE(Maximum Likelihood Estimation)& MAP(Maximum A Posterior)

1. 베이즈정리

$$P(A | B) = \frac{P(A \cap B)}{P(B)} = \frac{P(A)P(B | A)}{P(B)}$$



2. MLE(Maximum Likelihood Estimation)

하나의 동전을 100번 던져 봤는데 앞면이 70번 나왔고 뒷면이 30번 나왔다고 해보자. 여러분은 어떻게 생각하는가? 앞면이 많이 나온다고 생각하는가? 아니면 50%의 확률인데 “우연히 이번에 앞면이 많이 나왔나 보다”라고 단순히 생각하는가? 이 문제는 답하기 쉬운 문제 같지만 돈 내기를 할 때와 같은 어떤 경우에는 답하기 힘들다. 금액이 큰 경우는 더 결정하기 쉽지 않다. 위의 동전을 가지고 한번 동전을 던져서 나온 쪽을 맞추면 100만 원을 주는 내기를 한다고 생각해보자. 못 맞추면 내가 100만 원을 줘야 한다. 이런 내기를 한다면 여러분은 앞과 뒷면 중 어느 쪽에 내기를 걸겠는가? 내 경우라면 앞면에 내 운을 맡길 것 같다.

만약 뒷면에 돈을 걸어서 맞추면 200만 원을 준다고 생각해보자. 이 경우는 또 다른 고민이 생긴다. 50%의 확률인데 “우연히 앞면이 잘 나왔나” 생각하면서 뒷면에 100만 원을 걸 수도 있다. 만약 1000번의 동전을 던져서 700번이 앞면이 나왔고 300번이 뒷면이 나왔다고 생각해보자. 그러면 200만 원을 받기 위해서 뒷면에 내 돈을 거는 게 조심스러워질 수도 있다.



100번 던져서 70번이 앞면이 나왔으면 MLE입장에서는 앞면이 $\frac{7}{10}$ 의 확률로 나온다는 심
증을 다음과 같이 수학적 이론이 지지해 준다. 왜 그런지 알아보자.

동전을 던지는 행위는 매 시행마다 독립적(Independent)이고 항등적인 분포(Identically distributed)를 가지는 이항분포(Binomial distribution)로 모델링이 가능하다.

앞면이 나올 확률을 θ , 앞면 나온 횟수를 a_H , 뒷면이 나온 횟수를 a_T 라 하자.

θ 가 주어진 상황에서 관측결과를 D 라 하자. 즉, D 는 n 번 던진다면
 $D = \{d_1, d_2, \dots, d_n\}$ (d_i 는 앞 또는 뒷면)이 된다. $n = a_H + a_T$ 가 된다.

동전을 n 번 던졌을 때 나오는 확률은

$$P(D | \theta) = \theta^{a_H} (1 - \theta)^{a_T}$$

이 된다.



MLE(Maximum Likelihood Estimation)은 $P(D|\theta)$ 가 최대가 되게 하는 θ 을 찾는 것이다. 즉, 데이터 셋 D 가 나올 수 있는 최대의 $\hat{\theta}_{MLE}$ 을 구하는 것이다.

$$\hat{\theta}_{MLE} = \operatorname{argmax}_{\theta} P(D|\theta) = \operatorname{argmax}_{\theta} \theta^{a_H} (1-\theta)^{a_T} \dots \textcircled{1}$$

식 ①에 $\hat{\theta}_{MLE}$ 을 구하는 것은 번거로움이 있다. 그래서 다음과 같이 자연로그 $\ln$ 을 취해 준다.

$$\begin{aligned}\hat{\theta}_{MLE} &= \operatorname{argmax}_{\theta} \ln P(D|\theta) = \operatorname{argmax}_{\theta} \ln \{ \theta^{a_H} (1-\theta)^{a_T} \} \\ &= \operatorname{argmax}_{\theta} \{ a_H \ln \theta + a_T \ln (1-\theta) \}\end{aligned}$$



θ 로 미분해서 0이 되는 곳을 찾아보면

$$\frac{d}{d\theta} \{a_H \ln \theta + a_T \ln (1 - \theta)\} = 0$$

$\frac{a_H}{\theta} - \frac{a_T}{1 - \theta} = 0$ 에서 $\theta = \frac{a_H}{a_H + a_T} = \frac{a_H}{n}$ 이다.

θ 가 주어진 상황에서 관측결과를 D 가 최대가 되는 경우는

$$\hat{\theta}_{MLE} = \frac{a_H}{n}$$

인 경우다. 이것은 앞면이 많이 나올 것 같은 우리의 추측을 수학적으로 뒷받침 해 주고 있다. 이것이 MLE이다.



1.10 MLE의 치명적인 단점

100번 동전을 던져서 70번이 앞면이 나왔다고 하면 이 동전은 앞면이 많이 나온다고 생각할 수 있을 것 같다. 하지만 10번 던져서 7번이 앞면이 나온다면 약간 고개가 갸우뚱 거릴 수 있다. MLE 의 단점은 10번 던져서 7번이 앞면이 나오든

10000번 던져서 7000번이 앞면이 나오든 MLE 의 추정값은 $\frac{7}{10}$ 으로 같다는 것이다.



Hoeffding 부등식(Hoeffding's Inequality)

던진 횟수 또는 샘플 개수를 N 이라 하자. θ 을 우리가 구하고자 하는 실제의 확률값이라고 하고 $\hat{\theta}$ 을 MLE 을 통해 구한 확률값 이라고 하자. 그러면 Hoeffding 부등식은 다음과 같이 주어진다.

$$P(|\hat{\theta} - \theta| \geq \epsilon) \leq 2e^{-2N\epsilon^2}$$

여기서 ϵ 값을 작으면 작을수록 좋을 것이다. $\epsilon = 0.1$ 이라면

$$P(|\hat{\theta} - \theta| \geq 0.1) \leq 2e^{-2N0.1^2}$$

인 식을 얻게 된다.



$N=100$ 일 때 $2e^{-2 \times N \times 0.1^2}$ 을 계산해 보면 $2e^{-2 \times 100 \times 0.1^2} = 0.2707$ 이다.

즉, $P(|\hat{\theta} - \theta| \geq 0.01) \leq 0.2707$ 인데

우리의 생각대로 $N=100$ 일 때 70번이 앞면이 나왔다면 $\hat{\theta}=0.7$ 이 의미가 있음을 암시하고 있다.

$N=10$ 인 경우 $2e^{-2 \times 10 \times 0.1^2} = 1.6375$ 이다.

사실 $P(|\hat{\theta} - \theta| \geq 0.1) \leq 1$ 인데 그 보다는 더 큰 값 1.6375값을 준다는 것은 $N=10$ 이란 값은 전혀 신뢰성이 없음을 보여준다.

$N=200$ 이면 $2e^{-2 \times 200 \times 0.1^2} = 0.0366$ 인 값을 얻는다.

참고적으로 ϵ 값이 작을수록 상대적으로 매우 큰 N 값이 요구된다.



$\theta = 0.4$ 에서 $\theta = 0.9$ 까지 나누어 10번 던져서 7번이 나오는 경우 앞면이 나올 확률을 구해보면

$$P(Head \mid \theta = 0.4) = \binom{10}{7} \times 0.4^7 \times 0.6^3 = 0.425$$

$$P(Head \mid \theta = 0.5) = \binom{10}{7} \times 0.5^7 \times 0.5^3 = 0.1172$$

$$P(Head \mid \theta = 0.6) = \binom{10}{7} \times 0.6^7 \times 0.4^3 = 0.2150$$

$$P(Head \mid \theta = 0.7) = \binom{10}{7} \times 0.7^7 \times 0.3^3 = 0.2668$$

$$P(Head \mid \theta = 0.8) = \binom{10}{7} \times 0.8^7 \times 0.2^3 = 0.2013$$

$$P(Head \mid \theta = 0.9) = \binom{10}{7} \times 0.9^7 \times 0.1^3 = 0.0574$$

에서 $H = 0.7$ 인 경우가 확률값이 크다. 하지만 $H = 0.5$ 가 아니라고 단정 하기는 어렵다.



1.11 MAP(Maximum A Posterior) : 사전 확률을 알 수 만 있다면 흔들리지 않는다.

MAP는 $P(\theta | D)$ 을 구해보는 것이다. D 라는 데이터가 주어진 상황에서 θ 을 추측해 보는 것이다. 즉, 사후확률을 구하는 방법이다.

베이즈 정리에 의하면

$$P(\theta | D) = \frac{p(\theta)p(D|\theta)}{p(D)} \propto p(\theta)p(D|\theta)$$

위 식에서 $p(D)$ 값은 일정한 값이므로 식 $p(\theta)p(D|\theta)$ 에서 θ 을 최대화 하는식을 유도해 보자.



$$\begin{aligned}\hat{\theta}_{MAP} &= \operatorname{argmax}_{\theta} P(\theta \mid D) = \operatorname{argmax}_{\theta} p(\theta) p(D \mid \theta) \\ &= \operatorname{argmax}_{\theta} \ln [p(\theta) p(D \mid \theta)] \\ &= \operatorname{argmax}_{\theta} \{ \ln p(\theta) + \ln p(D \mid \theta) \} \\ &= \operatorname{argmax}_{\theta} \{ \ln p(\theta) + a_H \ln \theta + a_T \ln (1 - \theta) \}\end{aligned}$$

MAP와 MLE을 비교하자면 MAP는 MLE에 사전확률인 $p(\theta)$ 로 weight를 주고 있다. 사전확률 $p(\theta)$ 가 균일분포(uniform distribution)라 가정해보자. 이것은 선택할 수 있는 θ 에 모두 같은 weight값을 부여하게 된다는 의미인데, 이 경우는 MAP와 MLE는 같게 된다.



MAP(Maximum A Posterior)

머신러닝을 위한
선형대수학

09 확률의 기초와 머신러
닝 응용

1. 확률이론

$$\begin{aligned}\hat{\theta}_{MAP} &= \operatorname{argmax}_{\theta} \ln(p(\theta)p(D|\theta)) \\ &= \operatorname{argmax}_{\theta} \{\ln p(\theta) + \ln p(D|\theta)\} \\ &= \operatorname{argmax}_{\theta} \{\text{const} + \ln p(D|\theta)\} \\ &= \operatorname{argmax}_{\theta} \{a_H \ln \theta + a_T \ln(1 - \theta)\} \\ &= \hat{\theta}_{MLE}\end{aligned}$$



MLE는 θ 값이 고정된다는 개념이고 MAP는 θ 을 확률변수로 생각하는 것이다.

동전을 10번 던져서 7번의 앞면과 3번의 뒷면이 나온 사건을 MAP방법으로 계산해 보자.

이때 $p(\theta)$ 을 결정해야 하는데 $\theta = 0.5$ 인 확률을 $p(\theta = 0.5) = 0.8$,
 $\theta = 0.6$, $\theta = 0.7$ 인 확률을 각각 $p(\theta = 0.6) = p(\theta = 0.7) = 0.1$ 이라 해보자. 물론 동전의
앞면이 나오는 확률이 현실에서는 우리의 가정처럼 변하지는 않는다. 하지만 MAP를 설명
하기는 아주 좋다.

Hypotheses	Prior	Likelihood	prior*likelihood	posterior
$\theta = 0.5$	$p(0.5) = 0.8$	0.1172	0.0938	0.6606
$\theta = 0.6$	$p(0.6) = 0.1$	0.2150	0.0215	0.1515
$\theta = 0.7$	$p(0.7) = 0.1$	0.2668	0.0267	0.1880
Total	1		0.1419	1

위 표에서 posterior값은 각각을 전체 합 0.1419으로 나눈 값(normalized values)이다.
보듯이 $\theta = 0.7$ 일 때 Likelihood값이 최대인 것을 볼 수 있다. 하지만 MAP값은 사전확률
인 $p(\theta)$ 로 weight가 주어졌기 때문에 $\theta = 0.5$ 에서 최대인 것을 볼 수 있다. 지금까지 살
펴보았듯이 사전확률은 정확한 확률을 계산하는데 아주 중요한 역할을 한다.



사전확률과 사후확률을 아주 잘 이해할 수 있는 아주 멋진 예제가 있다[생각에 관한 생각: 대니얼 카너먼].

질문:

미국 어느 지역에서 Steve란 사람이 무작위로 뽑혔다고 가정하다. 어느 이웃이 스티브를 이렇게 묘사 했다. “스티브는 아주 수줍고 내성적이며 언제나 남을 돕지만 현실 세계에 관심은 거의 없다. 온순하고 찬찬한 그는 질서와 체계를 중시하고 아주 꼼꼼한 남자다.” 그러면 과연 Steve는 그 지역에서 사서일 확률이 높을까, 아니면 농부일 확률이 높을까?

질문에서 $P(\text{사서} | \text{주어진 특성})$, $P(\text{농부} | \text{주어진 특성})$ 중 어느 쪽이 큰 값을 가지느냐 하는 것이다.




얼핏 주어진 특성을 보면 Steve는 사서일 확률이 높아 보인다. $P(\text{사서} \mid \text{주어진 특성})$, $P(\text{농부} \mid \text{주어진 특성})$ 는 소위 사후확률이다. 이 연구가 진행될 때 미국에서 사서와 농부의 비율은 1 : 20쯤 이었다고 한다. 만약 사서가 10명 이면 농부가 200이 된다. 사서 중 Steve와 같은 성격의 소유자가 40%라 하고 농부 중에서는 10%정도라 생각해보자. 즉, 사서 중에서 Steve와 같은 성격의 소유자가 농부에 비해 4배나 많은 셈이다. 하지만 문제는 사전확률이다. $P(\text{사서})$ 의 확률이 $P(\text{농부})$ 에 비해 매우 적은편이다. 사후확률을 구해보면 다음과 같다.



아래 그림은 사서와 농부의 비율 1 : 20를 사서 10명과 농부 200명으로 표현한 것이다.

사서 중 주어진 특성을 갖는 사람은 4명 뿐 이고 농부는 20명이나 된다.





$$P(\text{사서} \mid \text{주어진 특성}) = \frac{P(\text{사서})P(\text{주어진 특성} \mid \text{사서})}{P(\text{주어진 특성})}$$

$$= \frac{P(\text{사서})P(\text{주어진 특성} \mid \text{사서})}{P(\text{사서})P(\text{주어진 특성} \mid \text{사서}) + P(\text{농부})P(\text{주어진 특성} \mid \text{농부})}$$

$$= \frac{\frac{1}{21} \times 0.4}{\frac{1}{21} \times 0.4 + \frac{20}{21} \times 0.1} = 0.167$$

$$P(\text{농부} \mid \text{주어진 특성})$$

$$= \frac{P(\text{농부})P(\text{주어진 특성} \mid \text{농부})}{P(\text{사서})P(\text{주어진 특성} \mid \text{사서}) + P(\text{농부})P(\text{주어진 특성} \mid \text{농부})}$$

$$= \frac{\frac{20}{21} \times 0.4}{\frac{1}{21} \times 0.4 + \frac{20}{21} \times 0.1} = 0.833$$

2. 확률변수 (Random Variables)



확률변수는 크게 이산확률변수(discrete random variable)와 연속확률변수(continuous random variable)로 구분한다. 이산확률변수는 다루는 값들이 유한개 이거나 자연수와 같이 셀 수 있는 경우를 의미하고, 반면 연속확률변수는 취할 수 있는 확률변수의 값이 구간으로 표시되는 경우이다.

2.1 확률변수(Random variable)와 상태공간(State Space)

100명의 학생을 표본으로 하는 표본공간공간을 $S = \{s_1, s_2, \dots, s_{100}\}$ 라 하자. 그러면 각각의 학생 s_i 에 대하여 어떤 값을 확인할 수 있다. 몇 가지 예들을 보자.



보기1: 학생들의 키 정보

학생들의 개개인의 키 정보 보다는 키의 크기를 적당한 구간으로 나누어 키의 분포를 알고 싶어 한다.

계급표시	H_1	H_2	H_3	H_4	H_5
키(cm) 이상-미만	155-160	160-165	165-170	170-175	175-180
학생 수(명)	10	20	32	24	14

각각의 학생들의 키가 $H(s_1) = 171cm$, $H(s_2) = 173cm$, $\dots$, $H(s_{100}) = 179cm$ 이라 하면 각각의 학생들의 키의 값은 H_1, H_2, H_3, H_4, H_5 중 한 곳에 속하게 된다. 즉,

$H(s_1) = H_4$, $H(s_2) = H_4$, $\dots$, $H(s_{100}) = H_5$ 이라 할 수 있다.



H 는 하나의 함수가 된다.

$$H : S = \{s_1, s_2, \dots, s_{100}\} \rightarrow H = \{H_1, H_2, H_3, H_4, H_5\}$$

이러한 H 를 확률변수라 한다. 학생을 표시하는 표본공간 $S = \{s_1, s_2, \dots, s_{100}\}$ 는 $H = \{H_1, H_2, H_3, H_4, H_5\}$ 에 의해서 분할 되게 된다. 이때 $H = \{H_1, H_2, H_3, H_4, H_5\}$ 상태공간(state space)이라고 한다.

각각의 H_i 에 대하여 확률값을 부여할 수 있다.

즉, $P(H_i) = \frac{\#(H_i)}{100}$, $\#(H_i)$: H_i 에 속한 학생들의 수.

$$P(H_3) = \frac{\#(H_3)}{100} = \frac{32}{100}$$



보기2: 학생들의 몸무게 정보

계급표시	W_1	W_2	W_3	W_4	W_5
몸무게(kg) 이상-미만	50-55	55-60	60-65	65-70	70-75
학생 수(명)	10	19	37	23	11

각각의 학생들의 몸무게가 $W(s_1) = 65kg$, $W(s_2) = 64kg$, $\dots$, $W(s_{100}) = 70kg$ 이라 하면 각각의 학생들의 키의 값은 W_1, W_2, W_3, W_4, W_5 중 한곳에 속하게 된다. 즉, $W(s_1) = W_4$, $W(s_2) = W_4$, $\dots$, $W(s_{100}) = W_5$ 이 된다.

W 는 하나의 함수가 된다.

$$W : S = \{s_1, s_2, \dots, s_{100}\} \rightarrow W = \{W_1, W_2, W_3, W_4, W_5\}$$

함수 W 을 확률변수, $W = \{W_1, W_2, W_3, W_4, W_5\}$ 을 상태공간이라고 한다.



보기3: 학생들의 수학성적

$M(s_1) = 75$ 점, $M(s_2) = 85$ 점, $\dots$, $M(s_{100}) = 100$ 점

계급표시	M_1	M_2	M_3	M_4	M_5	M_6
성적 이상-미만	60-65	65-70	70-75	75-80	80-85	85-90
학생 수(명)	36	23	12	19	5	5

위의 보기에서 보듯이 우리가 필요로 하는 정보인 키, 몸무게, 수학성적 등을 체크 할 수 있다. 체크된 값들은 필요한 경우 보기들과 같이 계급별로 나누어 처리하기도 하고 그냥 사용하기도 한다.



정의[확률변수] 2.1: 표본공간 S 에서 실수로 가는 함수를 확률변수(random variable)라고 한다. $X : S \rightarrow R$ 그리고 이 함수의 치역을 상태공간(state space)이라고 한다.
 $X(s) = x \in R$ 이면 간단히 $X = x$ 라 표시한다.

중요사항:

- (1) 많은 책들에서 확률변수는 표본공간에서 실수로 가는 함수라고 정의라고 있다. 위 보기들은 아닌 경우처럼 보인다. 하지만 상태공간 $H = \{H_1, H_2, H_3, H_4, H_5\}$ 을 단순히 $H = \{1, 2, 3, 4, 5\}$ 로 표현하면 표본공간에서 실수로의 함수로 생각해도 전혀 문제가 되지 않는다.
- (2) 또한 상태공간의 확률을 표시할 때 단순히 $P(1) = P(H_1)$ 로 표현하지 않고 $P(H=1)$ 로 표시한다. 당연한 얘기지만 보통 우리는 상태공간의 부분집합들에 대한 확률에 관심을 가질 것이다. 사실 상태공간 자체를 확률변수라 봐도 무방하다.



확률변수란 표본공간을 분할하고 분할된 각 사건에게 확률값을 부여하는 것이다.

10명	→ G_1
20명	→ G_2
30명	→ G_3
24명	→ G_4
13명	→ G_5

[확률변수: 표본공간 분할]

보통 확률을 다루는 책들에서 상태공간을 S_X 라 표시한다.

다음은 책에서 흔히 보는 확률변수와 상태공간의 예들이다.



보기4: 주사위를 한 번 던지는 실험을 한다.

표본공간: $S = \{1, 2, 3, 4, 5, 6\}$

$X : S = \{1, 2, 3, 4, 5, 6\} \rightarrow R, X(i) = i$ 로 하면 이는 확률변수이다.

상태공간: $S_X = \{1, 2, 3, 4, 5, 6\}$

여기서 확률변수 X 의 값은 $X = 1, 2, 3, 4, 5, 6$ 이다.



보기5: 동전 두 개를 던지는 실험을 한다.

표본공간 $S = \{(H, H), (H, T), (T, H), (T, T)\}$

$Y : S = \{(H, H), (H, T), (T, H), (T, T)\} \rightarrow R$ 인데 다음과 같이 정의 되었다고 하자.

$$Y(H, H) = 2, \quad Y(H, T) = 1, \quad Y(T, H) = 1, \quad Y(T, T) = 0$$

정의에 따라 Y 도 확률변수이다.

상태공간: $Y_S = \{0, 1, 2\}$

여기서 확률변수 Y 가 값은 $Y = 0, 1, 2$ 이다.



확률함수(Probability function): 확률함수에는 두 가지 종류가 있다. 지금 공부하고 있는 이산 확률변수인 경우는 확률질량함수(probability mass function: pmf)라 부르고 확률변수가 연속인 경우는 확률밀도함수(probability density function: pdf)라고 부른다. 확률변수 $X : S \rightarrow R$ 에 대하여 상태공간을 $S_X = X(S)$ 라 하자. $x \in S_X$ 에 대하여 확률값 $f_X(x)$ 을 정의할 것이다.


$x \in S_X$ 에 대하여 $X^{-1}(x) = \{s \in S \mid X(s) = x\}$ 라 하자 (아래 그림 참조). 즉, $X^{-1}(x)$ 는 표본공간 S 의 부분집합이다. 따라서 확률값을 부여할 수 있다, $f_X(x) = P(X^{-1}(x))$.

많은 책에서 $P(X^{-1}(x))$ 대신 간단히 $P(X=x)$ 라는 표현을 사용한다.

$P(X=x) = f_X(x) = P(X^{-1}(x))$ 이다.



결론: $f_X(x) = P(X=x) = P(X^{-1}(x))$



$$X^{-1}(x) = \{1, 2, 3\}$$

$$X^{-1}(y) = \{4, 5\}$$

계급표시	H_1	H_2	H_3	H_4	H_5
키(cm) 이상-미만	155-160	160-165	165-170	170-175	175-180
학생 수(명)	10	20	32	24	14

확률변수가 주어지면 표본공간이 분할되고 분할된 표본공간은 상태공간의 원소들로 구분하게 된다. 따라서 각각의 상태공간 원소에 확률을 부여하는 것을 확률함수라 한다.



(1) 주사위를 한 번 던지는 실험을 한다.

$S_X = \{1, 2, 3, 4, 5, 6\}$ 이고 $P(X=i) = f_X(i) = \frac{1}{6}, i = 1, 2, \dots, 6$ 라 정의하면

이는 확률 함수이다. 즉, 확률함수란 상태공간의 원소들에게 확률값을 부여하는 것이다.

(2) 동전 두 개를 던지는 실험을 한다.

$Y_S = \{0, 1, 2\}$ 이고 $P(Y=0) = f_Y(0) = \frac{1}{4}, P(Y=1) = f_Y(1) = \frac{1}{2},$

$P(Y=2) = f_Y(2) = \frac{1}{4}$



확률질량함수의 성질 9.4: 이산 확률변수 X 의 상태공간을 S_X 라 하자. 확률질량함수

$f : S_X \rightarrow [0, 1]$ 에 대하여

(1) 모든 $x \in S_X$ 에 대하여 $0 \leq f(x) \leq 1$ 이다.

(2) $\sum_{x \in S_X} f(x) = 1$

계급표시	H_1	H_2	H_3	H_4	H_5
키(cm) 이상-미만	155-160	160-165	165-170	170-175	175-180
학생 수(명)	10	20	32	24	14
확률	10/100	20/100	32/100	24/100	14/100

또한 $A \subset S_X$ 에 대하여 확률값 $f(A)$ 도 f 를 이용하여 구할 수 있다.

$$f(X \in A) = \sum_{x \in A} f(x)$$

참고: $f(X \in A) = f(A)$ 인 의미이다.

계급표시	W_1	W_2	W_3	W_4	W_5
몸무게(kg) 이상-미만	50-55	55-60	60-65	65-70	70-75
학생 수(명)	10	19	37	23	11
확률	10/100	19/100	37/100	23/100	11/100



2.2 연속확률변수


확률변수 X 가 연속적인 구간에서 값을 가지거나 좀더 나가서 구간들의 합집합에서 값을 가지는 확률변수를 연속확률변수(continuous random variable)라 한다.

정의[확률밀도 함수] 9.5: 연속확률변수 X 에 대하여 함수 $f(x)$ 가 다음 성질을 만족하면 $f(x)$ 를 X 의 확률밀도함수(probability density function)라 한다.

(1) 모든 실수 x 에 대하여 $f(x) \geq 0$

$$(2) \int_{-\infty}^{\infty} f(x)dx = 1$$

$$(3) P(a \leq X \leq b) = \int_a^b f(x)dx$$



이산확률의 경우에는 한 점에서의 확률값이 주어지지만 $f_X(a) = P(X = a)$, 연속확률변수의 경우는 임의의 점에서의 확률값은 0 이 된다.

$$P(X = a) = P(a \leq X \leq a) = \int_a^a f(x)dx = 0$$



정의[기댓값] 9.6: X 가 확률분포 $f(x)$ 를 가지는 확률변수라 하자.

X 가 이산형인 경우 X 의 평균(또는 기댓값)은

$$\mu = E[X] = \sum_x x f(x) = \sum_x x p(X=x)$$

X 가 연속인 경우 X 의 (평균 또는 기댓값)은

$$\mu = E[X] = \int_{-\infty}^{\infty} x f(x) dx$$



예제1: 표와 같이 상자 안에 10개의 제비가 들어있다. 이 중 한 개의 제비를 뽑을 때 기대되는 상금의 평균금액을 구하라.

등수	제비 수	상금(원)
1등	1	1000
2등	2	500
3등	3	200
등외	4	0

[풀이] 상금을 X 원 이라 하면 X 가 가지는 값은 1000, 500, 200, 0이고 이에 대한 확률값은 $\frac{1}{10}, \frac{2}{10}, \frac{3}{10}, \frac{4}{10}$ 이다. 이를 표로 그려보면 아래와 같다.

X	1000	500	200	0	합
$P(X = x_i)$	$\frac{1}{10}$	$\frac{2}{10}$	$\frac{3}{10}$	$\frac{4}{10}$	1

상금의 기댓값은 $\mu = E[X] = \sum_x xp(X = x)$

$$= 1000 \times \frac{1}{10} + 500 \times \frac{2}{10} + 200 \times \frac{3}{10} + 0 \times \frac{4}{10} = 260 \text{ (원)}$$



일반적으로 확률변수 X 와 함수 $g(x)$ 에 의해서 생기는 새로운 확률변수를 $Y = g(X)$ 라 하면 Y 에 대한 기댓값은 다음 정리와 같이 $g(x)$, X , $f(x)$ 을 이용해서 구할 수 있다.

정리 9.7: X 가 확률분포 $f(x)$ 를 가지는 확률변수일 때, 확률변수 $Y = g(X)$ 의 평균 혹은 기댓값은 다음과 같다.

$Y = g(X)$ 의 평균:

$$\mu_{g(X)} = E[g(X)] = \begin{cases} \sum_x g(x)f(x): X \text{가 이산인 경우} \\ \int_{-\infty}^{\infty} g(x)f(x)dx: X \text{가 연속인 경우} \end{cases}$$



몇 가지 잘 사용되는 기댓값 성질은 다음과 같다.

$$(1) \ E[aX] = aE[X]$$

$$(2) \ E[aX + b] = aE[X] + b$$

$$(3) \ E[a h(X) + b k(X)] = a E[h(X)] + b E[k(X)]$$



정의[분산(Variance)] 9.8: X 가 확률분포 $f(x)$ 를 가지는 확률변수라 하자.

X 의 기댓값 $\mu = E[X]$ 에 대하여

X 가 이산형인 경우 X 의 분산(variance) $E[(X - \mu)^2] = \sum_x (x - \mu)^2 f(x)$

X 가 연속인 경우 X 의 분산(variance) $E[(X - \mu)^2] = \int_{-\infty}^{\infty} (x - \mu)^2 f(x) dx$

분산은 확률변수 X 의 분포가 평균을 중심으로 밀집된 정도를 나타내는 척도가 된다. 이때

분산을 $Var(X)$ 또는 σ^2 으로 표시한다. 이때 표준편차(standard deviation)은 다음과

같이 정의 된다.

$$\sigma = \sqrt{E[(x - \mu)^2]}$$

분산공식은 다음과 같이 변형된다.

$$\begin{aligned}\sigma^2 &= E[(X - \mu)^2] = E[X^2 - 2\mu X + \mu^2] \\ &= E[X^2] - 2\mu E[X] + \mu^2 \\ &= E[X^2] - \mu^2\end{aligned}$$

3. 결합확률분포 (Joint probability distribution)



100명의 학생을 표본으로 하는 표본공간공간을 $S = \{s_1, s_2, \dots, s_{100}\}$ 라 하자.

앞에서 다루었던 보기1, 보기2 문제를 다시 살펴보자.

보기1: 학생들의 키 정보

계급표시	H_1	H_2	H_3	H_4	H_5
키(cm) 이상-미만	155-160	160-165	165-170	170-175	175-180
학생 수(명)	10	20	32	24	14

참고로, 학생들의 키가 $H(s_1) = 171cm$, $H(s_2) = 173cm$, $\dots$, $H(s_{100}) = 179cm$ 이라 하였다.



보기2: 학생들의 몸무게 정보

계급표시	W_1	W_2	W_3	W_4	W_5
몸무게(kg) 이상-미만	50-55	55-60	60-65	65-70	70-75
학생 수(명)	10	19	37	23	11

참고로 학생들의 몸무게가 $W(s_1) = 65kg$, $W(s_2) = 64kg$, $\dots$, $W(s_{100}) = 70kg$ 이라 하였다.



보기 1,2에서 우리는 학생들의 키와 몸무게를 계급을 나누어 분포를 확인하였다. 이번에는 각 학생들의 키와 몸무게를 함께(joint) 표현하는 방법을 알아보자. $H(s_1) = 171cm$, $W(s_1) = 65kg$ 이므로 $(H(s_1), W(s_1)) = (H_4, W_4)$ 가 된다.

같은 방법으로 $H(s_2) = 173cm$, $W(s_2) = 64kg$ 이므로 $(H(s_2), W(s_2)) = (H_4, W_3)$ 가 된다. 모든 s_i , $i = 1, 2, \dots, 100$ 에 대하여 $(H(s_i), W(s_i))$ 을 생각할 수 있다. 이것은 두 확률변수 H, W 을 결합해서 생각하는 방식으로 말 그대로 결합분포이다. 결합분포도 하나의 함수로 표현된다. $S \rightarrow R^2: s_i \rightarrow (H(s_i), W(s_i))$. 두 확률변수의 순서쌍 (H, W) 을 확률벡터라 부른다.



다음 표는 모든 s_i , $i = 1, 2, \dots, 100$ 에 대하여 $(H(s_i), W(s_i))$ 값을 표로 정리한 것이다.

	H_1	H_2	H_3	H_4	H_5	합계
W_1	6	2	2			10
W_2	2	12	5			19
W_3	1	4	20	12		37
W_4	1	2	5	8	7	23
W_5				4	7	11
합계	10	20	32	24	14	100

[H_i : 키, W_i : 몸무게]

	H_1	H_2	H_3	H_4	H_5	확률
W_1	6/100	2/100	2/100			10/100
W_2	2/100	12/100	5/100			19/100
W_3	1/100	4/100	20/100	12/100		37/100
W_4	1/100	2/100	5/100	8/100	7/100	23/100
W_5				4/100	7/100	11/100
확률	10/100	20/100	32/100	24/100	14/100	1

두 확률변수 H, W 가 각각 표본공간을 분할하고 분할된 각 사건에게 확률값을 부여하는 것과 같은 방법으로, 위 표를 가지고도 표본공간을 분할하고 각 사건에 대하여 확률값을 부

여할 수 있다. 예를 들면 (H_1, W_1) 의 확률값은 $P(H_1, W_1) = \frac{6}{100}$,

(H_2, W_2) 의 확률값은 $P(H_2, W_2) = \frac{12}{100}$ 이다.



$A = \{(H_1, W_1), (H_2, W_2)\}$ 라 하면

$$P(A) = \{(H_1, W_1), (H_2, W_2)\} = \frac{6}{100} + \frac{12}{100} = \frac{18}{100} \text{ 이 된다.}$$

일반적으로 확률분포 함수를 f 라 표시하면 확률벡터 (H, W) 의 확률은

$$f(H_1, W_1) = P(H_1, W_1) = \frac{6}{100},$$

$$f(H_1, W_2) = P(H_1, W_2) = \frac{2}{100},$$

$$f(H_1, W_3) = P(H_1, W_3) = \frac{1}{100},$$

...

으로 구할 수 있다.

위 방법을 일반화 하면

$$X = (X, Y): \text{대응 확률함수 } f(x, y),$$

$$X = (X, Y, Z): \text{대응 확률함수 } f(x, y, z),$$

⋮

$$X = (X_1, X_2, \dots, X_n): \text{대응 확률함수 } f(x_1, x_2, \dots, x_n)$$

	H_1	H_2	H_3	H_4	H_5	확률
W_1	6/100	2/100	2/100			10/100
W_2	2/100	12/100	5/100			19/100
W_3	1/100	4/100	20/100	12/100		37/100
W_4	1/100	2/100	5/100	8/100	7/100	23/100
W_5				4/100	7/100	11/100
확률	10/100	20/100	32/100	24/100	14/100	1



일반적인 확률벡터 $X = (X_1, X_2, \dots, X_n)$ 을 다루기 전에 두 확률변수를 가지는 벡터 $X = (X, Y)$ 에 대하여 좀 더 자세히 살펴보고 가자.

3.1 2변수 결합확률 분포

정의 9.9: [결합확률질량함수] 확률벡터 $X = (X, Y)$ 에 대하여 다음 조건이 만족될 때, 함수 $f(x, y)$ 를 이산확률변수 X 와 Y 의 결합확률분포 또는 결합확률질량함수(joint probability mass function: j.p.m.f)라 한다.

(1) $f : X \times Y \rightarrow [0, 1]$: 모든 x, y 에 대하여 $0 \leq f(x, y) \leq 1$ 이다.

(2) $\sum_{\text{모든 } x} \sum_{\text{모든 } y} f(x, y) = 1$

(3) $P(a < X \leq b, c < Y \leq d) = \sum_{a < x \leq b} \sum_{c < y \leq d} f(x, y)$ 이다.

	H_1	H_2	H_3	H_4	H_5	확률
W_1	6/100	2/100	2/100			10/100
W_2	2/100	12/100	5/100			19/100
W_3	1/100	4/100	20/100	12/100		37/100
W_4	1/100	2/100	5/100	8/100	7/100	23/100
W_5				4/100	7/100	11/100
확률	10/100	20/100	32/100	24/100	14/100	1



정의 9.10: [주변확률질량함수] 확률벡터 $X = (X, Y)$ 에서 각각의 확률변수 X, Y 에 대한 확률분포는 결합확률질량함수 $f(x, y)$ 로 부터 유도된다.

$$f_X(x) = \sum_{\text{모든 } y} f(x, y)$$

$$f_Y(y) = \sum_{\text{모든 } x} f(x, y)$$

계급표시	H_1	H_2	H_3	H_4	H_5
키(cm) 이상-미만	155-160	160-165	165-170	170-175	175-180
학생 수(명)	10	20	32	24	14
확률	10/100	20/100	32/100	24/100	14/100

$f_X(x)$ 을 X 의 주변질량함수(marginal probability mass function: m.p.m.f), $f_Y(y)$ 을 Y 의 주변질량함수라 한다. 사실 확률변수 X 의 확률함수가 $f_X(x)$ 이다. 마찬가지로 확률변수 Y 의 확률함수가 $f_Y(y)$ 이다.

계급표시	W_1	W_2	W_3	W_4	W_5
몸무게(kg) 이상-미만	50-55	55-60	60-65	65-70	70-75
학생 수(명)	10	19	37	23	11
확률	10/100	19/100	37/100	23/100	11/100

	H_1	H_2	H_3	H_4	H_5	확률
W_1	6/100	2/100	2/100			10/100
W_2	2/100	12/100	5/100			19/100
W_3	1/100	4/100	20/100	12/100		37/100
W_4	1/100	2/100	5/100	8/100	7/100	23/100
W_5				4/100	7/100	11/100
확률	10/100	20/100	32/100	24/100	14/100	1



정의 9.11: [결합밀도함수] 확률벡터 $X = (X, Y)$ 에 대하여 다음 조건이 만족될 때 함수 $f(x, y)$ 를 연속확률변수 X 와 Y 의 결합밀도함수(joint probability density function: j.p.d.f))라 한다.


$$f : D \rightarrow [0, 1], \quad D \subset \mathbb{R}^2$$

(1) 모든 $(x, y) \in D$ 에 대하여 $f(x, y) \geq 0$

$$(2) \quad \iint_D f(x, y) dx dy = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = 1$$

(3) $A = \{(x, y) \mid a \leq x \leq b, c \leq y \leq d\}$ 에 대하여

$$P((X, Y) \in A) = \iint_A f(x, y) dy dx = \int_a^b \int_c^d f(x, y) dy dx$$





정의 9.12: [주변확률밀도함수] X 와 Y 의 주변확률밀도함수(marginal probability density function: m.p.d.f)는 다음과 같이 정의된다.

$$f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy, \quad f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx$$



일반적으로 확률벡터 $X = (X_1, X_2, \dots, X_n)$ 에 대하여 확률분포함수 $f(x_1, x_2, \dots, x_n)$ 을 생각할 수 있다. 이산인 경우 $f(x_1, x_2, \dots, x_n)$ 을 결합확률질량함수(joint probability mass function: j.p.m.f)라 부르고 연속이면 $f(x_1, x_2, \dots, x_n)$ 을 결합밀도함수(joint probability density function: j.p.d.f))라 부른다. 확률값을 계산할 때, 이산인 경우는 다중 합을 사용하고 연속인 경우는 다중적분을 사용한다.

$A \subset X$ 라 하면

이산인 경우: $P((X_1, X_2, \dots, X_n) \in A) = \sum \cdots_{x \in A} \sum f(x_1, x_2, \dots, x_n)$

연속인 경우: $P((X_1, X_2, \dots, X_n) \in A) = \int \cdots_{x \in A} \int f(x_1, x_2, \dots, x_n)$



이때 주변 밀도 함수 $f_{X_i}(x_i)$ 는 다음과 같이 정의된다.

$$f_{X_i}(x_i) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} f(x_1, x_2, \cdots, x_n) dx_1 dx_2 \cdots dx_{i-1} dx_{i+1} \cdots dx_n$$

즉, x_i 성분을 제외한 나머지 값을 적분함으로써 얻어진다.

특히, 주변밀도 함수 $f_{X_i}(x_i)$ 는 확률변수들의 독립을 결정하는 척도가 된다.

또한 필요에 의해서 다양한 주변밀도 함수를 생각할 수 있다.

예를 들면 주변밀도 함수 $f_{X_1 X_2}(x_1, x_2)$ 는 다음과 같다.

$$f_{X_1 X_2}(x_1, x_2) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} f(x_1, x_2, \cdots, x_n) dx_3 \cdots dx_n$$

4. 나이브 베이즈 분류기와 마르코프 결정과정



보통 책에서 확률변수들은 대문자 $X, Y, Z, \dots$ 또는 $X_1, X_2, X_3, \dots$ 을 사용하고
구체적인 값을 표시할 때는 $X = x, Y = y, Z = z$ 등으로 표시한다.

동시에 확률값을 구할때는

$$p(x, y) = p(X = x \text{ and } Y = y)$$

$$p(x, y, z) = p(X = x \text{ and } Y = y \text{ and } Z = z)$$

확률변수 X, Y 가 독립인 경우는 $p(x, y) = p(x)p(y)$ 이다.

확률변수 X, Y, Z 가 독립인 경우는 $p(x, y, z) = p(x)p(y)p(z)$ 이다.

이것은 두 사건 A, B 에 대하여 $P(A \cap B) = P(A)P(B)$ 가 성립하면 두 사건 A, B 는
독립이라 것과 같은 표시이다.



앞에서 배운 조건 부확률의 정의와 같이 $p(A|B) = \frac{p(A \cap B)}{p(B)}$

확률변수의 조건부 확률도 같다.

$$p(x | y) = \frac{p(x, y)}{p(y)}$$

확률변수 X, Y 가 독립이면

$$p(x | y) = \frac{p(x, y)}{p(y)} = \frac{p(x)p(y)}{p(y)} = p(x)$$

이 뜻은 $Y = y$ 라는 제약조건이 의미가 없다는 뜻이다.



또한 $p(A \cap B) = p(A|B)p(B)$ 과 같이

$$p(x, y) = p(x | y)p(y) = p(y | x)p(x)$$

이 성립한다.

유사하게

$$p(x, y, z) = p(x, y | z)p(z) = p(x | y, z)p(y, z)$$

성립한다.



예제1: 조건부확률 연습하기 위해서 다음이 성립하는 지 유도해 보자.

$$p(x | y, z) = \frac{p(y | x, z)p(x | z)}{p(y | z)}$$

[풀이]

$$\begin{aligned} p(x | y, z) &= \frac{p(x, y, z)}{p(y, z)} = \frac{p(y | x, z)p(x, z)}{p(y | z)p(z)} \\ &= \frac{p(y | x, z)p(x | z)p(z)}{p(y | z)p(z)} = \frac{p(y | x, z)p(x | z)}{p(y | z)} \end{aligned}$$



4.2 조건부독립: $p(x, y | z) = p(x | z)p(y | z)$

이것을 다르게 표현하면, 즉, 위식과 동치이다.

$$p(x | y, z) = p(x | z), \quad p(y | x, z) = p(y | z)$$

$$\text{[증명]} \quad (\Rightarrow) p(x | y, z) = \frac{p(x, y, z)}{p(y, z)} = \frac{p(x, y | z)p(z)}{p(y, z)}$$

$$= \frac{p(x | z)p(y | z)p(z)}{p(y | z)p(z)} = p(x | z)$$

$$(\Leftarrow) p(x, y | z) = \frac{p(x, y, z)}{p(z)} = \frac{p(x | y, z)p(y, z)}{p(z)}$$

$$= \frac{p(x | y, z)p(y | z)p(z)}{p(z)} = \frac{p(x | z)p(y | z)p(z)}{p(z)} = p(x | z)p(y | z)$$



나이브 베이즈 분류기나 마르코프 모델에서 공부하겠지만 다음과 같이 일반적인 조건부 확률 기호들이 등장한다.

$$p(y \mid x_1, x_2, \dots, x_n)$$

$x_1, x_2, \dots, x_n$ 조건 하에서 y 의 확률값이 얼마나 라는 뜻이다.

$$p(y, z \mid x_1, x_2, \dots, x_n)$$

$x_1, x_2, \dots, x_n$ 조건 하에서 y 와 z 가 동시에 일어나는 확률값이 얼마나 라는 뜻이다.

또한 문제를 해결할 때

$$\begin{aligned} p(y \mid x_1, x_2, \dots, x_n) &= \frac{p(y, x_1, x_2, \dots, x_n)}{p(x_1, x_2, \dots, x_n)} \\ &= \frac{p(x_1, x_2, \dots, x_n \mid y)p(y)}{p(x_1, x_2, \dots, x_n)} \propto p(x_1, x_2, \dots, x_n \mid y)p(y) \end{aligned}$$

와 같이 $p(x_1, x_2, \dots, x_n)$ 값을 고려하지 않고 $p(x_1, x_2, \dots, x_n \mid y)p(y)$ 값만 구할 때가 있다.



4.4 나이브 베이즈 분류기 (Naïve Bayes Classifier)

주어진 데이터 셋

Sky	Temp	Humid	Wind	Water	Forecast	Enjoy Sport
Sunny	Warm	Normal	Strong	Warm	Same	Yes
Sunny	Warm	High	Strong	Warm	Same	Yes
Rainy	Cold	High	Strong	Warm	Change	No
Sunny	Warm	High	Strong	Cool	Change	Yes

문제제기: 위와 같은 데이터 셋이 주어졌다고 가정할 때, 아래 보기에서

Enjoy Sport = Yes로 분류될 확률은 얼마인가?

Sky	Temp	Humid	Wind	Water	Forecast	Enjoy Sport
Sunny	Warm	High	Strong	Warm	Change	?



문제를 간단히 수식화 하기 위해서

Enjoy Sport = Y 로 표시하자. 이때 $Y=y(\text{yes})$ 또는 $Y=N(\text{No})$ 가 가능하다.

Sky= X_1 로 표시하자. $X_1 = x_1$ 에서 $x_1 = \text{Sunny}$ 또는 Rainy이다.

Temp= X_2 로 표시하자. $X_2 = x_2$ 에서 $x_2 = \text{Warm}$ 또는 Cold이다.

Humid = X_3 로 표시하자. $X_3 = x_3$ 에서 $x_3 = \text{Normal}$ 또는 High이다.

Wind = X_4 로 표시하자. $X_4 = x_4$ 에서 $x_4 = \text{Strong}$ 또는 Weak이다.

Water = X_5 로 표시하자. $X_5 = x_5$ 에서 $x_5 = \text{Warm}$ 또는 Cold이다.

Forecast = X_6 로 표시하자. $X_6 = x_6$ 에서 $x_6 = \text{Same}$ 또는 Change이다.

$p(\text{Enjoy Sport} \mid \text{Sunny, Warm, High, Strong, Change})?$

$p(y \mid x_1, x_2, x_3, x_4, x_5, x_6)?$



$$p(y \mid x_1, x_2, x_3, x_4, x_5, x_6) = \frac{p(y, x_1, x_2, x_3, x_4, x_5, x_6)}{p(x_1, x_2, x_3, x_4, x_5, x_6)}$$

$$\begin{aligned} p(y, x_1, x_2, x_3, x_4, x_5, x_6) &= p(x_1, x_2, x_3, x_4, x_5, x_6 \mid y) p(y) \\ &= p(x_1 \mid y) p(x_2 \mid y) p(x_3 \mid y) p(x_4 \mid y) p(x_5 \mid y) p(x_6 \mid y) p(y) \end{aligned}$$

따라서

$$\begin{aligned} p(y \mid x_1, x_2, x_3, x_4, x_5, x_6) &= \frac{1}{p(x_1, x_2, x_3, x_4, x_5, x_6)} p(x_1 \mid y) \cdot p(x_2 \mid y) p(x_3 \mid y) p(x_4 \mid y) p(x_5 \mid y) p(x_6 \mid y) p(y) \\ &\propto p(y) p(x_2 \mid y) p(x_3 \mid y) p(x_4 \mid y) p(x_5 \mid y) p(x_6 \mid y) \end{aligned}$$



$$\Pr(\text{Yes})=3/4 \quad \Pr(\text{No})=1/4$$

$$\Pr(\text{Sunny}|\text{Yes})=1$$

$$\Pr(\text{Warm}|\text{Yes})=1$$

$$\Pr(\text{High}|\text{Yes})=2/3$$

$$\Pr(\text{Strong}|\text{Yes})=1$$

$$\Pr(\text{Warm}|\text{Yes})=2/3$$

$$\Pr(\text{Change}|\text{Yes})=1/3$$

$$p(y)p(x_2 | y)p(x_3 | y)p(x_4 | y)p(x_5 | y)p(x_6 | y)$$

$$= \frac{3}{4} \times 1 \times \frac{2}{3} \times 1 \times \frac{2}{3} \times \frac{1}{3} = \frac{1}{9}$$

Sky	Temp	Humid	Wind	Water	Forecast	Enjoy Sport
Sunny	Warm	Normal	Strong	Warm	Same	Yes
Sunny	Warm	High	Strong	Warm	Same	Yes
Rainy	Cold	High	Strong	Warm	Change	No
Sunny	Warm	High	Strong	Cool	Change	Yes

문제제기: 위와 같은 데이터 셋이 주어졌다고 가정할 때, 아래 보기에서
Enjoy Sport = Yes로 분류될 확률은 얼마인가?

Sky	Temp	Humid	Wind	Water	Forecast	Enjoy Sport
Sunny	Warm	High	Strong	Warm	Change	?



4.5 마르코프 결정과정 (Markov decision process (MDP))

마르코프 결정과정 이론을 간단한 예로 설명하고 자 한다. 어느 지역의 날씨가 하루 종일 셋 중의 하나라고 가정해 보자, sunny, rainy, foggy. 중간에 sunny 에서 rainy 로 바뀌는 일은 없다. 하루의 날씨는 오로지 위 셋 중의 하나라고 좀 무리하지만 단순한 가정을 해보라. 날씨의 예측은 오늘과 순차적인 과거의 날씨에 제한을 받는다고 가정하자. 이를 표현하면 아래와 같다.

$$p(w_n | w_{n-1}, w_{n-2}, \dots, w_1)$$

$$p(w_n | w_{n-1}, w_{n-2}, \dots, w_1) = p(w_n | w_{n-1}): \text{1차 마르코프 체인}$$

$$p(w_n | w_{n-1}, w_{n-2}, \dots, w_1) = p(w_n | w_{n-1}, w_{n-2}): \text{2차 마르코프 체인}$$



오늘 날씨: sunny, 어제 날씨: sunny 그저께 날씨: foggy일 때 내일의 날씨가 rainy
인 확률을 표현하면 아래와 같다.

$$p(w_4 = \text{rainny} \mid w_3 = \text{sunny}, w_2 = \text{foggy}, w_1 = \text{rainny})$$

하나의 문제는 n 이 커질수록 수집해야할 통계량이 기하급수적으로 많아진다. $n = 5$ 이면
 $3^5 = 243$ 의 과거 데이터의 통계량이 필요하다. 일반적으로 마르코프체인을 생각하는 경우
는 1차 마르코프 체인을 의미하는 경우가 많다, $p(w_n \mid w_{n-1})$.

여기서도 1차 마르코프인 경우만 생각하자.




1차 마르코프 체인을 이용하면 결합확률 분포를 계산할 수 있다.

$$\begin{aligned} p(w_1, w_2, \dots, w_n) &= p(w_1 | w_2, \dots, w_n) p(w_2, \dots, w_n) \\ &= p(w_1 | w_2) p(w_2, \dots, w_n) \\ &= p(w_1 | w_2) p(w_2 | w_3, \dots, w_n) p(w_3, \dots, w_n) \\ &= p(w_1 | w_2) p(w_2 | w_3) p(w_3, \dots, w_n) \\ &\quad \vdots \\ &= p(w_1 | w_2) p(w_2 | w_3) \cdots p(w_{n-1} | w_n) \\ &= \prod_{i=1}^n p(w_i | w_{i-1}) \end{aligned}$$



$n = 1$ 인 1차 마르코프 체인인 경우는 $3^2 = 9$ 의 통계량만 필요하다.
그래서 아래와 같은 확률분포 테이블을 구했다고 생각해 보자.

		Tomorrow's Weather		
		sunny	rainy	foggy
Today's Weather	sunny	0.8	0.05	0.15
	rainy	0.2	0.6	0.2
	foggy	0.2	0.3	0.5



[위 표를 그림으로 그린 것]



문제1: 오늘 날씨는: sunny일때 내일 날씨는 sunny 모레날씨는 rainy인 확률을 위 | 표
를 이용하여 구하라.

[풀이] $w_1 = sunny$, $w_2 = sunny$, $w_3 = rainy$ 라 하면 구하는 확률은

$p(w_2 = sunny, w_3 = rainy | w_1 = sunny)$ 이다. 계산을 위하여
 $p(w_2, w_3 | w_1)$ 로 표시하자.

$$\begin{aligned}
 p(w_2, w_3 | w_1) &= \frac{p(w_2, w_3, w_1)}{p(w_1)} \\
 &= \frac{p(w_3 | w_2, w_1) p(w_2, w_1)}{p(w_1)} \\
 &= \frac{p(w_3 | w_2) p(w_2 | w_1) p(w_1)}{p(w_1)} \\
 &= p(w_3 | w_2) p(w_2 | w_1) \\
 &= p(w_3 = rainy | w_2 = sunny) p(w_2 = sunny | w_1 = sunny) \\
 &= 0.05 \times 0.8 = 0.04
 \end{aligned}$$

		Tomorrow's Weather		
		sunny	rainy	foggy
Today's Weather	sunny	0.8	0.05	0.15
	rainy	0.2	0.6	0.2
	foggy	0.2	0.3	0.5



문제2: 오늘 날씨는: foggy일 때, 모레 날씨가 *rainy*될 확률을 구하라.

[풀이] 모레 비오는 경우는 다음 세 가지가 있다.

$\{ \text{foggy}, \text{foggy}, \text{rainy} \}, \{ \text{foggy}, \text{rainy}, \text{rainy} \}, \{ \text{foggy}, \text{sunny}, \text{rainy} \}$

$$p(w_3 = \text{rainy} | w_1 = \text{foggy})$$

$$= p(w_2 = \text{foggy}, w_3 = \text{rainy} | w_1 = \text{foggy})$$

$$+ p(w_2 = \text{rainy}, w_3 = \text{rainy} | w_1 = \text{foggy})$$

$$+ p(w_2 = \text{sunny}, w_3 = \text{rainy} | w_1 = \text{foggy})$$

$$= p(w_3 = \text{rainy} | w_2 = \text{foggy}) p(w_2 = \text{foggy} | w_1 = \text{foggy})$$

$$+ p(w_3 = \text{rainy} | w_2 = \text{rainy}) p(w_2 = \text{rainy} | w_1 = \text{foggy})$$

$$+ p(w_3 = \text{rainy} | w_2 = \text{sunny}) p(w_2 = \text{sunny} | w_1 = \text{foggy})$$

$$= 0.3 \times 0.5 + 0.6 \times 0.3 + 0.05 \times 0.2$$

$$= 0.34$$

		Tomorrow's Weather		
		sunny	rainy	foggy
Today's Weather	sunny	0.8	0.05	0.15
	rainy	0.2	0.6	0.2
	foggy	0.2	0.3	0.5