

머신러닝과 데이터 처리

02 데이터 처리

목차 02 데이터 처리

1. 결측치와 이상치
2. 결측치 처리하기
3. 이상치 처리하기

1. 결측치와 이상치



강의에 앞서

머신러닝과 데이터 처리

데이터 처리

결측치와 이상치

	PassengerId	Survived	Pclass
0	1	0	3
1	2	1	1
2	3	1	3

데이터



데이터 조작 도구



시각화 도구






강의에 앞서

머신러닝과 데이터 처리


데이터 처리

결측치와 이상치





이번 강의에선



☑ 결측치 처리 방법



☑ 이상치 처리 방법





- 일부 누락된 데이터
- 데이터 분석에 방해가 되므로 적절한 처리 필요
- 분석가의 견해 반영, 분석하는 사람에 따라 다른 결과 도출




결측치 확인하기

```
titanic.isnull().sum()
```

PassengerId	0
Survived	0
Pclass	0
Name	0
Sex	0
Age	177
SibSp	0
Parch	0
Ticket	0
Fare	0
Embarked	2
dtype:	int64

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Embarked
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...)	female	38.0	1	0	PC 17599	71.2833	C
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	S
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	S
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	S




- 다른 데이터와 동떨어진 분포의 데이터
- 분석의 결과를 편향, 왜곡되게 함
- 모델 성능에 악영향



이상치 확인하기

```
%matplotlib inline

boxplot = titanic.boxplot(column = ['Age'])
```



	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Embarked
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	S
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	S
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	S

2. 결측치 처리하기



수집

결측된 데이터를 수집

대체

다른 값으로 대체

제거

데이터를 삭제



수집

- 결측된 데이터를 추가로 수집할 수 있다면 가장 좋음
- 추가 수집이 불가능한 경우 많음
- 비용 및 시간 소요

대체

- 적절한 방법을 사용하여 다른 값으로 대체
- 데이터가 적을 때 사용
- 데이터에 편향이 생길 수 있음

제거

- 결측치가 포함된 행 또는 열 삭제
- 수집 및 대체가 불가능할 경우 사용
- 데이터가 충분한 경우 사용




서울의 월별 기온	평균기온	최고기온	최저기온
2022-01		8.4	-11.3
2022-02	-1.1	11.5	-10.7
2022-03	7.7	19.5	-3.0
2022-04	14.8	28.7	3.5

행의 정보로 결측치를 추론하여 대체
변수간의 결합으로 다른 변수를 설명할 수 있을 때

서울의 월별 기온	평균기온	최고기온	최저기온
2022-01	-2.2	8.4	-11.3
2022-02	-1.1	11.5	-10.7
2022-03	7.7		-3.0
2022-04	14.8	28.7	3.5

열의 정보로 결측치를 추론하여 대체
주로 시계열 데이터에서 사용





서울의 월별 기온	평균기온	최고기온	최저기온
2022-01			-11.3
2022-02	-1.1	11.5	-10.7
2022-03	7.7	19.5	-3.0
2022-04	14.8	28.7	3.5

행 전체를 삭제

데이터가 충분히 많은 경우 사용

서울의 월별 기온	평균기온	최고기온	최저기온
2022-01	-2.2		-11.3
2022-02	-1.1	11.5	-10.7
2022-03	7.7		-3.0
2022-04	14.8		3.5

열 전체를 삭제

분석에 큰 의미가 없거나 데이터의 대다수가 결측된 경우 사용



타이타닉 데이터를 활용한 결측치 처리 실습

머신러닝과 데이터 처리

데이터 처리

결측치 처리하기

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	S

3. 이상치 처리하기



대체

다른 값으로 대체

변수화

다른 변수로 대체

제거

데이터를 삭제



대체

- 통계적 방법으로 이상치를 대체
- 데이터의 수가 적을 때 주로 사용

변수화

- 데이터를 설명할 수 있는 변수로 변환
- 오류에 의한 이상치가 아닌 경우에 사용

제거

- 오류에 의한 이상치인 경우 데이터를 삭제
- 데이터의 수가 충분할 때 주로 사용



이상치 대체

머신러닝과 데이터 처리

데이터 처리

이상치 처리하기

서울의 월별 기온	평균기온	최고기온	최저기온
2022-01	-22	8.4	-11.3
2022-02	-1.1	11.5	-10.7
2022-03	7.7	19.5	-3.0
2022-04	14.8	28.7	3.5

행의 정보로 이상치를 추론하여 대체
변수간의 결합으로 다른 변수를 설명할 수 있을 때

서울의 월별 기온	평균기온	최고기온	최저기온
2022-01	-2.2	8.4	-11.3
2022-02	-1.1	11.5	-10.7
2022-03	7.7	67.1	-3.0
2022-04	14.8	28.7	3.5

열의 정보로 이상치를 추론하여 대체
주로 통계값을 이용




이상치 변수화

문화지리학과 졸업생 연봉	연봉 (\$)
...	23,000
...	19,000
Michael Jordan	630,000
...	30,000



문화지리학과 졸업생 연봉	연봉
...	20k~20k
...	15k~20k
Michael Jordan	over 30k
...	over 30k

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	S



☑ 결측치 처리 방법

수집

결측된 데이터를 수집

대체

다른 값으로 대체

제거

데이터를 삭제

☑ 이상치 처리 방법

대체

다른 값으로 대체

변수화

다른 변수로 대체

제거

데이터를 삭제