

머신러닝과 데이터 처리

04 데이터와 특성 중요도

목차 04 데이터와 특성 중요도

1. 의사결정나무로 알아보는 특성 중요도
2. 특성 엔지니어링

1. 의사결정나무로 알아보는 특성 중요도



EDA

- 탐색적 데이터 분석
- pandas
- Matplotlib,
seaborn

결측치와 이상치

- 결측치와 이상치
- 대체
- 제거
- 변수화

데이터 불균형

- 데이터 불균형
- Undersampling
- Oversampling




의사결정나무

특성 중요도


특성 엔지니어링




- 시각적으로 쉽게 이해할 수 있는 모델
- 스무고개와 같이 특정 질문을 통해 정답을 찾아가는 모델
- 분류와 회귀 모두 사용 가능



- 특정 질문들을 통해 정답을 찾아가는 모델
- 최상단 Root Node에서 마지막 Terminal Node까지 아래 방향으로 진행




- 회귀를 위한 의사결정나무 모델의 학습 방법과 예측 방법
- 위에서 아래로 진행될수록 데이터의 구역을 나눔



- 겹치지 않는 구역으로 데이터를 나눔

- 특정 구역에 데이터가 있으면 예측값은 해당 구역의 평균 값




- $RSS = \sum_{i=1}^n (y_i - f(x_i))^2$


- 좌/우 노드의 RSS 합이 가장 작은 지점에서 분할

- 이 지점이 전체 RSS를 가장 많이 감소시키는 지점

- RSS값이 임계값 이하이거나 트리의 지정된 깊이까지 반복




- 구역을 나누는데 오차제곱합 대신 불순도 사용
- 불순도란 다른 데이터가 섞여 있는 정도



- 지니 불순도 (*Gini Impurity*)
- 선택된 항목이 임의로 잘못 분류될 확률
- 각 클래스의 비율의 제곱합을 1에서 뺀 값
 - $Gini Impurity = 1 - (yes의 확률)^2 - (no의 확률)^2$



전체 학생 100명 중 대학 졸업 여부



- $Gini\ Impurity = 1 - (yes\text{의 확률})^2 - (no\text{의 확률})^2$

- $Age \geq 25\text{의 } Gini\ impurity = 1 - \left(\frac{50}{(50+25)}\right)^2 - \left(\frac{25}{(50+25)}\right)^2$

- $Age < 25\text{의 } Gini\ impurity = 1 - \left(\frac{15}{(15+10)}\right)^2 - \left(\frac{10}{(15+10)}\right)^2$

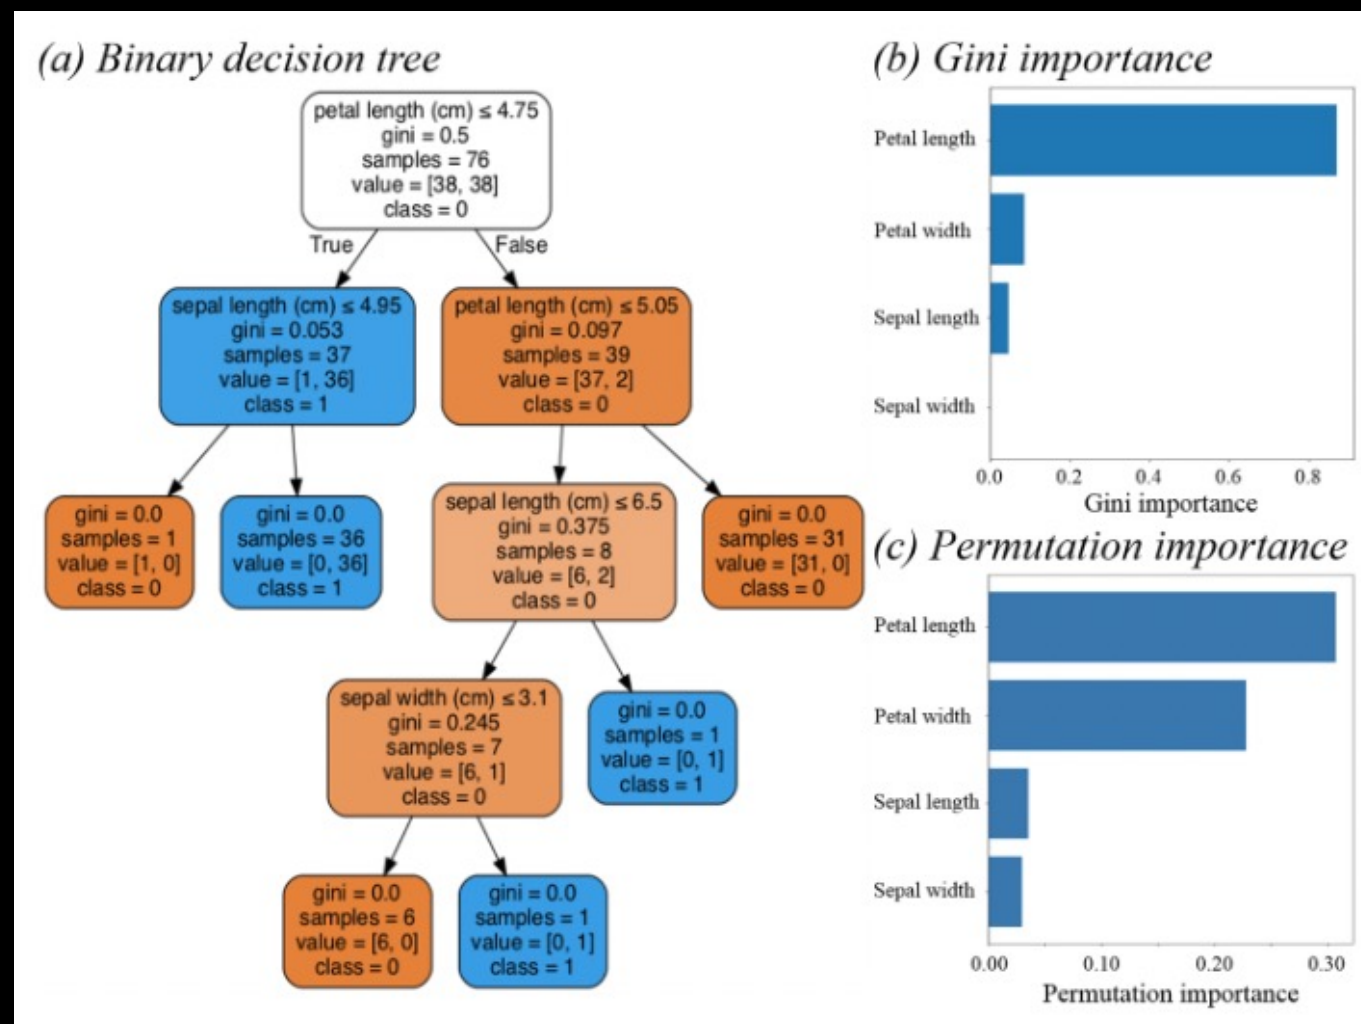


• 특성중요도는 각 특성이 모델의 예측에 기여하는 정도 지표


• 지니계수를 이용해 특성중요도를 계산

• 각 특성별 지니 계수 감소량을 통해 특성중요도 파악


- 특정 특성을 활용해 분할했을 때 불순도가 가장 크게 감소했다는 것
-> 해당 특성이 데이터를 분류하는데 가장 큰 차이를 만들었다는 뜻




(a) Binary decision tree



(b) Gini importance



(c) Permutation importance



2. 특성 엔지니어링




- 새로운 관측치나 변수를 추가하지 않고도 데이터를 보다 유용하게 만드는 방법
- 기존 데이터를 활용
- 데이터를 더 잘 설명하는 특성을 생성해 모델의 성능을 개선



스케일링
Scaling

비닝
Binning

더미
Dummy



- 데이터의 값 범위를 일정한 범위로 조정하는 과정
- 특정 특성 값들이 과도하게 크거나 작아서 발생하는 문제 방지
- 표준화, 정규화 등 다양한 방법 존재




비닝(Binning) & 더미(Dummy)

머신러닝과 데이터 처리

데이터와 특성 중요도

특성 엔지니어링



- 비닝: 수치형 데이터를 구간을 활용하여 범주형 데이터로 변경
- 더미: 범주형 데이터를 이진벡터를 활용하여 변경
 - One-hot Encoding



타이타닉 데이터로 특성 엔지니어링 실습

머신러닝과 데이터 처리

데이터와 특성 중요도

특성 엔지니어링

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	S

