

머신러닝과 데이터 처리

03 불균형한 데이터 처리

목차 03 불균형한 데이터 처리

1. 데이터 불균형
2. 데이터 불균형 처리

1. 데이터 불균형



강의에 앞서

머신러닝과 데이터 처리

불균형한 데이터 처리

데이터 불균형

	PassengerId	Survived	Pclass
0	1	0	3
1	2	1	1
2	3	1	3

데이터



데이터 조작 도구



시각화 도구









강의에 앞서

머신러닝과 데이터 처리

불균형한 데이터 처리

데이터 불균형





☑ 결측치 처리 방법

수집
결측된 데이터를 수집

대체
다른 값으로 대체

제거
데이터를 삭제

☑ 이상치 처리 방법

대체
다른 값으로 대체

변수화
다른 변수로 대체

제거
데이터를 삭제




이번 강의에선


머신러닝과 데이터 처리

불균형한 데이터 처리


데이터 불균형




Original Dataset



Generating Samples



Resampled Dataset




Original Dataset


- 추론하고자 하는 데이터의 분포가 다른 데이터
- 모델의 **과적합**을 유발
- 적절한 방식으로 처리해야 함

	index	quality	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	type
0	0	5	5.6	0.695	0.06	6.8	0.042	9.0	84.0	0.99432	3.44	0.44	10.2	white
1	1	5	8.8	0.610	0.14	2.4	0.067	10.0	42.0	0.99690	3.19	0.59	9.5	red
2	2	5	7.9	0.210	0.39	2.0	0.057	21.0	138.0	0.99176	3.05	0.52	10.9	white
3	3	6	7.0	0.210	0.31	6.0	0.046	29.0	108.0	0.99390	3.26	0.50	10.8	white
4	4	6	7.8	0.400	0.26	9.5	0.059	32.0	178.0	0.99550	3.04	0.43	10.9	white
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
5492	5492	5	7.7	0.150	0.29	1.3	0.029	10.0	64.0	0.99320	3.35	0.39	10.1	white
5493	5493	6	6.3	0.180	0.36	1.2	0.034	26.0	111.0	0.99074	3.16	0.51	11.0	white
5494	5494	7	7.8	0.150	0.34	1.1	0.035	31.0	93.0	0.99096	3.07	0.72	11.3	white
5495	5495	5	6.6	0.410	0.31	1.6	0.042	18.0	101.0	0.99195	3.13	0.41	10.5	white
5496	5496	6	7.0	0.350	0.17	1.1	0.049	7.0	119.0	0.99297	3.13	0.36	9.7	white

2. 데이터 불균형 처리



더 많은 데이터를 제거하여 데이터의 분포를 일치
데이터가 충분한 경우 사용




더 적은 데이터를 복제하여 데이터의 분포를 일치
데이터가 부족한 경우 사용




랜덤 샘플링

Tomek Links


CNN rule



- 더 많은 데이터 중 랜덤하게 선택
- 더 적은 데이터 만큼 샘플링 하여 데이터의 수를 일치



- 적은 데이터와 근접한 데이터를 삭제
- 데이터의 경계를 더 명확히 함
- 큰 데이터셋에서는 시간이 많이 소요됨




- Condensed Nearest Neighbor
- 적은 데이터와 근접한 데이터를 샘플링
- 경계 샘플들을 유지하여 데이터의 주요 구조와 패턴을 보존




Resampling

SMOTE

**Borderline
SMOTE**



- 적은 데이터를 랜덤하게 복제
- 더 많은 데이터만큼 복제하여 수를 일치시킴



- K-NN 알고리즘으로 적은 데이터를 새롭게 생성

- 과적합 문제 해결 가능


- 생성된 데이터가 기존 분포와 다를 수 있음



- 경계에 속한 데이터에 SMOTE 적용

- 모델이 경계 영역에서 더 잘 작동하도록 함

- 노이즈를 증폭시킬 위험이 있음





	index	quality	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	type
0	0	5	5.6	0.695	0.06	6.8	0.042	9.0	84.0	0.99432	3.44	0.44	10.2	white
1	1	5	8.8	0.610	0.14	2.4	0.067	10.0	42.0	0.99690	3.19	0.59	9.5	red
2	2	5	7.9	0.210	0.39	2.0	0.057	21.0	138.0	0.99176	3.05	0.52	10.9	white
3	3	6	7.0	0.210	0.31	6.0	0.046	29.0	108.0	0.99390	3.26	0.50	10.8	white
4	4	6	7.8	0.400	0.26	9.5	0.059	32.0	178.0	0.99550	3.04	0.43	10.9	white
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
5492	5492	5	7.7	0.150	0.29	1.3	0.029	10.0	64.0	0.99320	3.35	0.39	10.1	white
5493	5493	6	6.3	0.180	0.36	1.2	0.034	26.0	111.0	0.99074	3.16	0.51	11.0	white
5494	5494	7	7.8	0.150	0.34	1.1	0.035	31.0	93.0	0.99096	3.07	0.72	11.3	white
5495	5495	5	6.6	0.410	0.31	1.6	0.042	18.0	101.0	0.99195	3.13	0.41	10.5	white
5496	5496	6	7.0	0.350	0.17	1.1	0.049	7.0	119.0	0.99297	3.13	0.36	9.7	white